




UNIVERSIDAD NACIONAL DEL COMAHUE
FACULTAD DE INFORMÁTICA



TESIS DE LICENCIATURA EN SISTEMAS DE INFORMACIÓN

**Un Enfoque Top-Down de Variedad de Contexto: Caso
de estudio en la predicción del nivel de la napa freática
en el Alto Valle de Río Negro y Neuquén**

Walter Garrido

Agustina Buccella

NEUQUÉN

ARGENTINA

2025

PREFACIO

Esta tesis es presentada como parte de los requisitos finales para optar al grado académico de *Licenciado en Sistemas de Información*, otorgado por la Universidad Nacional del Comahue, y no ha sido presentada previamente para la obtención de otro título en esta Universidad u otras. La misma es el resultado de la investigación llevada a cabo en el Departamento de Ingeniería de Sistemas de la Facultad de Informática, en el período comprendido entre mes de Junio de 2024 y el mes abril de 2025, bajo la dirección de Agustina Buccella.

Garrido, Walter Rafael
FACULTAD DE INFORMÁTICA
UNIVERSIDAD NACIONAL DEL COMAHUE
Neuquén, 15/05/2025



UNIVERSIDAD NACIONAL DEL COMAHUE

Facultad de Informática

La presente tesis ha sido aprobada el día, mereciendo la calificación de

AGRADECIMIENTOS

Quiero expresar mi más sincero agradecimiento a la **Universidad Nacional del Comahue**, institución que me brindó las herramientas, el espacio y el tiempo para crecer tanto en lo académico como en lo personal.

A todos los **profesores y profesoras** que formaron parte de mi formación a lo largo de la carrera, gracias por compartir su conocimiento, su tiempo y su vocación. En especial, a mi directora de tesis, **Agustina Buccella**, por su acompañamiento, compromiso y orientación constante durante este proceso.

A mis compañeros y compañeras de facultad, con quienes compartí años de cursada, desafíos, risas y aprendizajes. Gracias por ser parte de este camino.

A mis abuelos, **Salvador y Aidé**, que ya no están físicamente, pero cuya presencia, enseñanzas y valores me acompañan siempre. Esta tesis también es para ellos.

A mi compañera de vida, **Valeria**, gracias por tu apoyo, tu paciencia infinita y por estar siempre, en cada paso.

A mis dos gatitas **Lola y Lumi**, que con su silenciosa compañía, sus ronroneos y su ternura fueron testigos fieles de tantas jornadas de estudio.

A mi mamá **Cristina**, por su amor incondicional, su fuerza y por estar siempre ahí.

A mis hermanos **Franco, Belén y Marcia**, por acompañarme a su manera, con cariño, cercanía y apoyo.

Y a mi tía, **Joaquina**, por haberme dado ese empujón inicial cuando más lo necesitaba. Ese gesto fue clave, y lo llevo conmigo.

A todos ustedes, gracias por acompañarme y por ser parte de este logro

RESUMEN

La agricultura de precisión busca optimizar la producción agrícola mediante la incorporación de tecnologías que permitan un manejo más eficiente de los recursos. En este contexto, el monitoreo del nivel freático cobra especial relevancia, ya que influye directamente en la gestión del riego y en la productividad de los cultivos. Sin embargo, el análisis de grandes volúmenes de datos hidrológicos y climáticos representa un desafío que puede ser abordado mediante el uso de Sistemas de Big Data.

Esta tesis se motiva por la necesidad de aplicar enfoques analíticos avanzados para predecir el nivel freático en zonas de producción agrícola. El objetivo principal es evaluar cómo los Sistemas de Big Data, pueden contribuir a generar predicciones precisas a partir de datos climáticos e hidrológicos.

La metodología adoptada se basa en un enfoque top-down, propuesto en trabajos previos del grupo de investigación en el que se enmarca esta tesis. Esta metodología permite guiar el proceso desde la formulación de hipótesis hasta la obtención de resultados concretos. Se desarrollan dos casos de dominio en la región de Villa Regina, utilizando datos de la estación meteorológica, niveles de río y mediciones de freatómetros.

Los resultados obtenidos muestran que, durante el período sin riego, los modelos LSTM (Long Short-Term Memory) permitieron realizar predicciones con un alto grado de precisión, utilizando variables climáticas e hidrológicas. Sin embargo, en el período con riego no se logró validar ninguna de las hipótesis planteadas, lo que sugiere que la activación del canal de riego y por ende el riego que se produce en la zona, podría estar interfiriendo en el proceso de recarga de la napa freática. Esta situación plantea nuevos interrogantes que se proponen como trabajos futuros. Además, se utilizó la herramienta CoVaMaT (Context-based Variety Management Tool) para documentar y almacenar la variedad de contexto identificada en los casos analizados, promoviendo la reutilización de activos en futuros desarrollos.

En conclusión, este trabajo evidencia que el uso de metodologías y tecnologías para el desarrollo de Sistemas de Big Data en el dominio de la agricultura de precisión permite generar conocimiento valioso para la toma de decisiones en la gestión del agua subterránea en zonas agrícolas.

ABSTRACT

Precision agriculture aims to optimize agricultural production through the incorporation of technologies that enable more efficient resource management. In this context, monitoring groundwater levels becomes especially relevant, as it directly influences irrigation management and crop productivity. However, the analysis of large volumes of hydrological and climatic data presents a challenge that can be addressed through the use of Big Data Systems.

This thesis is motivated by the need to apply advanced analytical approaches to predict groundwater levels in agricultural production areas. The main objective is to evaluate how Big Data Systems, supported by neural network models, can contribute to generating accurate predictions based on climatic and hydrological data.

The adopted methodology is based on a top-down approach, as proposed in previous work by the research group to which this thesis belongs. This methodology guides the process from hypothesis formulation to the achievement of concrete results. Two domain-specific case studies are developed in the Villa Regina region, using data from the meteorological station, river levels, and groundwater monitoring wells (piezometers).

The results obtained show that, during the non-irrigation period, LSTM (Long Short-Term Memory) models allowed highly accurate predictions using climatic and hydrological variables. However, during the irrigation period, none of the proposed hypotheses could be validated, suggesting that the activation of the irrigation canal—and consequently the irrigation practices in the area—may interfere with the groundwater recharge process. This situation raises new questions that are proposed as future work. Additionally, the CoVaMaT (Context-based Variety Management Tool) tool was used to document and store the context variability identified in the analyzed cases, promoting the reuse of assets in future developments.

In conclusion, this work demonstrates that the use of methodologies and technologies for the development of Big Data Systems in the domain of precision agriculture can generate valuable knowledge for decision-making in groundwater management in agricultural areas.

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Objetivo General	4
1.3. Objetivos Específicos	4
1.4. Metodología	4
1.5. Estructura	5
2. Big Data, Aplicaciones y Trabajos Previos	7
2.1. Conceptos de Big Data	7
2.2. Ciclo de Vida de Big Data	8
2.2.1. Evaluación del caso del negocio	8
2.2.2. Identificación y recolección de datos	9
2.2.3. Preparación de datos	10
2.2.4. Análisis de datos	12
2.2.5. Modos de análisis	16
2.2.6. Visualización y utilización de los resultados	17
2.3. Dominio de Agricultura de Precisión	17
2.4. Trabajos Relacionados	19
2.4.1. Trabajo presentado por Lallahem et al. [1]	19
2.4.2. Trabajo presentado por Stricevic et al. [2]	21
2.4.3. Trabajo presentado por Shamsuddin et al. [3]	23
2.4.4. Trabajo presentado por Sun et al. [4]	24
2.4.5. Trabajo presentado por El Bilali et al. [5]	26
2.4.6. Trabajo presentado por Liu et al. [6]	27
2.5. Resumen de los Trabajos Relacionados	29
2.6. Trabajos Previos dentro del Proyecto de Investigación	32
2.6.1. Enfoques para la Identificación de la Variedad	32
2.6.2. Herramienta para la Gestión de la Variedad basada en Contexto (CoVaMaT)	35
2.7. Resumen del capítulo	37
3. Enfoque T-VIP para la Agricultura de Precisión	39
3.1. Enfoque T-VIP en dos casos de dominio	39
3.1.1. Caso de Dominio 1: periodo sin Riego	40
3.1.2. Caso de Dominio 2: periodo con Riego	68
3.2. Resumen del Capítulo	81
4. Conclusiones y trabajo futuro	83
4.1. Resumen del Trabajo	83
4.2. Limitaciones y Trabajos Futuros	85

Índice de figuras

1.1. Enfoques Top-Down (T-VIP) y Bottom-up (B-VIP) para el desarrollo de SBD considerando variedades	3
2.1. Ciclo de Vida de Big Data (Extraída de [7])	8
2.2. Dibujo de un Freatímetro con cada una de sus partes (extraída de [8])	19
2.3. Mapa de ubicación de la zona de estudio en Francia (extraída de [1])	20
2.4. Mapa de ubicación de la zona de estudio en Rio Danubio (extraída de [2])	22
2.5. Mapa de ubicación de la zona de estudio (extraída de [3])	24
2.6. Mapa de ubicación de la zona de estudio (extraída de [4])	25
2.7. Mapa de ubicación de la zona de estudio en Marruecos (extraída de [5])	27
2.8. Mapa de ubicación de la zona de estudio Rio Tarim (extraída de [6])	28
2.9. Resumen de los trabajos relacionados	31
2.10. Enfoques Top-Down (T-VIP) y Bottom-up (B-VIP) para el desarrollo de SBD considerando variedades	34
2.11. Ejemplo de modelos de variabilidad (extraída de [9])	37
3.1. Enfoque T-VIP aplicado a dos casos de dominio	40
3.2. Proceso P-1 donde documentamos la variedad de contexto como un nuevo <i>Activo de dominio de Agricultura de Precisión</i> en CoVaMaT	41
3.3. Proceso P-1 donde documentamos la variedad de las fuentes dentro del <i>Activo de dominio de Agricultura de Precisión</i> en CoVaMaT	43
3.4. Proceso P-1 donde documentamos la variedad de contenido como activo de dominio de Agricultura de Precisión en CoVaMaT	47
3.5. Comparación del nivel del Río Negro y las mediciones en distintos freatímetros.	49
3.6. Resultados del análisis de correlación para el Conjunto de Datos <i>freatímetroCotaCompleto</i> y <i>nivelRíoPromedio</i> utilizando los técnicas de Pearson, Spearman y Kendall	50
3.7. Representación de los freatímetros con un código de colores según su distancia al río: verde = correlación fuerte, amarillo = correlación intermedia y rojo = correlación débil o nula.	51
3.8. Comparación entre valores reales (azul) y predicciones del modelo LSTM (naranja) para el nivel freático.	55
3.9. Comparación entre valores reales (azul) y predicciones del modelo LSTM (naranja) para el nivel freático en la segunda configuración.	56
3.10. Comparación entre los valores reales (azul) y las predicciones (naranja) para las tres configuraciones del modelo LSTM.	59
3.11. Resultados de las correlaciones entre el nivel freático y las variables climáticas utilizando Pearson.	60
3.12. Comparación entre valores reales (azul) y predicciones (naranja) del modelo LSTM para el nivel freático utilizando variables climáticas.	62

3.13. Comparación entre los valores reales y las predicciones para las dos configuraciones del modelo LSTM.	64
3.14. Proceso P-1 donde documentamos la variedad de procesos como <i>activo de dominio de Agricultura de Precisión</i> en CoVaMaT	66
3.15. Ejemplo de entrada de datos en el formulario interactivo para la predicción del nivel freático.	66
3.16. Proceso P-1 donde documentamos la variedad de contexto como un nuevo activo de dominio de Agricultura de Precisión en CoVaMaT	69
3.17. <i>Caso de dominio sin riego VR</i> creado a partir de las instancias del <i>Activo de dominio de Agricultura de Precisión</i>	69
3.18. Caso de dominio 2 donde vemos el canal de riego activo	70
3.19. Creación de una nueva variedad de contexto y del <i>Caso reusable periodo con riego</i>	70
3.20. Instanciación de las variables asociadas con el <i>Activo de dominio de Agricultura de Precisión</i> al <i>Caso reusable periodo con riego VR</i>	71
3.21. Comparación del nivel del Río Negro y las mediciones en distintos freáticos	73
3.22. Resultados del análisis de correlación para el Conjunto de Datos freáticoCotaCompleto_C2 y nivelRíoPromedio_C2 con las técnicas de Pearson, Spearman y Kendall	74
3.23. Representación de los freáticos con un código de colores según su distancia al río: amarillo = correlación intermedia y rojo = correlación débil o nula.	75
3.24. Resultados de las correlaciones entre el nivel freático y las variables climáticas utilizando Pearson.	76
3.25. Comparación del porcentaje de cambio en la correlación de Pearson entre los periodos sin riego y con riego para cada freático	79
3.26. Proceso P-1 donde documentamos la nueva variedad de procesos para la comparación como <i>activo de dominio de Agricultura de Precisión</i> en CoVaMaT	80
3.27. <i>Caso reusable con riego VR</i> creado a partir de las instancias del <i>Activo de dominio de Agricultura de Precisión</i> y del <i>Caso de dominio sin riego VR</i>	81

Capítulo 1

Introducción

En este capítulo describimos el contexto en el cual se enmarca este trabajo de tesis y la motivación de la realización del mismo. Además, se describen los objetivos, la metodología empleada para su desarrollo y su estructura.

1.1. Motivación

En la actualidad, es cada vez más común que las organizaciones adopten un enfoque diferenciado en el uso de los datos, yendo más allá del simple almacenamiento y consulta. El verdadero desafío radica ahora en aprovechar de manera efectiva la información generada, especialmente considerando la gran cantidad de datos disponibles en diversos formatos y sistemas. Muchos de estos datos permanecen subutilizados o se gestionan como pasivos, desaprovechando su potencial para generar valor estratégico. De esta manera, surgen nuevos tipos de requerimientos enfocados ahora en el aprovechamiento rápido y eficiente de toda la información disponible. Estos nuevos requerimientos son en la actualidad posibles de afrontar gracias a los avances tanto técnicos como tecnológicos en el campo de la ingeniería de software y de los sistemas inteligentes, creando los hoy llamados Sistemas de Big Data (SBD)¹ [10, 11]. Estos sistemas engloban el tipo de software y recursos necesarios para reunir la información recopilada en las organizaciones y que pueda ser aprovechada para la extracción y producción de nueva información realmente útil, en especial para la toma de decisiones. Así, los SBD están dedicados a la recopilación, transformación y explotación de datos generados desde diferentes fuentes, con diferentes características y estructuras, permitiendo obtener nuevos descubrimientos y patrones no visibles a simple vista. Al mismo tiempo, es importante reconocer a estos sistemas como multidisciplinarios y orientados al dominio. La primera se refiere a que del proceso de construcción y luego del uso de estos sistemas participan diferentes actores de varias disciplinas como, informáticos, técnicos y expertos del dominio. A su vez, estos últimos aportan el conocimiento del dominio en donde se enmarcan los SBD, permitiendo conocer, guiar y mejorar las actividades involucradas y los resultados obtenidos. A nivel de software, las particularidades dentro de los dominios generan artefactos comunes y variantes que permiten la creación de estos sistemas bajo los principios de reusabilidad y flexibilidad.

En este contexto, en este trabajo de tesis se plantea trabajar en el dominio de la agricultura y más específicamente en la *agricultura de precisión*. Según [12], *la agricultura de precisión es la aplicación de tecnologías y principios para gestionar la variabilidad espacial y temporal asociada con todos los aspectos de la producción agrícola con el fin de mejorar el rendimiento de los cultivos y la calidad ambiental*. En particular en este trabajo nos centramos principalmente en el problema de las fluctuaciones de la napa freática, ya que los niveles de las mismas impactan directamente sobre las plantaciones. Niveles de napa freática altos (ceranos a la superficie) pueden generar problemas como mayor salinidad del suelo y/o ventajas como contribuir con el desarrollo del

¹en ingles, Big Data System

cultivo ya que el mismo puede utilizar esta agua para abastecerse. Lo mismo sucede con niveles freáticos bajos, es decir, muy lejos de la superficie en donde las plantaciones corren el riesgo de no conseguir el agua suficiente, o recibir demasiada con fuentes artificiales de abastecimiento (como riego por aspersión, manto, etc.). De esta forma, en los ambientes productivos, como es el caso del Alto Valle de Río Negro y Neuquén, es sumamente importante conocer el comportamiento de las napas freáticas de forma tal de poder analizar la dinámica del agua y su calidad para mantener a los suelos saludables [13].

Existen varios trabajos en la literatura que desarrollan SBD para estudiar diferentes aspectos dentro de este dominio [1, 2, 3, 4, 5]. Por ejemplo, la propuesta presentada en [1] utiliza datos recopilados durante 11 años (del 1988 al 1999) en intervalos de 1 mes e implementa una red neuronal artificial [14] para predecir el comportamiento del nivel de las aguas subterráneas. Como datos característicos de entrada utilizaron mediciones de freatímetros, lluvia, temperatura y evaporación. También, en el trabajo presentado en [2], los autores utilizaron datos temporales desde el año 1990 al 2010, obtenidos de freatímetros para predecir el nivel de la napa y comparar modelos paramétricos para obtener el mas eficiente. Para ello utilizaron datos del nivel de agua en pozos cercanos, nivel del río, nivel del canal, precipitación y evapotranspiración. Por último podemos citar el trabajo presentado en [3] en donde, basados en datos tales como lluvia, nivel del río, flujo superficial y la temperatura de los años 2015 a 2016, demostraron la aplicabilidad de la filtración fluvial y su potencial en la modelización de las fluctuaciones del nivel de agua. También analizaron la relación entre el río y el acuífero en la zona de estudio.

El trabajo de esta tesis se enmarca en una metodología de desarrollo de SBD realizada en trabajos previos por el grupo de investigación, la cual se basa en el concepto *variedad* como aspecto clave del reuso. La variedad se define en base a cuatro aspectos principales que ayudan a guiar el desarrollo de las actividades de un proceso de big data tradicional. La definición de dichas variedades ayuda a la creación de activos dentro del dominio en donde se lleva a cabo el desarrollo, que por la forma de ser creados, pueden ser reusados en casos futuros [15, 16, 17, 18]. En la Figura 1.1 podemos observar la metodología completa, en donde en el lado izquierdo se detallan las cuatro variedades definidas. La *variedad de fuentes* se define como los posibles tipos y formatos en que se pueden encontrar los datos dentro del dominio; la *variedad de contenido* se refiere a las variables y/o factores interesantes, que provienen de las fuentes, y que serán útiles para las actividades de análisis previstas; la *variedad de procesos* define el abanico de técnicas de análisis posibles que permitan extraer conocimiento utilizando las variables definidas previamente, e incorpora también el tipo de procesamiento que se puede realizar; y por último la *variedad de contexto* define el contexto semántico en función del entorno y particularidades del dominio, y es el punto central para conocer la forma en la que se llevarán a cabo las actividades para su posible reuso. Estas cuatro variedades son el eje de la metodología la cual define dos enfoques para hacer posible su identificación, ellos son: top-down (T-VIP)² y bottom-up (B-VIP)³. Como podemos observar del lado izquierdo de la Figura 1.1, el enfoque T-VIP parte de hipótesis bien definidos por los usuarios expertos del dominio y aplica el proceso de big data (actividades en la parte central del figura) para la verificación y corroboración de las mismas; responde a la pregunta ¿los datos corroboran las hipótesis?. Por otro lado, el enfoque B-VIP se basa en un estudio exploratorio, sin hipótesis definidas, en donde se analiza la información disponible en las fuentes para encontrar patrones y/o comportamientos ocultos en los mismos; responde a la pregunta ¿qué dicen los datos?. Otro aspecto sumamente importante dentro de la metodología es la definición de activos dentro de una base de conocimiento, la cual se denomina CoVaMaT (Context-based Variety Management Tool) [15, 19]. Dicha base (lado derecho de la figura en verde), que esta soportada por una herramienta, posee tres activos principales que permiten documentar las variedades encontradas durante el desarrollo del sistema de big data. Así, los activos denominados *variedad de dominio* permiten documentar las cuatro variedades

²en ingles , Top-down Variety Identification Process

³en ingles, Bottom-up Variety Identification Process




Figura 1.1: Enfoques Top-Down (T-VIP) y Bottom-up (B-VIP) para el desarrollo de SBD considerando variedades

para el dominio en donde se está trabajando mediante la creación de modelos de variabilidad [9]. Estos modelos definen puntos de variabilidad que engloban las variantes posibles en un dominio determinado. Luego, en los activos de *casos de dominio* se instancian las variantes previas mediante la selección de algunas de ellas. Finalmente, cuando se crean casos que reusan variantes de otros casos ya creados, se documentan como *casos reusables*. De esta forma, al seguir cualquiera de los dos enfoques de desarrollo (T-VIP o B-VIP) propuestos, toda la información utilizada se almacena en esta base de conocimiento y podrá ser reusada en nuevos casos dentro del mismo dominio.

Considerando dichos enfoques, en este trabajo se propone la aplicación de un enfoque T-VIP que comenzará desde hipótesis definidas por los usuarios expertos y por los trabajos en la literatura y realizará las actividades necesarias para la verificación de las mismas. En particular, nos centramos en el análisis y predicción de la fluctuación de la napa freática en el Alto Valle de Río Negro y Neuquén. Para realizar este trabajo, se cuenta con la colaboración de personal experto del INTA que nos brindan los datos y sus conocimientos para que se pueda llevar a cabo.

De esta forma, el trabajo tiene como objetivo aplicar el enfoque T-VIP identificando las variedades existentes durante el desarrollo de casos de dominio. Al mismo tiempo, las variedades encontradas deben almacenarse utilizando la herramienta CoVaMat, de manera que puedan reusarse en el desarrollo de otros casos. El resultado de los casos de dominio creados son utilizados por expertos del INTA⁴ de modo de analizarlos para la comprensión y estudio del comportamiento del nivel freático en la región estudiada.

Este trabajo se enmarca en tareas de investigación del proyecto 04/F019 *Modelado de Variedad en Sistemas de Big Data* y se establece confidencialidad con respecto a todo dato que sea utilizado en las pruebas del caso de estudio.

⁴Instituto Nacional de Tecnología Agropecuaria

1.2. Objetivo General

El objetivo general de esta tesis es:

Desarrollar casos de dominio para el análisis y predicción de la fluctuación de la napa freática mediante la aplicación de un enfoque T-VIP que identifique y almacene las variedades encontradas.

1.3. Objetivos Específicos

Del objetivo general se desprenden los siguientes objetivos específicos:

- *O1- Modelar el contexto para el análisis y definir hipótesis:* recolectar información de casos y elaborar una clasificación del contexto de acuerdo a usos, variables y modelos de análisis apropiados para comprender el comportamiento de la napa freática y los factores que la alteran en la zona del Alto Valle de Río Negro y Neuquén. Se deben definir las hipótesis e identificar las variedades.
- *O2-Instanciar el modelo de contexto:* diseñar el modelo de datos necesario para adecuar los datos recolectados al procesamiento requerido por el desarrollo de los casos de dominio, de acuerdo a la clasificación realizada en O1. A su vez se deben modelar las variedades encontradas y crear así los activos de dominio necesarios que deben documentarse en CoVaMat.
- *O3- Verificar las hipótesis:* verificar las hipótesis mediante la instanciación de los activos de dominio creados en O2. Es decir, se deben crear casos de dominio que utilicen el modelo común creado y puedan instanciar variedades de contexto para la creación de nuevos casos. Esto mostrará variaciones en los resultados que deberán analizarse por expertos. Los casos de dominio creados e instanciados deben también documentarse en CoVaMat ya que retroalimentarán la creación de nuevos casos.

1.4. Metodología

Este trabajo se enmarca tanto en revisiones de la bibliografía, como en modelado de dominio para SBD. Asimismo, incluye necesidades específicas del caso de estudio y la instanciación del modelo en dicho caso. Para esto, se prevén reuniones con expertos del dominio (Del INTA Alto-Valle), así como el uso de frameworks de referencia existentes. Para el desarrollo basado en el modelado y documentación de la variedad (Figura 1.1), se aplicará el enfoque T-VIP (que consiste de 5 pasos [16], como podemos observar en la Figura 1.1. El paso (1) comienza con la formulación de hipótesis por parte de un experto en el dominio, basadas en su conocimiento previo, lo que guía el análisis posterior de datos para validar esas suposiciones. Luego, (2) los analistas se sumergen en actividades de big data (3) para analizar los datos. Más tarde, estos resultados son devueltos para validar la hipótesis (4), posiblemente visualizando los resultados de diferentes maneras; y permitir la reformulación de hipótesis o la finalización del proceso, alternativamente (5). Como resultado de este enfoque, se generan casos específicos que encapsulan las variaciones identificadas, los cuales pueden ser reutilizados en instancias futuras, promoviendo así la eficiencia y la consistencia en futuros análisis dentro del mismo dominio. Al mismo tiempo, tanto el modelado de la variedad como los casos deben documentarse en CoVaMat.

De los objetivos planteados, se desprenden las siguientes actividades a ser terminadas en el transcurso de seis meses desde el comienzo de esta tesis:

- A1. Clasificación de elementos del contexto. Para esto se analizará el estado de la práctica (incluso en la Institución del caso de estudio), y las formas en que los expertos y los trabajos

relacionados de la literatura referentes al análisis de la napa freática, en todos sus aspectos. Corresponde al objetivo O1.

- A2. Modelado del contexto. Se modelarán relaciones entre usos, variables, parámetros e indicadores, con los modelos de análisis de napas freáticas y resultados alcanzados, según el estado de la práctica analizado en A1. A su vez se identificarán posibles variedades según la clasificación de la Figura 1.1. Corresponde al objetivo O1.
- A3. Recolección y preparación de datos. Se analizarán los datos de entrada de los casos de dominio, enfocando en aspectos de calidad como completitud, correctitud, etc. A su vez, se modelarán las variedades. Corresponde al objetivo O2.
- A4. Análisis de datos. Se utilizarán técnicas de análisis de estadísticas básicas para comprender las fuentes de datos y sus relaciones. Los datos provienen de estaciones meteorológicas de la región, mediciones del caudal del Río Negro, y de las mediciones de los freatómetros. Al mismo tiempo, se aplicarán técnicas de predicción u otras sugeridas en la instanciación para realizar los análisis para cada uno de los casos de domino desarrollados. Corresponde al objetivo O3.
- A5. Documentación de los casos. Consiste en la documentación del modelo de variedad definido, junto con las variantes encontradas y su posterior instanciación en forma de casos de dominio dentro de la herramienta CoVaMAAt. De esta forma, dicha documentación quedará disponible para la realización de nuevos casos en este contexto y en otros. Corresponde a los objetivos O2 y O3.
- A6. Redacción del Reporte de la Tesis.

1.5. Estructura

La tesis se organiza de la siguiente manera:

- En el Capítulo 2 se presenta una descripción completa de los fundamentos relacionados con los SBD, el dominio de aplicación y los trabajos relacionados en el mismo. También se describen los trabajos previos del grupo de investigación en el cual se enmarca esta tesis.
- En el Capítulo 3 se describe la aplicación del enfoque T-VIP para la construcción y documentación de dos casos en el dominio de agricultura de precisión.
- En el Capítulo 4 se presentan las conclusiones y trabajos futuros destacando las contribuciones y limitaciones de esta tesis.

Capítulo 2

Big Data, Aplicaciones y Trabajos Previos

En este capítulo se describen los conceptos básicos de Big Data incluyendo su ciclo de vida, las actividades involucradas y algunas de las técnicas y herramientas que las soportan. A su vez, como cada sistema de big data trabaja dentro de dominios específicos, describimos en particular el dominio de agricultura de precisión en el cual esta basado nuestro trabajo de tesis. Luego, continuamos con un análisis de varios trabajos relacionados en el dominio y que construyen SBD para analizar las fluctuaciones de la napa freática en diferentes regiones. Por último, se describen los trabajos previos dentro del proyecto de investigación que utilizaremos como base para nuestro trabajo.

2.1. Conceptos de Big Data

El concepto de big data se refiere a la manipulación y análisis de grandes conjuntos de datos involucrando tareas interdisciplinarias que combinan matemáticas, estadística, informática y conocimientos especializados [20]. Los datos en entornos de big data suelen acumularse en las organizaciones a través de aplicaciones, sensores y fuentes externas. Los datos procesados por los SBD pueden ser utilizados directamente por las aplicaciones de la organización o pueden introducirse en un almacén de datos para enriquecer los datos existentes. Los resultados obtenidos mediante el procesamiento de big data pueden dar una amplia gama de conocimientos y beneficios, como por ejemplo: optimización operativa, inteligencia procesable, identificación de nuevos mercados, predicciones precisas, detección de fallos y fraudes, registros más detallados, mejora de la toma de decisiones, descubrimientos científicos, etc. Para que un conjunto de datos sea considerado big data, debe poseer una o más características que requieren ajustes en el diseño de la solución y la arquitectura del entorno analítico. Las seis V's características de todo sistema big data son:

- *Volumen*: se refiere a que la cantidad de datos que se procesan en los SBD son de un volumen significativo y en constante aumento. Esto impone demandas distintivas en el almacenamiento y procesamiento de datos, así como en procesos adicionales de preparación, tratamiento y gestión de datos.
- *Velocidad*: hace referencia a que los datos pueden llegar a generarse muy rápido, y grandes cantidades de información se pueden acumular en muy poco tiempo.
- *Variedad*: se refiere a los múltiples formatos y tipos de datos que ingresan y que deben ser compatibles con las soluciones de big data.

- *Veracidad*: abarca la calidad o fidelidad de los datos. Los datos que ingresan deben ser evaluados en términos de calidad, lo que puede llevar a actividades de procesamiento de datos para resolver datos inválidos y eliminar ruidos.
- *Valor*: se define como la utilidad de los datos para un determinado propósito y esta a su vez relacionado con la fidelidad de los datos. Además, depende del tiempo de procesamiento de datos, ya que los resultados analíticos tienen una vida útil.
- *Variabilidad*: se refiere a que las fuentes de datos pueden cambiar. Por esto, se requieren mecanismos de adaptación para la evolución de los esquemas y a su vez de los datos, cuando nuevos datos deben ser ingresados.

2.2. Ciclo de Vida de Big Data

El ciclo de vida de big data [7] difiere principalmente del análisis de datos tradicional debido a las características particulares de este tipo de sistemas. Para abordar los requerimientos diferentes o no tradicionales, se necesitan metodologías que organicen las actividades y tareas involucradas en la adquisición, procesamiento, análisis y reutilización de datos. En la Figura 2.1 podemos observar el ciclo de vida de big data que involucra seis etapas bien definidas. A continuación describimos cada una de ellas en mas detalle.




Figura 2.1: Ciclo de Vida de Big Data (Extraída de [7])

2.2.1. Evaluación del caso del negocio

Durante esta etapa se crea, evalúa y aprueba un caso de negocio, lo que ayuda a los responsables de tomar decisiones a comprender los recursos necesarios y los desafíos comerciales que el análisis abordará. Además, se identifican indicadores clave de rendimiento para guiar la evaluación de los resultados analíticos. La documentación de los requisitos permite determinar si los problemas son verdaderamente problemas de big data, relacionados con características como

volumen, velocidad y/o variedad. Esta etapa también establece el presupuesto necesario para la realización del proyecto de análisis, considerando compras como herramientas, hardware y capacitación, y destaca la importancia de plantear los objetivos del proyecto *específicos, medibles, alcanzables, relevantes y oportunos (SMART¹)*.

2.2.2. Identificación y recolección de datos

En esta etapa se deben identificar los conjuntos de datos necesarios y sus fuentes. Identificar una mayor variedad de fuentes de datos puede aumentar la probabilidad de encontrar patrones y correlaciones ocultos. Por ejemplo, para proporcionar información valiosa, puede ser beneficioso identificar tantos tipos de fuentes de datos relacionadas como sea posible, especialmente cuando no está claro exactamente qué se desea buscar o encontrar.

Dependiendo del alcance del proyecto de análisis y la naturaleza de los problemas que se abordan, los conjuntos de datos necesarios y sus fuentes pueden ser internos y/o externos a la empresa. En el caso de conjuntos de datos internos, se suele compilar y cotejar una lista de conjuntos de datos disponibles de fuentes internas, como datamarts y sistemas operativos, con una especificación de conjunto de datos predefinida. En el caso de conjuntos de datos externos, se construye una lista de posibles proveedores de datos de terceros, como mercados de datos y/o conjuntos de datos disponibles públicamente. Algunas formas de datos externos pueden estar integradas en blogs u otros tipos de sitios Web basados en contenido, en cuyo caso es posible que deban recolectarse mediante herramientas automatizadas. Existen varios tipos de conectores que pueden utilizarse en el proceso de recopilación de datos, y la elección de uno en particular depende de las necesidades del sistema. Hay algunos factores, como la velocidad de los datos, que influyen a la hora de elegir un conector. Otro ejemplo es el tipo de la fuente de datos y procesamiento de los mismos, ya que influyen en la cantidad y frecuencia de entrega, pudiendo ser entregados en lotes grandes, en pequeños lotes (micro-lotes) o datos en tiempo real.

Existen en la literatura varias técnicas que permiten la recolección de datos en forma organizada [10]. Entre ellas podemos citar:

- *Mensajería Publicar-Suscribir (en inglés Publish-Subscribe)*: comprende editores, intermediarios y consumidores. Los editores son las fuentes de los datos que envían a temas gestionados por el intermediario. Los editores no son conscientes de los consumidores. Los consumidores se suscriben a los temas que son gestionados por el intermediario. Cuando el intermediario recibe datos para un tema de parte de un editor, los envía a todos los consumidores suscritos. Alternativamente, los consumidores pueden extraer datos de temas específicos del intermediario. Ejemplos de marcos de mensajería publicar-suscribir son Apache Kafka² y Amazon Kinesis³.
- *Conectores Fuente-Destino (Source-Sink)*: permiten recopilar, agregar y mover datos de diversas fuentes, como registros de servidores, bases de datos, redes sociales, datos de sensores en streaming de dispositivos y otras fuentes, a un almacén de datos centralizado (como un sistema de archivos distribuido). Un ejemplo de esto es Apache Flume⁴, el cual se presenta como un marco para agregar datos de diferentes fuentes utilizando un modelo de flujo de datos que comprende fuentes, canales y destinos.
- *Conectores de Base de Datos*: se utilizan para importar datos de sistemas de gestión de bases de datos relacionales al almacenamiento destinado para grandes volúmenes de datos y a los frameworks de análisis de datos. Un ejemplo de esto es Apache Sqoop⁵.

¹SMART por sus siglas en inglés correspondientes a *Specific, Measurable, Achievable, Realistic, Time-bound*

²<https://kafka.apache.org/>

³<https://aws.amazon.com/es/pm/kinesis>

⁴<https://flume.apache.org/>

⁵<https://sqoop.apache.org/>

- *Colas de Mensajería*: son útiles para la mensajería productor-consumidor (en inglés push-pull) donde los productores envían datos a las colas y los consumidores los extraen. Los productores y consumidores no necesitan ser conscientes el uno del otro. Ejemplos de colas de mensajería son RabbitMQ⁶, ZeroMQ⁷, RestMQ⁸ y Amazon SQS⁹.
- *Conectores Personalizados*: se pueden desarrollar según la fuente de los datos y los requisitos de recopilación. Algunos ejemplos de conectores personalizados se construyen para recopilar datos de redes sociales, bases de datos NoSQL¹⁰ e Internet de las Cosas (IoT), entre otros. Ejemplos de conectores personalizados incluyen conectores basados en REST¹¹, WebSocket¹² y MQTT¹³.

2.2.3. Preparación de datos

La preparación de datos es una etapa crítica en el ciclo de vida abarcando los procesos de adquisición, extracción, validación, limpieza, agregación y representación de datos. Esta etapa debe garantizar que los datos sean adecuados para análisis posteriores y que se manejen adecuadamente los valores nulos, faltantes y/o atípicos. Según el ciclo de vida, esta etapa contiene cuatro actividades:

1. *Adquisición y filtrado de datos*: implica la recolección de datos relevantes de diversas fuentes. Durante esta actividad, se emplean técnicas de filtrado para eliminar datos irrelevantes o redundantes. El filtrado inicial ayuda a reducir el volumen de datos y enfocar el análisis en la información más pertinente.
2. *Validación y limpieza de datos*: se refiere a las tareas que permitan asegurar que los datos sean precisos, completos y estén libres de errores. Las técnicas comunes incluyen:
 - *Eliminación de valores duplicados*: Dado que los datos pueden venir de múltiples fuentes, es común encontrar duplicados. Identificar y eliminar estos valores evita sesgos en el análisis.
 - *Manejo de valores nulos y faltantes*: Se pueden emplear varias estrategias, como eliminar registros incompletos, imputar valores faltantes usando la media, mediana o moda de la variable, o utilizar técnicas más avanzadas como imputación por algoritmos de aprendizaje automático.
 - *Detección y tratamiento de valores atípicos*: Los valores atípicos pueden identificarse utilizando métodos estadísticos, como desviaciones estándar, o técnicas de aprendizaje automático para la detección de anomalías. Dependiendo del contexto, los valores atípicos pueden eliminarse o investigarse más a fondo, ya que los datos que parecen no ser válidos aún pueden ser valiosos porque pueden contener patrones y tendencias ocultas.
3. *Transformación de datos*: se refiere a la adecuación de datos específicos de fuentes no estructuradas o semiestructuradas, como documentos de texto, XML o JSON. Dependiendo del tipo de dato y del sistema de big data a ser construido, puede ser necesario transformar los datos extraídos en un formato estructurado adecuado para el análisis. Por ejemplo,

⁶<https://www.rabbitmq.com/>

⁷<https://zeromq.org/>

⁸<http://restmq.com/>

⁹<https://aws.amazon.com/es/sqs/>

¹⁰<https://aws.amazon.com/es/nosql/>

¹¹<https://www.ibm.com/es-es/topics/rest-apis>

¹²<https://www.ibm.com/docs/es/was/9.0.5?topic=applications-websocket>

¹³<https://aws.amazon.com/es/what-is/mqtt/>

extraer campos específicos de registros de servidores Web o documentos de texto para análisis textuales.

4. *Agregación y representación de datos*: implica combinar datos de diferentes fuentes para proporcionar una vista unificada. Esto puede requerir la reconciliación de diferencias en la estructura de los datos o en la semántica de los mismos, como alinear diferentes terminologías para campos similares (“dirección” vs. “domicilio”). Las técnicas pueden incluir:
 - *Unión de datos*: Combinar conjuntos de datos mediante campos comunes como identificadores únicos o fechas.
 - *Normalización de datos*: Ajustar los datos a un formato o escala común para permitir comparaciones significativas.

Técnicas para la preparación de los datos

Existe un amplio abanico de técnicas para esta etapa, como la eliminación de datos, la imputación estadística, la interpolación y la imputación basada en modelos. La forma en que se manejan los valores faltantes puede influir significativamente en la calidad de los resultados obtenidos, por lo que es fundamental elegir el enfoque adecuado según el contexto del análisis.

En este trabajo de tesis, utilizamos dos técnicas para el tratamiento de valores nulos y atípicos, que responden a la imputación basada en modelos:

- *KNNImputer*¹⁴ permite completar valores faltantes utilizando el método de k-vecinos más cercanos (KNN¹⁵). Para cada dato ausente, se buscan los n vecinos más cercanos que poseen un valor en la misma característica. Luego, el valor faltante se reemplaza con el promedio de esos vecinos, ya sea de manera uniforme o ponderando según la distancia. A su vez, si una muestra tiene más de un valor faltante, los vecinos pueden variar según la característica a imputar. En caso de no haber suficientes vecinos disponibles, se usa el promedio de la columna en el conjunto de entrenamiento. Si al menos un vecino tiene una distancia válida, se emplea su promedio (ponderado o no) para la imputación. Además, si una característica está completamente vacía en el conjunto de entrenamiento, se elimina antes de aplicar la transformación.
- *IterativeImputer*¹⁶ utiliza un enfoque iterativo para estimar los valores faltantes. Modela cada columna con datos perdidos en función de las demás columnas y aplica un proceso repetitivo para refinar la imputación. El procedimiento consiste en seleccionar una columna con valores faltantes y tratarla como la variable a predecir, mientras que las demás columnas actúan como datos de entrada para entrenar un modelo de regresión. Este modelo aprende de los valores conocidos y predice los valores ausentes en la columna seleccionada. El proceso se aplica a todas las columnas con datos faltantes y se repite varias veces para mejorar la precisión de la imputación. Finalmente, los valores obtenidos en la última iteración se utilizan en el conjunto de datos definitivo.

Para validar los resultados obtenidos por las técnicas anteriores se utilizan las siguientes métricas:

- MAE (Error medio absoluto¹⁷) [21]: es una métrica que cuantifica el promedio de las diferencias absolutas entre las predicciones del modelo y los valores reales observados. En otras palabras, es el promedio de los errores que comete el modelo al hacer predicciones.

¹⁴<https://scikit-learn.org/stable/>

¹⁵por sus siglas en inglés, k-nearest neighbors

¹⁶<https://scikit-learn.org/stable/>

¹⁷por sus siglas en inglés, Mean Absolute Error

Se expresa en las mismas unidades que la variable que se predice. El MAE toma valores entre 0 e ∞ . Si su valor es 0 indica que las predicciones del modelo coinciden con los valores reales, mientras que valores más altos reflejan una menor precisión en las predicciones.

- R^2 (coeficiente de determinación¹⁸) [22]: el coeficiente de determinación, indica la proporción de la variabilidad de la variable dependiente que es explicada por el modelo. Mide cuánto explica el modelo de los datos. Su valor oscila entre 0 y 1, donde valores más cercanos a 1 indican un mejor ajuste del modelo. Por ejemplo, si R^2 es 0.8, el modelo explica el 80 % de la variación de los datos.

2.2.4. Análisis de datos

Esta etapa se centra en realizar la analítica en sí misma y puede involucrar diferentes tipos de análisis. Puede ser iterativa, especialmente en un análisis exploratorio, donde se repite hasta encontrar un patrón o correlación adecuado. Dependiendo del resultado analítico deseado, puede ser tan simple como consultar datos o tan desafiante como combinar minería de datos, inteligencia y análisis estadísticos complejos. Existen dos enfoques de análisis: *exploratorio* y *confirmatorio*. El primero busca comprender la causa de un fenómeno. Aunque puede que no proporcione respuestas definitivas, este método proporciona una dirección general que puede facilitar el descubrimiento de patrones o anomalías. Por otro lado, el análisis *confirmatorio* busca respuestas definitivas a preguntas específicas a través de hipótesis preexistentes. En resumen, ambos tipos de análisis implican explorar y entender los datos para descubrir patrones, ya sea siguiendo o no una hipótesis.

Existen cuatro tipos de categorías para la analítica de datos que dependen de los resultados que producen [23]:

- *Descriptiva*: Responde a la pregunta ¿Qué sucedió?. El análisis descriptivo se lleva a cabo para responder preguntas sobre eventos que ya han ocurrido. Esta forma de análisis contextualiza los datos para generar información.
- *Diagnóstica*: Responde a la pregunta ¿Por qué sucedió?. El análisis diagnóstico tiene como objetivo determinar la causa de un fenómeno que ocurrió en el pasado mediante preguntas que se centran en la razón detrás del evento. El objetivo de este tipo de análisis es determinar qué información está relacionada con el fenómeno para poder responder preguntas que buscan descubrir por qué ocurrió algo.
- *Predictiva*: Responde a la pregunta ¿Qué es posible que suceda?. El análisis predictivo se lleva a cabo en un intento por determinar el resultado de un evento que podría ocurrir en el futuro. Con este análisis, la información se enriquece con significado para generar conocimiento que expresa cómo esa información está relacionada. La fuerza y magnitud de las asociaciones forman la base de modelos que se utilizan para generar predicciones futuras basadas en eventos pasados.
- *Prescriptiva*: Responde a la pregunta ¿Qué podemos hacer para que algo suceda?. El análisis prescriptivo se basa en los resultados del análisis predictivo al prescribir acciones que deberían llevarse a cabo. El enfoque no solo se centra en cuál opción prescrita es la mejor a seguir, sino también en el por qué. En otras palabras, este análisis proporciona resultados que pueden ser razonados porque incorporan elementos de comprensión situacional. Por lo tanto, se puede utilizar para obtener una ventaja o mitigar un riesgo.

En general un proceso de análisis de datos puede realizarse siguiendo dos tipos diferentes de aprendizaje:

¹⁸por sus siglas en inglés, Coefficient of Determination

- *Aprendizaje supervisado*: el modelo se entrena utilizando un conjunto de datos etiquetados. Esto significa que cada entrada de datos viene con una etiqueta de salida correspondiente. El objetivo es que el modelo aprenda a predecir la salida correcta a partir de las entradas dadas. Las técnicas de aprendizaje supervisado incluyen:
 - *Regresión lineal*: predice un valor numérico continuo basado en una o más variables independientes.
 - *Árboles de decisión*: utilizan un conjunto de reglas derivadas de los datos para tomar decisiones basadas en el valor de las variables de entrada.
 - *Máquinas de Soporte Vectorial (SVM¹⁹)*: utilizadas para clasificación y regresión, buscan el hiperplano que mejor separa las diferentes clases en los datos.
 - *Redes neuronales*: simulan el funcionamiento del cerebro humano para encontrar patrones en datos complejos.
- *Aprendizaje no supervisado*: se utiliza cuando los datos no están etiquetados y el objetivo es encontrar estructuras o patrones ocultos en los mismos. Las técnicas de aprendizaje no supervisado incluyen:
 - *Clustering*: agrupa los datos en clusters o grupos que son similares entre sí pero diferentes de otros grupos. Los métodos populares incluyen k-means y el clustering jerárquico.
 - *Análisis de Componentes Principales (PCA²⁰)*: reduce la dimensionalidad de los datos para facilitar el análisis y la visualización, manteniendo la mayor parte de la variabilidad en los datos.
 - *Redes Neuronales Autoasociativas*: son redes neuronales utilizadas para aprender una representación comprimida de los datos.

Técnicas para el análisis de datos

El análisis de datos puede abordarse mediante diversos enfoques, que van desde métodos estadísticos tradicionales hasta técnicas avanzadas de aprendizaje automático. La elección de uno u otro depende del objetivo específico y del tipo de variable con el que se trabaja, ya sea para describir el comportamiento de los datos o para predecir resultados futuros. Para análisis descriptivos, es habitual el uso de coeficientes de correlación, especialmente útiles cuando se dispone de variables numéricas. En cambio, en análisis predictivos o diagnósticos, se suele recurrir a un conjunto distinto de enfoques, como las redes neuronales, las cuales pueden implementarse en múltiples variantes: redes neuronales artificiales (ANN²¹), redes neuronales convolucionales (CNN²²) y redes neuronales recurrentes (RNN²³), entre otras [14].

Correlaciones

Las correlaciones más utilizadas en el tipo de análisis de datos descriptivo son las técnicas de Pearson, Spearman y Kendall [24]. Las mismas sirven para medir la correlación entre distintas variables y ayudan a entender como se relacionan. Las diferencias entre ellas son:

¹⁹por sus siglas en inglés, Support Vector Machines

²⁰por sus siglas en inglés, Principal Component Analysis

²¹por sus siglas en inglés, Artificial Neural Network

²²por sus siglas en inglés, Convolutional Neural Networks

²³por sus siglas en inglés, Recurrent Neural Network

- **Correlación de Pearson:** mide la relación lineal entre dos variables continuas, considerando tanto la intensidad como la dirección de la asociación. Es especialmente útil cuando se analiza la dependencia entre variables con distribución normal. Por ejemplo, se puede aplicar para evaluar la correlación entre la temperatura ambiente y el consumo de energía en un edificio.
- **Correlación de Spearman:** evalúa la correlación monótona, es decir, si cuando una variable aumenta, la otra tiende a aumentar o disminuir. Se utiliza para medir la correlación entre dos variables clasificadas, por ejemplo, rango de la calificación de un hotel frente al rango de edad de los que califican.
- **Correlación de Kendall:** evalúa la correlación de orden, es decir, se basa en la concordancia de los rangos entre las observaciones de dos variables. Por ejemplo, se puede aplicar para evaluar la correlación entre las clasificaciones de dos jueces en una competencia. Si los jueces clasifican a los participantes de manera similar, habrá una alta correlación de Kendall, indicando que sus evaluaciones están alineadas.

Redes Neuronales

Una red neuronal es un programa, o modelo de aprendizaje automático que toma decisiones de forma similar al cerebro humano, utilizando procesos que imitan la forma en que las neuronas biológicas trabajan juntas para identificar fenómenos, considerar opciones y llegar a conclusiones [14]. Estas redes están compuestas por capas formadas por unidades llamadas nodos o neuronas artificiales. Cada nodo recibe valores de entrada, los combina mediante una operación matemática (una suma ponderada con pesos) y transforma el resultado aplicando una función de activación. Esta salida se transmite luego como entrada a los nodos de la siguiente capa. En este sentido, una capa es un conjunto de nodos que operan en paralelo y que juntos procesan la información de manera progresiva a lo largo de la red. Las redes neuronales permiten realizar tareas como reconocimiento de imágenes y videos, procesamiento de lenguaje natural, predicción y análisis de datos, automatización y robótica, entre otras. Existen una gran variedad de ellas, por ejemplo monocapa, multicapa, convolucional, recurrentes, etc.

En este trabajo de tesis, utilizamos un tipo de red neuronal artificial diseñada para procesar datos secuenciales, como texto, audio o series de tiempo. La misma, *Red Neuronal Recurrente (RNN)* [25], tiene como principal ventaja una *memoria interna*, gracias a bucles en sus conexiones, que les permite recordar información de pasos anteriores. Esto las hace útiles para tareas donde el contexto o el orden de los datos importa, como traducir una frase o predecir el siguiente valor en una secuencia. Su estructura básica incluye tres componentes: *capa de entrada*, que recibe los datos, como una palabra, *capa oculta* que procesa la información combinando la entrada actual con lo aprendido en pasos previos, y *capa de salida* que genera el resultado, como una predicción. La clave está en la capa oculta, que utiliza bucles para mantener un flujo de información constante entre los pasos de la secuencia. En cada paso, por ejemplo, al analizar una palabra en una frase, la RNN toma la entrada actual y la mezcla con la información guardada de pasos anteriores. Esto se logra mediante pesos ajustables, que determinan cuánta importancia dar a la nueva entrada y cuánta a la memoria pasada. Durante el entrenamiento, estos pesos se ajustan automáticamente para minimizar errores, usando el método llamado *propagación hacia atrás en el tiempo*²⁴, que corrige no solo el error actual, sino también los de pasos previos. Por ejemplo, si una RNN lee la frase “El cielo está...”, analiza cada palabra en orden. Al llegar a “está”, recuerda que “cielo” suele asociarse con “azul” ó “nublado”, lo que le ayuda a predecir mejor la siguiente palabra.

A su vez, las RNN manejan secuencias de longitud variable (como frases de distintas palabras) y capturan dependencias temporales. Sin embargo, las RNN básicas tienen una limitación: les cuesta recordar información de pasos muy antiguos en secuencias largas. Para solucionarlo,

²⁴backpropagation through time

se usan variantes más avanzadas como memoria a largo y corto plazo (LSTM²⁵) o unidades recurrentes con puertas (GRU²⁶), que tienen mecanismos específicos para gestionar la memoria a largo plazo.

En este trabajo utilizamos el tipo LSTM la cual esta diseñada para manejar conjuntos de datos de series temporales, gracias a su capacidad de recordar dependencias de largo plazo. Las LSTM se componen de un *celda de memoria* y *tres puertas*. La función principal de la celda de memoria es almacenar información relevante a largo plazo, lo que permite a la red recordar elementos clave del pasado; por ejemplo, el género de un sujeto en una oración o patrones repetitivos en registros climáticos históricos. Las puertas son mecanismos que regulan cómo la información entra, sale o se elimina de la celda de memoria. Las tres puertas son: la *puerta de olvido* que evalúa si se debe retener o descartar la información del paso anterior; la *puerta de entrada* que determina la relevancia de la entrada actual, influyendo en el grado en que esta se incorpora al estado de la celda; y la *puerta de salida* que decide el siguiente estado considerando tanto el estado de la celda actualizada, como la entrada actual.

Para construir el modelo LSTM, es fundamental definir sus hiperparámetros y optimizadores, los cuales alguno de ellos son:

- *Tamaño del lote*: hace referencia a la cantidad de registros que el modelo procesa de manera simultánea. En lugar de utilizar todo el conjunto de entrenamiento, los datos se dividen en subconjuntos llamados lotes, donde el tamaño define cuantos registros se consideran en cada paso del entrenamiento. El tamaño del lote afecta el rendimiento y la calidad del modelo, lotes pequeños aprenden lento pero se ajustan mejor a casos específicos, mientras que lotes grandes aprenden rápido pero pueden pasar por alto detalles.
- *Número de épocas*: una época equivale a un ciclo completo en el que todos los registros disponibles han sido utilizados una vez para entrenar la red. Por ejemplo, si se dispone de 1.000 registros y se entrena durante 10 épocas, el modelo verá cada uno de esos registros 10 veces a lo largo del proceso de entrenamiento, ajustando sus parámetros en cada repetición. El número de épocas afecta el aprendizaje del modelo: muy pocas pueden causar subajuste, lo que genera predicciones imprecisas; demasiadas pueden provocar sobreajuste, reduciendo la capacidad del modelo para generalizar nuevos datos.
- *Tasa de aprendizaje*: es la proporción de los pesos que se actualizan durante el entrenamiento del modelo. Puede elegirse en el rango $[0,0-1,0]$, aunque en la práctica los modelos suelen utilizar tasas de aprendizaje entre $[0,0001$ y $0,1]$. Tasas de aprendizaje cercanas a 0.0001 hacen que el proceso de entrenamiento sea muy lento y puede hacer que el modelo quede atrapado en mínimos locales. Por el contrario, una tasa superior a 0.1 puede hacer que el modelo pierda precisión. La tasa de aprendizaje de 0.01 es considerada un intermedio dentro del rango comúnmente utilizada en la práctica, ya que permite un equilibrio entre velocidad de aprendizaje y estabilidad.
- *Tasa de abandono*²⁷: es una técnica de regularización en la que las neuronas seleccionadas al azar se ignoran durante el entrenamiento con el objetivo de evitar un sobreajuste. Consiste en “apagar” aleatoriamente un porcentaje de neuronas durante el entrenamiento, obligando a la red a aprender patrones más robustos y a no depender excesivamente de neuronas específicas. El valor del abandono se define como una proporción entre 0 y 1, indicando el porcentaje de neuronas que se “apagan”. Por ejemplo, un valor de 0.3 implica que el 30 % de las neuronas se desactivan aleatoriamente en cada paso de entrenamiento.
- *Función de activación*: convierte una señal de entrada de un nodo de una red neuronal en una señal de salida, que luego se utiliza como entrada de la siguiente capa oculta, y así

²⁵por sus siglas en inglés, Long Short-Term Memory

²⁶por sus siglas en inglés, Gated Recurrent Units

²⁷en ingles Dropout

sucesivamente. Para encontrar la salida de una capa, se calcula la suma de los productos de las entradas y sus pesos correspondientes, se aplica la función de activación a esa suma y luego se alimenta esa salida como entrada a la siguiente capa. Existen distintas funciones de activación. Algunos ejemplos comunes son: tanh, relu, linear, silu, entre otras.

- *Optimizadores*: son responsables de actualizar los pesos durante el entrenamiento. Es decir, son algoritmos que ayudan a encontrar el conjunto óptimo de pesos que minimiza la función de pérdida. Esta función mide la diferencia entre los valores predichos y reales de la variable objetivo. El objetivo final de la optimización es reducir la pérdida de un modelo de red neuronal determinado. Algunos ejemplos comunes son: SGD, RMSprop, Adam, AdamW, Adadelta, Adagrad, entre otros.
- *Detención temprana*: es una técnica de regularización utilizada en el entrenamiento de modelos de aprendizaje automático para prevenir el sobreajuste. Consiste en monitorear el rendimiento del modelo en un conjunto de datos de validación durante el proceso de entrenamiento y detener dicho entrenamiento cuando el rendimiento en este conjunto deja de mejorar. De esta manera, se evita que el modelo se ajuste demasiado a los datos de entrenamiento, lo que podría perjudicar su capacidad de generalización a datos nuevos.

Para validar los resultados obtenidos de las predicciones de las redes neuronales, se utilizan las métricas MAE y R^2 descritas previamente y las siguientes [26, 27]:

- Error Cuadrático Medio (MSE^{28}) : es el promedio de los errores al cuadrado entre predicciones y valores reales. El resultado de esta métrica oscila entre 0 e ∞ . Un valor cercano a 0 indica que el modelo realiza predicciones precisas. Como eleva al cuadrado las diferencias, penaliza más fuertemente los errores grandes.
- Raíz del Error Cuadrático Medio ($RMSE^{29}$): es la raíz cuadrada del MSE. También oscila entre 0 e ∞ , pero se expresa en las mismas unidades que la variable predicha, lo que facilita su interpretación práctica. Al igual que el MSE, un valor bajo indica que las predicciones del modelo se aproximan a los valores reales.
- Validación cruzada³⁰: evalúa la generalización de un modelo predictivo, es decir, divide el conjunto de datos en k subconjuntos (folds), entrenando el modelo en $k - 1$ folds y validándolo en el fold restante. Este proceso se repite k veces, promediando los resultados para estimar el rendimiento. El resultado es el promedio de una métrica de evaluación (como MAE, RMSE o R^2) calculada sobre los distintos folds.

2.2.5. Modos de análisis

Una vez definido el tipo de análisis a realizar, se debe determinar el modo de procesarlo [10]. La elección de este modo va a depender de los requerimientos de la aplicación. Es decir, si la aplicación demanda resultados actualizados cada cortos intervalos de tiempo (pocos segundos), si los intervalos de tiempo son muy largos (días o meses), o si se necesita interacción de los usuarios. De esta forma, los tres modos disponibles son:

- *Por lotes*: los datos se procesan sin conexión y el tiempo de respuesta puede variar de minutos a horas. Además, los datos deben almacenarse en algún repositorio previo a ser procesados. Este modo implica generalmente procesar un rango de conjuntos de datos grandes, ya sea por sí mismos o unidos, abordando esencialmente las características de volumen y variedad de los conjuntos de datos. La mayor parte del procesamiento de big

²⁸por sus siglas en ingles, Mean Squared Error

²⁹por sus siglas en ingles, Root Mean Squared Error

³⁰en ingles Cross-Validation

data ocurre en modo por lotes. Es relativamente simple, fácil de configurar y de bajo costo en comparación con el modo en tiempo real.

- *Tiempo real*: los datos se procesan en memoria a medida que se capturan, antes de almacenarse en el disco. El tiempo de respuesta generalmente varía desde fracciones de segundo hasta menos de un minuto. Este modo aborda la característica de velocidad de los conjuntos de datos de big data. El procesamiento en tiempo real también se denomina procesamiento de eventos o flujos, ya que los datos llegan de forma continua (flujo) o por intervalos (evento). El dato individual del evento/flujo suele ser de tamaño pequeño, pero su naturaleza continua da como resultado conjuntos de datos muy grandes.
- *Interactivo*: permiten a los usuarios consultar datos bajo demanda tanto en tiempo real como en lotes, escribiendo declaraciones en lenguajes similares a SQL. Los usuarios esperan poder actualizar un criterio y obtener gráficos actualizados, incluso si la creación de este análisis implica procesar grandes cantidades de datos.

2.2.6. Visualización y utilización de los resultados

Por último, esta etapa se centra en utilizar técnicas gráficas para comunicar de manera efectiva los resultados del análisis a los usuarios. Esto es crucial para que los usuarios comprendan y valoren los resultados obtenidos. Los mismos pueden generar modelos que mejoran la lógica de procesos empresariales, optimizan sistemas y procesos, y generan alertas. Esta etapa asegura que los análisis sean comprensibles, aprovechables y aplicables para la toma de decisiones y la mejora continua de las operaciones de las organizaciones. La elección de las herramientas de visualización, servidores de bases de datos y marcos de trabajo Web dependen de los requisitos de la aplicación. Las visualizaciones pueden ser:

- *Estáticas*: Se utilizan cuando los resultados del análisis se almacenan en una base de datos y simplemente se quieren mostrar. En este caso, la visualización actúa como una presentación final de los resultados.
- *Dinámicas*: Son necesarias cuando se requiere que los resultados se actualicen con regularidad. Éstas son útiles para mostrar tendencias o cambios en tiempo real.
- *Interactivas*: Se utilizan cuando es necesario que se acepten entradas del usuario y se muestren los resultados en función de ellas. Permiten a los usuarios explorar los datos de forma más profunda y descubrir patrones o tendencias que podrían no ser evidentes en una visualización estática o dinámica.

2.3. Dominio de Agricultura de Precisión

La agricultura mundial viene enfrentado, a lo largo del tiempo, el desafío constante de aumentar la producción en respuesta a la creciente demanda de la población [28]. Este aumento, a su vez, se ha producido de dos formas principales, la primera con la expansión de nuevas áreas agrícolas, luego la segunda, dentro de cada área, con el aumento de los rendimientos. Este último se obtuvo mediante la generación de nuevas tecnologías bajo la forma de semillas mejoradas, insumos modernos y agroquímicos más eficientes. Esto, junto al manejo adecuado de nuevas máquinas agrícolas para preparar, sembrar, cultivar, cosechar y procesar los productos agrícolas, permitió avances significativos en el área de producción de alimentos. Sin embargo, con la modernización de las prácticas agrícolas, surgen nuevos desafíos, principalmente respecto al concepto de sustentabilidad ambiental y económica del proceso de producción. En este contexto, la respuesta de la investigación, extensión e innovación de los segmentos relacionados al área agrícola para

enfrentar esos nuevos desafíos, ha sido la generación de tecnologías que permitan desarrollar técnicas que cuantifiquen y manejen diferenciadamente la variabilidad natural del área productora. Para ello, a partir de la década del '70, se comenzó a delinear un nuevo concepto de agricultura con los estudios sobre automatización de máquinas agrícolas. En forma complementaria, a fines de la década del '80 y comienzos del '90, con la liberación del sistema de posicionamiento global por satélite (GPS) para uso civil, fue posible desarrollar equipos inteligentes que permitieron el manejo localizado de las prácticas agrícolas, con una mayor eficiencia de aplicación de insumos, reduciendo el impacto sobre el medio ambiente y en consecuencia, disminuyendo los costos de la producción de alimentos. A ese conjunto de procesos y sistemas aplicados se los denomina *Agricultura de Precisión*³¹.

La agricultura de precisión es un conjunto de técnicas orientadas a optimizar el uso de los insumos (semillas, agroquímicos y correctivos) en función de la cuantificación de la variabilidad espacial y temporal de la producción agrícola. Esta optimización se logra con la distribución de la cantidad correcta de esos insumos, dependiendo del potencial y de la necesidad de cada punto de las áreas abarcadas. La agricultura de precisión no consiste solamente en medir la variabilidad existente en el área, sino también en la adopción de prácticas administrativas que se realizan en función de esa variabilidad. Esta agricultura se beneficia principalmente del surgimiento y la convergencia de varias tecnologías, incluido el GPS, e incorpora el componente de interfaz de software informático de la base de datos, el mapeo, la interpretación con Sistemas de Información Geográficos (GIS) y sistemas de análisis de información de alto nivel (redes neuronales, celulares autómatas, agentes, etc.), sensores electrónicos y controladores, entre otros, con los cuales los agricultores pueden crear un plano muy detallado de su operación agrícola.

Dentro del contexto de la agricultura de precisión, el estudio del nivel freático es importante ya que influye significativamente en la productividad y la gestión eficiente del agua en los cultivos. Para comprender la importancia del nivel freático, es importante definir el concepto de acuífero³². Un acuífero es una formación subterránea que funciona como una gran esponja natural. Está compuesto por capas de materiales como roca, arena o grava, que tienen la capacidad de almacenar y permitir el paso del agua a través de sus poros. Gracias a esta característica, el agua puede infiltrarse desde la superficie y circular lentamente por el subsuelo. El nivel freático [8] es una capa de agua dentro del acuífero que está bajo tierra, justo debajo de la superficie del suelo y puede variar en profundidad según el lugar. Por encima de esta capa, hay otra área llamada zona de saturación, donde el suelo está empapado de agua. El agua en movimiento a través del suelo se llama agua gravitacional, y generalmente se encuentra en la zona saturada. Por encima de la zona de saturación, está la zona de aireación, donde algunos poros del suelo contienen aire. La cercanía del nivel freático a la superficie del suelo, a veces menos de un metro, puede causar que el suelo esté muy húmedo generando un problema para los cultivos (anoxia de raíces, mortandad de plantas, reducción de rendimiento, entre otros).

³¹<https://agrovoc.fao.org/browse/agrovoc/en/>

³²<https://www.usgs.gov/special-topics/water-science-school/science/aquifers-and-groundwater>




Figura 2.2: Dibujo de un Freatímetro con cada una de sus partes (extraída de [8])

Para medir el nivel de la napa freática, se utilizan dispositivos llamados freatímetros (Figura 2.2). Estos son pozos permanentes donde se mide, cada cierta cantidad de tiempo, la profundidad del agua en relación con la superficie del suelo. También se hacen perforaciones temporales para medir el nivel y la calidad del agua en lugares específicos y momentos críticos. Es importante ubicar los freatímetros en lugares representativos del entorno, al menos a 150 metros de características que puedan influir, como cunetas, árboles, corrales, entre otros. Además, se recomienda que los freatímetros alcancen una profundidad de 3,7 metros, aunque para pasturas se sugiere llegar a 6 metros. Una vez instalados, se espera que los niveles se estabilicen, lo cual puede tardar desde unas horas hasta un día, dependiendo del tipo de suelo. Luego, se comienza a medir la profundidad del agua utilizando una cinta métrica con un objeto plano en la punta para detectar el contacto con el agua.

La aplicación de las técnicas y herramientas de la agricultura de precisión a estudios sobre el nivel freático ofrece una gran oportunidad para mejorar la eficiencia y la rentabilidad en la producción agrícola. La capacidad de monitorear y cuantificar la profundidad del agua subterránea permite tomar decisiones informadas sobre el manejo de los cultivos, especialmente en lo que respecta a la programación de riegos y la selección de cultivos adaptados a las condiciones hidrológicas específicas de cada zona.

2.4. Trabajos Relacionados

En la literatura existen varios trabajos dentro del dominio de la agricultura de precisión que realizan diferentes análisis sobre las cuencas y los niveles freáticos. A continuación describimos algunos de ellos.

2.4.1. Trabajo presentado por Lallahem et al. [1]

En este trabajo, los autores plantearon que la simulación del nivel de agua subterránea utilizando modelos matemáticos en un medio calcáreo era un tema complicado en hidrogeología debido a la complejidad de los procesos físicos involucrados, la variabilidad de los freatímetros en el espacio y el tiempo, y la respuesta del acuífero en un ambiente fisurado y matricial en bloques. Debido a esta complejidad surgió la necesidad de buscar otros métodos mas eficientes para evaluar el nivel de agua subterránea en acuíferos de estas características. En esta investigación se propuso entonces utilizar un modelo ANN para tal fin.

Este estudio se llevó a cabo en la cuenca del norte de París, Francia. La región tiene un clima oceánico con una temperatura promedio de 10°C y una precipitación anual entre 700 y 1000 mm. El suelo estaba compuesto por suelos calcáreos de las etapas Senoniense y Turonian.

Se identificaron dos familias de fallas WNW-ESE³³ y NNE-SSW³⁴. La familia mayor, WNW-ESE, tenía fallas regionales importantes con un buzamiento hacia el sur. La familia menor, NNE-SSW, tenía fallas más locales que afectaban la dirección general de la familia mayor. Estas características geológicas y estructurales son relevantes para comprender la hidrología de la región y el comportamiento de las aguas subterráneas. En la Figura 2.3 se observa la ubicación geográfica del área de estudio de este estudio y los distintos tipos de suelo que componen esta cuenca.

En este estudio, se utilizaron datos recopilados durante 11 años, desde enero de 1988 hasta marzo de 1999, con un intervalo de tiempo de 1 mes. Los datos incluyeron información observada en 13 frentímetros, así como datos de precipitación, temperatura, precipitación efectiva y evapotranspiración potencial en dos estaciones meteorológicas ubicadas en el área de la cuenca de estudio.




Figura 2.3: Mapa de ubicación de la zona de estudio en Francia (extraída de [1])

Al mismo tiempo, se establecieron tres objetivos principales. El primero consistió en determinar los parámetros más influyentes que impactaban en el nivel de agua subterránea en medios calcáreos fisurados. El segundo objetivo fue investigar el efecto de la información temporal y espacial considerando conjuntos de datos actuales y pasados junto con el uso de una variedad de lecturas de frentímetros. Por último, el tercero fue simular el nivel de agua subterránea en un frentímetro seleccionado. Para lograr los dos primeros objetivos, los autores eligieron un frentímetro con una ubicación única, en el centro del área de estudio y cerca de otros frentímetros. Buscaron características generales que pudiesen aplicarse a otros frentímetros, dejando fuera aquellos ubicados en los extremos de la cuenca o alejados de los demás. Evaluaron el modelo incluyendo información sobre lluvia, temperatura y evaporación, así como datos de otros frentímetros. Durante todo el proceso, fueron observando la superposición de los gráficos de entrenamiento y

³³Noroeste y se dirige hacia el sureste

³⁴Noreste y se dirige hacia el suroeste

validación, los gráficos de prueba y la métrica RMSE. También agregaron más información para ajustar los parámetros geológicos e hidrogeológicos, como la distancia entre los freáticos y su salida, el espesor del medio no saturado y los bloques limitados por fallas. Como resultado se seleccionaron los parámetros con menor RMSE según lo observado en la superposición de los gráficos. Luego, agruparon los freáticos en tres grupos según su ubicación en la cuenca, su geología y su hidrogeología. De estos grupos, se seleccionaron dos freáticos que capturaban el mismo acuífero y encontraron que tenían un comportamiento similar bajo lluvia efectiva, considerando los datos históricos con diferentes niveles debido a la profundidad del freático y el espesor del medio no saturado. Estos resultados confirmaron a los investigadores que los freáticos en el mismo compartimento tenían niveles de agua subterránea comparables. Por lo tanto, concluyeron que esta condición debería ser considerada al determinar los parámetros de entrada más influyentes en el nivel del agua subterránea. Para cumplir con el tercer objetivo buscaron un límite óptimo de información temporal-espacial y parámetros. Como detectaron que el retraso óptimo podía variar en diferentes estudios y contextos, su determinación se basó en la experiencia y conocimiento de los investigadores, así como en las características específicas del sistema hidrológico en estudio. Mediante un proceso iterativo, probaron diferentes valores de retraso y evaluaron su desempeño en términos nuevamente de la superposición de gráficos de validación y entrenamiento, así como el valor de RMSE, obteniendo en este estudio un límite óptimo de 3 días.

Como conclusión los investigadores determinaron que en este estudio existe una complejidad óptima para las redes neuronales, que depende del número de nodos ocultos y el retraso de la red. En general, observaron un mejor rendimiento de las redes con menor retraso y número de nodos ocultos. Los investigadores plantearon que la selección adecuada de los parámetros espaciales, temporales, geológicos e hidrogeológicos es un desafío, ya que es necesario lograr la convergencia del modelo y obtener resultados de simulación satisfactorios. Sin embargo, a pesar de esta dificultad, sostienen que el enfoque de redes neuronales tuvo una capacidad superior para simular este proceso dinámico en este estudio. En ausencia de conocimiento previo, concluyeron que el modelo basado en redes neuronales desarrollado para este estudio puede simular los resultados deseados con un alto grado de precisión.

2.4.2. Trabajo presentado por Stricevic et al. [2]

En este trabajo se propusieron dos modelos paramétricos para predecir el nivel del agua subterránea en una región agrícola con el objetivo de encontrar el más eficiente. Los investigadores plantearon que también los modelos físicos eran muy utilizados para realizar modelos de aguas subterráneas, pero presentaban una desventaja: para funcionar correctamente era necesario tener información muy detallada sobre los parámetros hidrológicos e hidrogeológicos y cómo interactuaban entre sí. Así, a diferencia de los modelos físicos, los modelos paramétricos se basaban en la observación y el análisis de datos existentes para construir un modelo que pudiera predecir cómo fluía el agua de las napas. Por ejemplo, si se disponía de datos sobre la cantidad de agua subterránea en un pozo a lo largo del tiempo, se podían utilizar técnicas matemáticas y estadísticas para desarrollar un modelo que pudiera predecir el flujo de agua subterránea. Según los investigadores, los modelos paramétricos se podían construir de manera rápida y sencilla y no requerían datos sobre las condiciones iniciales, de contorno y de las características del acuífero; pero podían ser más susceptibles a errores si los datos utilizados para construir el modelo no eran precisos o representativos de la zona de estudio.

Con esto en mente, la investigación se enfocó en un área específica entre Kovin y Dubovac en Serbia, dentro de la llanura aluvial del Danubio a lo largo de 25 km. Como esta región agrícola se encontraba afectada por sistemas hidroeléctricos, los investigadores destacaron la importancia de realizar pronósticos confiables del nivel freático para garantizar la operación adecuada de las instalaciones de drenaje y el mantenimiento de los niveles de agua subterránea necesarios para la producción.

Para esta investigación se seleccionaron pozos ubicados en tres partes separadas: (1) cerca del Danubio, a una distancia de 350 m; (2) en la parte central, a una distancia de 4080 m; y (3) en la llanura aluvial protegida pero más alejada del Danubio, a una distancia de 4850 m. También se representaron tres líneas de drenaje: (1) más cercanas al terraplén a lo largo del Danubio, donde el nivel tenía el mayor efecto sobre la profundidad del nivel freático, (2) dentro del área de estudio, y (3) dentro de la zona de influencia de los flujos de agua subterránea del interior del país (Figura 2.4). Los datos se recopilaban en un periodo que abarcó desde junio de 1990 hasta mayo de 2010.



Figura 2.4: Mapa de ubicación de la zona de estudio en Rio Danubio (extraída de [2])

Luego se seleccionaron dos modelos paramétricos para comparar su rendimiento, cada uno de ellos tenía como objetivo predecir el nivel de aguas subterráneas con un mes de anticipación y poder establecer relaciones entre los parámetros de entrada. Los modelos seleccionados fueron ANN y ANFIS³⁵ el Sistema de Inferencia Neuro-Difuso Adaptativo [29]. Para establecer la relación entre los parámetros se seleccionaron dos métodos. El primero se basó en la opinión de un experto sobre cuales podían ser las variables más relacionadas con el aumento o baja del nivel freático, y para el segundo se realizó un análisis de correlación donde se eligieron variables en base a la experiencia y se buscó establecer una relación entre ellas y el nivel freático. Algunas de las variables elegidas en este estudio fueron los niveles de agua en pozos cercanos, precipitación, evapotranspiración y temperatura del aire. El análisis de correlación sirvió para seleccionar los pares de variables físicas entre las que se establecía una relación causal significativa. Este análisis mostró que no había una dependencia significativa entre la precipitación, los parámetros climáticos y los niveles de agua subterránea en los pozos estudiados. Por otro lado, el análisis mostró una fuerte relación causal entre la profundidad del agua en un pozo determinado, la profundidad del agua en los pozos circundantes, el nivel del Danubio, y el nivel del agua en el canal principal desde el cual se descargaba el agua al Danubio, ya sea por gravedad o por bombeo. Según los autores, la selección de variables de entrada para los modelos fue importante, ya que una gran cantidad de ellas ralentizaban el modelo y no proporcionaban datos estadísticamente significativos sobre las interacciones de las variables individuales.

Luego, basados en las métricas del RMSE, R^2 y el coeficiente de eficiencia (COE³⁶) concluyeron que ambos modelos podían ser utilizados con un alto nivel de precisión para modelar los niveles freáticos sin un efecto significativo de la distancia del pozo al río, ya que la precisión del modelo, expresada a través de los indicadores, fue aproximadamente la misma en los tres casos.

³⁵por sus siglas en inglés, Adaptive Neuro-Fuzzy Inference System

³⁶por sus siglas en inglés, Coefficient of Efficiency

De esta forma, los resultados sugirieron que ambas técnicas, ANN y ANFIS, fueron útiles para modelar procesos hidrológicos y que sus capacidades de cómputo y memoria fueron similares. También representaron un marco numérico para generar modelos de alta calidad ante la ausencia de algunos datos que podrían ser relevantes si se hubiera seleccionado un modelo físico.

2.4.3. Trabajo presentado por Shamsuddin et al. [3]

En esta propuesta se planteó a la filtración fluvial como método para mejorar la calidad del agua potable a través de la filtración de aguas superficiales y la mezcla con el agua subterránea. El estudio analizó la interacción entre los ríos y los acuíferos mediante la recarga natural de las aguas subterráneas cercanas a la rivera del río analizado.

En particular, el área de estudio se definió sobre una zona plana de la cuenca del río Langat, donde se conectan los ríos Semenyih, Langat y un pequeño río Jenderam Hilir que fluyen hacia el río Langat en Malasia. El área de estudio se delimita por zonas montañosas al norte y al este, y por el mar al suroeste. La elevación máxima es de 297 msnm³⁷ y la mínima es de 7.981 msnm. Se cubrió una zona de 10 km² como se puede observar en la Figura 2.5. Las temperaturas promedio diarias en dicha zona varían de 27°C a 30°C. A su vez, el área experimenta dos periodos de monzones: el monzón del noreste de octubre a enero (estación húmeda) y el monzón del suroeste de mayo a septiembre (estación seca). La precipitación anual se concentra en noviembre y diciembre. Los datos utilizados en este estudio (lluvia, caudal del río, temperatura, nivel del agua del río y nivel del agua subterránea) cubrieron el periodo desde febrero de 2015 a marzo de 2016.

Según los autores, la fluctuación dinámica de los niveles de agua subterránea esta influenciada por varios factores como la climatología, las propiedades hidrogeológicas y la cantidad de agua que se extrae. Por tal motivo, plantearon el diseño de una red de monitoreo de aguas subterráneas, la cual va a depender de las condiciones hidrogeológicas y de los recursos logísticos disponibles. Por otro lado, utilizaron modelos matemáticos y conceptuales para comprender la relación río-acuífero y sus limitaciones prácticas. Es por ello que sugirieron la utilización de un método de aprendizaje automático para la predicción de los niveles de agua subterránea. El objetivo de este estudio fue demostrar la aplicabilidad de este enfoque en la predicción de los niveles de agua subterránea, su potencial en la modelización de las fluctuaciones del nivel de agua y demostrar la relación entre el río y el acuífero.

Para esto, propusieron la creación de un modelo ANN con el propósito de realizar predicciones de los niveles de agua subterránea en dos pozos de prueba con un día de anticipación. Para mejorar la precisión de las predicciones, tomaron en cuenta varios parámetros, tales como la lluvia, el nivel del río, el flujo superficial y la temperatura. Los resultados del análisis les reveló la existencia de una relación significativa entre los niveles de agua actuales y los del día anterior, lo que les aportó información valiosa para el modelo. Tras el entrenamiento, comprobaron que pudieron predecir los niveles de agua subterránea en los pozos de prueba. Específicamente, determinaron que la lluvia resultó ser el parámetro más relevante que afecta los niveles de agua subterránea en la zona de estudio, demostrando una mayor influencia que el nivel del río y la temperatura. También confirmaron para este modelo que el flujo de agua superficial desempeñó un papel importante en la recarga del agua subterránea.

Si bien se encontraron algunas desviaciones en ciertas ocasiones, en general, el modelo demostró buena correlación entre los datos pronosticados y los datos reales, lo que sugirió un desempeño satisfactorio. De esta forma, los resultados respaldaron la relevancia primordial de la lluvia y el flujo de agua superficial como factores clave que influyen en los niveles de agua subterránea en el área de estudio. Estos hallazgos pueden tener implicaciones importantes para una gestión más eficiente y sustentable del recurso hídrico en la región.

³⁷msnm significa metros sobre el nivel del mar




Figura 2.5: Mapa de ubicación de la zona de estudio (extraída de [3])

2.4.4. Trabajo presentado por Sun et al. [4]

El trabajo presentado se enmarca en una política del gobierno chino para la preservación del ambiente ecológico del río Yongding. Así, en 2016 se implementó un esquema integral de tratamiento y restauración ecológica del río, destacando el concepto de Reabastecimiento Ecológico de Agua (EWR³⁸) como clave en la restauración de ecosistemas fluviales. De esta forma, este artículo describe el estudio realizado en la cuenca hidrográfica del río Yongding, específicamente en la sección de Beijing. La cuenca incluyó dos ramas principales, la norte (río Yang) y la sur (río Sanggan), que convergen en la presa Guanting, formando así el río en cuestión. Se clasificó en tres zonas: montañosa, llanura norte y llanura sur, como se observa en la Figura 2.6. Como podemos observar, el flujo de agua en el río Yongding está controlado por varios embalses, con almacenamiento en Sanjiadian y Lugouqiao. Además, se realizan trabajos de desvío a través del canal del río Yongding antes de Sanjiadian. Todas estas intervenciones afectaron al río durante el periodo de gestión de recursos de agua EWR.

El agua subterránea en el área de estudio se recarga principalmente por precipitación, filtración del río y flujo lateral. La descarga se realiza principalmente en forma de explotación artificial (campos de suministro de agua pública), complementada por evaporación y flujo lateral. Este estudio recopiló principalmente la escala diaria de conjuntos de datos de precipitación, caudal, nivel de agua subterránea y suministro de agua desde el 20 de abril de 2020 hasta el 1 de junio de 2020, y datos de caudal anual de algunas estaciones de medición en 2019.

El objetivo del estudio fue desarrollar un modelo integrado de flujo de canal abierto y agua subterránea para revelar los cambios dinámicos en el flujo de corriente y el nivel del agua subterránea durante el periodo del proyecto EWR. Para lograr dicho objetivo, los autores propusieron desarrollar un modelo físico utilizando el método Muskingum, el cual es un enfoque hidrológico

³⁸por sus siglas en inglés, Ecological Water Replenishment

utilizado para modelar el comportamiento de los flujos en ríos y arroyos [30]. Por otro lado para predecir el nivel del agua subterránea bajo la influencia de la infiltración del río utilizaron ANN, SVM y bosque aleatorio (RF³⁹) [14].




Figura 2.6: Mapa de ubicación de la zona de estudio (extraída de [4])

Basados en los datos sobre los niveles de agua subterránea, la infiltración de los ríos, la lluvia y el suministro de agua en las ciudades, se clasificaron los cambios en los niveles de agua subterránea en cuatro tipos diferentes, clasificando un total de 77 freáticos en distintos grupos. En el Tipo I, observaron que los niveles de agua subterránea se vieron afectados principalmente por la infiltración del río. Estos pozos de observación se encontraban principalmente en áreas montañosas y en la llanura norte cerca del río. Durante el periodo de gestión de recursos de agua EWR, el aumento en el suministro de agua del río mediante infiltración aumentó la recarga de agua subterránea, lo que resultó en un aumento en el nivel freático. En el Tipo II, los pozos de observación estaban ubicados principalmente cerca de la estación de Lugouqiao y los cambios en los niveles de agua subterránea fueron influenciados tanto por la lluvia como por la infiltración del río. En el Tipo III, los niveles de agua subterránea eran controlados por la infiltración de los ríos, la lluvia y la extracción de agua subterránea. Finalmente, en los pozos de observación

³⁹por sus siglas en inglés, Random forest

restantes, pertenecientes al Tipo IV, los niveles de agua subterránea no se vieron afectados de manera evidente por la infiltración del río, la lluvia y la extracción de agua subterránea.

De esta forma, los autores concluyeron que el método Muskingum demostró una precisión aceptable en el cálculo del flujo, mientras que el método RF fue seleccionado como el más preciso y menos sensible para simular el nivel del agua subterránea.

Al construir quince escenarios de EWR, se predijeron cambios en el flujo del río y el nivel del agua subterránea. La conclusión principal resalta la importancia de un flujo adecuado en el embalse de Guanting (superior a $65 \text{ m}^3/\text{s}$) para mantener un flujo estable en Beijing y lograr una recuperación significativa del nivel del agua subterránea, alcanzando un total de 170 millones de m^3 de EWR.

2.4.5. Trabajo presentado por El Bilali et al. [5]

En este artículo, los autores subrayaron la importancia crucial del agua subterránea como recurso vital para el abastecimiento de agua a nivel global, destacando la intensificación de su extracción debido al aumento de la población y la demanda de la misma. Ante los desafíos del agotamiento y degradación de la calidad del agua subterránea, propusieron el uso de técnicas basadas en el conocimiento científico para la planificación y gestión. Señalaron que, tradicionalmente, se empleaban modelos conceptuales para simular procesos acuíferos, pero estos enfrentaban dificultades debido a la complejidad de evaluar múltiples parámetros físicos, hidrológicos y geológicos. Propusieron entonces la implementación de modelos de aprendizaje automático y minería de datos como una opción viable, respaldada por estudios que demostraban su alta precisión en diversos campos.

En el momento del estudio, el acuífero Tanobart, situado en la mitad oriental de la ciudad de Khemesset, Marruecos, abarcaba una superficie total de 34 km^2 . Esta reserva subterránea de agua, alimentada por los ríos Tanobart y Bouregreg, estaba compuesta por rocas de basalto del periodo triásico en una parte y capas de arcilla y yeso en el resto (Figura 2.7). El agua subterránea de este acuífero desempeñaba un papel crucial en el suministro de agua potable en la ciudad de Maaziz, proporcionando hasta 0.2 millones de m^3 de agua al año para una población de 8900 personas en el centro de la ciudad y 2600 personas en las áreas rurales cercanas. También se utilizaba para regar 800 hectáreas de tierra. Desde el punto de vista climático, la zona donde se encontraba el acuífero experimentaba un clima semiárido, con temperaturas muy altas en verano, alcanzando un promedio de alrededor de 34°C , y temperaturas más frescas en invierno, con un promedio de aproximadamente 4.8°C . La cantidad promedio de lluvia anual se situaba en torno a los 400 mm.

Para comprender el funcionamiento del acuífero Tanobart, se instalaron siete freáticos para medir el nivel del agua subterránea a lo largo de varios años; desde mayo de 2008 hasta agosto de 2017. Esta información resultó crucial para comprender las variaciones en el nivel del agua a lo largo del tiempo y su respuesta a factores como el caudal de los ríos y las extracciones de agua.

Los objetivos del estudio fueron: (1) evaluar la eficacia de los modelos de aprendizaje automático en la predicción del nivel del agua subterránea en las condiciones del área de estudio; (2) comparar y clasificar los modelos en términos de precisión y estabilidad; y (3) evaluar la incertidumbre de los modelos utilizados en la predicción. Para realizar el estudio, se utilizaron conjuntos de datos correspondientes a un periodo de nueve años, que incluyen información sobre el nivel del agua subterránea, precipitación, caudal del río, tasa de evaporación y tasa de extracción de agua subterránea. Los datos fueron proporcionados por la agencia de cuenca hidrográfica de Bouregreg-Chaouia y se organizaron a escala mensual. Se realizaron análisis estadísticos descriptivos para resumir las características de los datos encontrando que las variables de entrada más relevantes para predecir el nivel del agua subterránea fueron el registro de su nivel anterior, la precipitación y el caudal del río, entre otras.

Al mismo tiempo, se desarrollaron cuatro modelos de aprendizaje automático para predecir




Figura 2.7: Mapa de ubicación de la zona de estudio en Marruecos (extraída de [5])

el nivel de agua subterránea del acuífero: KNN, SVR⁴⁰, ANN y RF. Se destacó la utilidad de los mismos para prever el nivel del agua subterránea, proporcionando herramientas valiosas para la gestión del agua subterránea en zona analizada. Los modelos seleccionados y los resultados obtenidos ofrecieron recursos significativos para la predicción precisa del nivel del agua subterránea en un contexto semiárido. Según los autores, la metodología desarrollada podría aplicarse en regiones similares, superando limitaciones asociadas con los conjuntos de datos físicos requeridos por modelos conceptuales para la predicción de los niveles de agua subterránea.

2.4.6. Trabajo presentado por Liu et al. [6]

Este estudio se enfocó en la parte inferior de la cuenca del río Tarim, conocida como “Corredor Verde”, como se puede observar en la Figura 2.8. Los funcionarios y técnicos de la zona habían observado en varios estudios que el caudal de agua en esa región había ido experimentando una disminución significativa debido al cambio climático y la actividad humana. Este fenómeno había comenzado a ocasionar sequías, degradación de ecosistemas y la propagación de procesos de desertificación y salinización. La cuenca del río Tarim, con una superficie de aproximadamente $1,02 \times 10^6 \text{ km}^2$, es uno de los sistemas de drenaje hidrológico cerrado más grandes del mundo. Se encuentra cerca del desierto de Taklimakan y se alimenta principalmente de las precipitaciones de las montañas medias y del agua de deshielo de los glaciares y zonas montañosas altas. Sin embargo, debido al cambio climático y la explotación intensiva del agua, muchas cabeceras de cuenca habían perdido los enlaces hidráulicos con la corriente principal del río Tarim, quedando sólo los ríos Aksu, Yarkant y Hotan como fuentes de agua para la cuenca. Ante estos problemas, el gobierno chino implementó el proyecto de “Conducción Ecológica de Agua” desde el año 2000.

⁴⁰por sus siglas en inglés, Support Vector Regression

Dicho proyecto involucró el transporte de agua desde el río Tarim superior y el lago Bosten hacia las áreas bajas, lo que logró incrementar los niveles de agua subterránea y recuperar los ecosistemas afectados.




Figura 2.8: Mapa de ubicación de la zona de estudio Rio Tarim (extraída de [6])

Para este estudio, los datos que utilizaron incluyeron observaciones mensuales de niveles de agua subterránea de 74 pozos de monitoreo desde el año 2000 hasta 2020. Además, recopilaron datos de temperatura y humedad relativa de estaciones climatológicas, así como el volumen mensual de agua transportada desde el embalse de Daxihaizi a los canales del río Tarim.

El objetivo principal fue desarrollar un modelo para predecir la distribución espacio-temporal de los niveles de agua subterránea en regiones áridas, donde la recarga de agua subterránea ocurre principalmente a través del flujo intermitente como la recarga artificial de agua desde el curso del río. Además, buscaban estimar cuantitativamente el estado actual y futuro del agua subterránea en la cuenca baja del río Tarim utilizando modelos de aprendizaje automático. Los modelos utilizados consistieron en SVM, Red Neuronal de Regresión Generalizada (GRNN⁴¹), Árbol de Decisión (DT⁴²) y RF. Por otro lado, también utilizaron tres modelos de aprendizaje profundo: CNN, LSTM y GRU.

De la comparación entre los modelos, el modelo RF mostró un rendimiento superior en las predicciones de la profundidad del agua subterránea en el dominio espacio-temporal. Este modelo utilizó datos como temperatura, humedad relativa, volumen de flujo, información geoespacial y la distancia al cauce del río. Se utilizó el método de explicaciones aditivas de Shapley para interpretar el modelo RF. Esto permitió entender cómo cada variable de entrada afecta el nivel de agua subterránea. Al mismo tiempo, se utilizó el modelo RF para simular el nivel actual del agua subterránea y predecir su variación en los próximos tres años. Esto proporcionó información útil para el estudio de la ecología e hidrología resultante del cambio en el nivel de agua subterránea en la cuenca del río estudiado.

Los resultados resaltaron la importancia de los modelos realizados proyectos de “Conducción Ecológica de Agua” en la elevación de los niveles de agua subterránea y en la expansión de las áreas adecuadas para el crecimiento de plantas. El estudio proporcionó información cuantitativa sobre las variaciones presentes y futuras del agua subterránea, lo cual sería relevante para la toma de decisiones informadas sobre la gestión sostenible de los recursos hídricos en regiones áridas. En particular, se proyectó que los niveles de agua subterránea disminuirían en promedio a -6,4 m en los próximos tres años sin conducción de agua. De esta forma, se sugirió realizar investigaciones

⁴¹por sus siglas en inglés, General Regression Neural Network

⁴²por sus siglas en inglés, Decision Tree

adicionales para mejorar la precisión de la predicción del nivel del agua subterránea, incluyendo el uso de datos satelitales y la integración de modelos basados en procesos para mejorar la comprensión de los mecanismos físicos involucrados en el sistema de agua subterránea.

2.5. Resumen de los Trabajos Relacionados

En la Tabla 2.1 presentamos un resumen de las propuestas descriptas previamente en relación a estudios de las cuencas y los niveles freáticos. En particular resumimos cuatro aspectos: el objetivo de cada estudio, las fuentes utilizadas y el periodo analizado, las técnicas de análisis empleadas y los resultados obtenidos.

Por ejemplo, podemos observar que la propuesta presentada en [1] estableció como objetivo el uso de datos temporales de freáticos y de dos estaciones meteorológicas para calcular el nivel del agua subterránea en la cuenca del norte de París-Francia y predecir el comportamiento del nivel de las aguas subterráneas. Para esto utilizaron ANN con datos provenientes de las mediciones de freáticos, lluvia, temperatura y evaporación. Estos datos fueron recopilados durante 11 años, desde enero de 1988 hasta marzo de 1999, con un intervalo de tiempo de 1 mes. Como resultado pudieron demostrar que el enfoque de redes neuronales tiene una buena capacidad para simular el proceso dinámico estudiado, logrando resultados precisos con un límite óptimo de 3 días.

Luego, en el trabajo presentado en [2] propusieron el uso de datos temporales obtenidos de freáticos para predecir el nivel de la napas y comparar modelos paramétricos para obtener el más eficiente que permita predecir dichos niveles. Para esto utilizaron datos del nivel de agua en pozos cercanos, nivel del río, nivel del canal, precipitación, evapotranspiración, temperatura del aire, y aplicaron dos modelos de aprendizaje automático: ANN y ANFIS. Los datos utilizados fueron obtenidos durante el periodo de junio de 1990 a mayo de 2010. Los resultados sugirieron que ambos modelos lograron predecir el nivel de las napas con una precisión similar a los modelos físicos y que no hay una diferencia significativa entre ambas técnicas en este estudio.

En el artículo presentado en [3], tercera fila de la tabla, los autores utilizaron datos temporales obtenidos de freáticos y estaciones meteorológicas con el objetivo de demostrar la aplicabilidad de la filtración fluvial y su potencial en la modelización de las fluctuaciones del nivel de agua. Para esto se diseñó un modelo ANN con datos tales como lluvia, nivel del río, flujo superficial y la temperatura obtenidos desde febrero de 2015 hasta marzo de 2016. Los resultados respaldaron la relevancia primordial de la lluvia y el flujo de agua superficial como factores clave que influyen en los niveles de agua subterránea en el área de estudio.

Luego, en el artículo presentado en [4], y como podemos observar en la cuarta fila, los autores plantearon como objetivo de estudio desarrollar un modelo integrado de flujo de canal abierto y agua subterránea para revelar los cambios dinámicos en el flujo de corriente y el nivel del agua subterránea. Para tal objetivo utilizaron el método Muskingum para modelar el comportamiento de los flujos en ríos y arroyos, y los modelos ANN, SVM y RF para predecir el nivel del agua subterránea. Se utilizaron también datos temporales obtenidos de estaciones meteorológicas, los cuales incluían información sobre precipitaciones. Se recopilaron datos de freáticos, como nivel de agua subterránea y suministro de agua, durante el periodo desde el 20 de abril de 2020 hasta el 1 de junio de 2020. Además, se incluyeron datos de caudal anual de algunas estaciones de medición correspondientes al año 2019. Los autores concluyeron que el método Muskingum demostró una aceptable precisión en el cálculo del flujo de corriente, mientras que el método RF fue seleccionado como el más preciso y menos sensible para simular el nivel del agua subterránea.

Continuando, en [5] el objetivo fue evaluar la eficacia de los modelos de aprendizaje automático en la predicción del nivel del agua subterránea. Para ello, compararon, clasificaron y evaluaron la incertidumbre asociada a los mismos. Para cumplir con los objetivos, se utilizaron conjuntos de datos temporales desde el 1 de mayo de 2008 al 1 de agosto de 2017. Estos conjuntos incluyeron información sobre el nivel del agua subterránea, precipitación, caudal del río, tasa de evaporación

Propuesta	Objetivo	Fuentes/Periodo	Análisis	Resultados
Lallahem et al. 2005 [1] (Francia)	Predicir el comportamien- to del nivel de las aguas subterránea con ANN	Nivel de la napa, Tem- peratura, Precipitación, Evapotranspiración, 13 Freatímetros, 2 centros meteorológico 11 años (1988 a 1999).	ANN	El modelo ANN tiene bue- na capacidad para simular los Niveles de agua subte- rránea y predecirlos.
Stricevic et al. 2015 [2] (Serbia)	Evaluar la aplicabilidad de ANN y ANFIS para pre- decir el nivel freáticos	Niveles freáticos, Nivel del río, Nivel del canal, Pre- cipitación, Evapotranspi- ración y Temperatura, 3 Freatímetros, 1990 a 2010.	ANFIS, ANN	ANN y ANFIS logra- ron predicir el nivel de agua subterránea sin dife- rencias significativas entre modelos.
Shamsuddin et al. 2017 [3](Malasia)	El objetivo demostrar la aplicabilidad RBI, com- prender la relación entre el río-acuífero y evaluar la viabilidad del enfoque de ANN.	Precipitación, Caudal del río, Temperatura, SWL, Nivel freático, 2 Freatime- tros, 02/2015 a 03/2016.	ANN	El modelo ANN demostró ser efectivos para prom- ticar el nivel de agua sub- terránea.
Sun et al. 2021 [4] (China)	Predicir cambios dinámi- cos en el flujo de la co- rriente y el nivel del agua subterránea durante el pe- ríodo del proyecto EWR utilizando ANN, SVM y RF.	Precipitación, Caudal, Ni- vel freático, Caudal anual 2019, 77 Freatímetros, estaciones meteorológicas, del 04/2020 a 06/2020.	ANN, SVM y RF	RF fue seleccionado como el modelo más preciso y menos sensible para simu- lar el nivel del agua subte- rránea.
El Bilali et al. 2021 [5](Marruecos)	Evaluar la eficacia de los modelos ML (K-NN, SVR, ANN y RF) para predicir el nivel freático.	Nivel freático, Precipita- ción, Caudal del río, Tasa de evaporación, Tasa de bombeo, 7 freatímetros, 2008 a 2017.	k-Nearest Neighbour SVR RF ANN	Los resultados mostraron que, a excepción del mo- delo k-NN, todos los de- más modelos produjeron buenos desempeños para predicir el nivel freático.
Liu et al. 2022[6] (China)	Desarrollar un modelo pa- ra predicir la distribución espacio-temporal. Estimar el estado presente y futuro de las aguas subterráneas.	Temperatura, RH, Volu- men total mensual, Ni- vel freático, 74 freatime- tros, Estaciones meteoroló- gicas, satélites, 1999-2020.	SVM, GRNN, DT, RF, CNN, LSTM, GRU.	Los investigadores conclu- yeron que RF demostró ser superior a los demás en las predicciones a cor- to plazo.

Tabla 2.1: Resumen Artículos

y tasa de extracción de agua subterránea obtenidas de estaciones meteorológicas y freatímetros. El análisis de incertidumbre enfatizó la eficacia de los modelos de aprendizaje automático en la predicción del nivel del agua subterránea. De los cuatro modelos evaluados (KNN, SVR, RF y ANN), los últimos tres mostraron resultados prometedores. Así, estos hallazgos les proporcionaron herramientas significativas para una predicción precisa del nivel del agua subterránea en un entorno semiárido.

Finalmente, en el artículo presentado en [6], se estableció el objetivo de comparar la capacidad predictiva de diferentes modelos de aprendizaje automático y aprendizaje profundo. Además, se buscó interpretar los resultados obtenidos de los modelos para identificar los factores más importantes, simular el nivel actual del agua subterránea, y predecir los niveles futuros de la misma. Para este propósito, emplearon modelos como SVM, GRNN, DT, RF, CNN, LSTM, GRU y se utilizaron datos mensuales de temperatura del aire y humedad relativa entre los años 1999 y 2020, recolectados de una estación meteorológica cercana. También se incluyeron mediciones del nivel del agua subterránea obtenidas de diferentes freatímetros, así como información geoespacial. De la comparación entre los modelos, en particular, el modelo RF mostró un rendimiento superior en las predicciones a corto plazo del nivel de agua subterránea.




Figura 2.9: Resumen de los trabajos relacionados

Para un análisis general, en la Figura 2.9 mostramos un resumen de las fuentes de datos utilizadas (satélites, estaciones meteorológicas, freatímetros y escala hidrométrica), las formas de extracción (en lotes), las variables utilizadas (como una taxonomía de factores), y las técnicas de análisis aplicadas en las propuestas analizadas.

Después de examinar detenidamente los estudios sobre la predicción del nivel del agua subterránea y el análisis hidrológico, resulta evidente que ciertas variables y técnicas de análisis juegan un papel crucial en este campo de investigación. En primer lugar, se destaca la importancia de variables como la temperatura, precipitación, nivel del río, flujo superficial y evaporación. Estas variables resultaron fundamentales para comprender los procesos hidrológicos y las fluctuaciones en los niveles freáticos ya que influyen directamente en el comportamiento del agua subterránea en diferentes entornos.

En cuanto a las técnicas de análisis, se observa que las ANN fueron ampliamente utilizadas

en estos estudios, como se pudo observar en los trabajos [1, 2, 3, 4, 5]. Es importante destacar que varios estudios compararon diferentes modelos de predicción, incluidos ANN, Random Forest (RF) ([4, 5, 6]) y modelos físicos, para evaluar su eficacia en la predicción del nivel del agua subterránea. Si bien algunos modelos mostraron resultados prometedores, las ANN y RF emergieron como las técnicas más eficaces para predecir este nivel en diversos entornos hidrológicos.

Los hallazgos de estos estudios resaltan la importancia de considerar variables clave y técnicas analíticas avanzadas en la predicción del nivel del agua subterránea. Esta comprensión profunda de los procesos hidrológicos y el uso de herramientas analíticas adecuadas son fundamentales para abordar los desafíos asociados con la gestión sostenible de los recursos hídricos y la mitigación de los impactos del cambio climático en los sistemas acuíferos.

2.6. Trabajos Previos dentro del Proyecto de Investigación

El trabajo de esta tesis se enmarca dentro Proyecto de Investigación denominado *Modelado de Variedad en Sistemas Big Data* (ORD 0084/22). En el mismo se han realizado varios avances dentro del proceso de desarrollo de big data enfocándose en el concepto de *variedad* para la construcción de sistemas más flexibles y adaptables mediante la promoción del reuso [15, 16, 17, 31].

En las secciones siguientes se resumen los enfoques y herramientas mas importantes de los trabajos realizados tendientes a identificar, documentar y gestionar la variedad en SBD.

2.6.1. Enfoques para la Identificación de la Variedad

Previo a describir los enfoques que permiten identificar la *variedad*, es necesario definir este concepto según los trabajos previos. La *variedad* en sí misma, se define como *la diversidad o multiplicidad de alternativas dentro de dominios específicos que pueden ser identificados para ser reusados* [17]. La variedad se clasifica como:

- *Variedad de las fuentes*: son los diversos conjuntos de datos que se utilizan para llevar adelante la construcción de un sistema de big data. Documentar las fuentes que se han utilizado para trabajar dentro de un dominio es útil para que en un proyecto futuro se conozcan los datos que suelen consultarse dentro del mismo. Por ejemplo, para determinados análisis se usan fuentes de datos satelitales, datos meteorológicos, etc. A modo de estandarizar qué tipos de fuentes pueden relevarse, se agrega también como variedad de fuentes los tipos de estructuras posibles como: conjuntos de datos estructurados, no estructurados y semi-estructurados.
- *Variedad de contenido*: se centra en las variables o factores utilizados, las variables objetivo, los umbrales y otras características relevantes. Esto ayuda a determinar de antemano las variables que suelen considerarse en cada fuente, facilitando la planificación de nuevos SBD.
- *Variedad de procesamiento*: se enfoca en las técnicas de análisis utilizadas para procesar y extraer conocimiento a partir de los datos (ej. redes neuronales, correlación, series temporales, redes convolucionales, etc.). Tener conocimiento de los análisis previamente realizados en un dominio permite utilizarlos como punto de partida para análisis más avanzados o diferentes. En caso de contar con resultados, es posible también reutilizarlos o ajustarlos según sea necesario. También define las diferentes variedades en cuanto al procesamiento desarrollado, ya sea en lotes, en tiempo real, o interactivo.
- *Variedad de contexto*: incorpora el contexto semántico al definir las observaciones en función de su entorno, permitiendo diferenciar y agrupar casos similares. El contexto es esencial para dar sentido a las otras variedades, ya que, por ejemplo intentar reutilizar un análisis

de correlación en el dominio hidrológico sin contextualización puede no ser efectivo. Al documentar la variedad de contexto, todas las observaciones estarán vinculadas a su entorno. Por ejemplo, se puede reutilizar un análisis de correlación en el dominio hidrológico para ríos ubicados en zonas semiaridas contra otro contexto de ríos en zonas húmedas.

Para dar soporte a la identificación de los tipos de variedad definidos previamente, se han desarrollado dos enfoques: *Top-Down (T-VIP)* y *Bottom-up (B-VIP)*, como observamos en la Figura 2.10 (repetida de la Figura 1.1). Estos enfoques permiten identificar y trabajar la variedad a lo largo del desarrollo de todo sistema de big data. Se centran especialmente en mejorar la reusabilidad en estos sistemas mediante la utilización de una base de conocimiento de manera de ahorrar tiempo y trabajo. Como podemos observar en la figura, los enfoques poseen una serie de pasos a realizar, los cuales se definen como:

- *Enfoque Top-Down (T-VIP)*: En este enfoque, representado en el lado izquierdo de la Figura 2.10, se realizan los siguientes pasos:
 - Dado un problema del dominio (1), un usuario experto elabora una o más hipótesis que se deben probar a través del proceso. Es decir, define la pregunta ¿los datos corroboran esto?.
 - Luego, las hipótesis son tomadas por analistas de datos (2) quienes proceden a realizar las actividades (3) incluidas en el *Proceso de Big Data* (en azul en el centro de la figura).
 - Los resultados se devuelven para verificar las hipótesis (4), posiblemente visualizando los datos de diferentes maneras.
 - Finalmente se debe decidir si se realizará una reformulación de las hipótesis o se finalizará el proceso (5).
- *Enfoque Bottom-Up (B-VIP)*: En este enfoque, representado en el lado derecho de la Figura 2.10, se realizan las siguientes acciones:
 - Dado un problema del dominio (1), un usuario experto decide comenzar un estudio exploratorio para descubrir qué pueden revelar los datos sobre este problema. Es decir, define la pregunta ¿qué dicen los datos?.
 - Luego, los analistas de datos llevan a cabo el estudio (2), nuevamente aplicando las actividades incluidas en el *Proceso de Big Data* (3).
 - Los resultados se devuelven para verificar las hipótesis (4), posiblemente visualizando los datos de diferentes maneras.
 - Finalmente se debe decidir si se realizará una reformulación de las hipótesis o se finalizará el proceso (5).

Al mismo tiempo, y como podemos observar en la figura, además de la variedad, los enfoques deben considerar las actividades involucradas en el *proceso de big data*, las cuales son:

- *Colección*: maneja la interfaz con los proveedores de datos. Puede ser un servicio general como un servidor de archivos o un servidor Web configurado para aceptar o recopilar datos específicos. Este servicio también puede estar diseñado para extraer datos o recibir datos directamente del proveedor. Una vez recibidos los datos, deben almacenarse para que se guarden permanentemente. En esta actividad, se recopilan conjuntos de datos de estructura similar, se combinan y se crean metadatos iniciales para facilitar la futura agregación o búsqueda de datos.




Figura 2.10: Enfoques Top-Down (T-VIP) y Bottom-up (B-VIP) para el desarrollo de SBD considerando variedades

- *Preparación*: se encarga principalmente de la transformación de datos. Las tareas incluyen validar, verificar formatos, limpiar, eliminar registros o campos incorrectos, eliminar valores atípicos, estandarizar, reformatear y encapsular los datos. Además, en esta etapa se suelen almacenar los datos en archivos y verificar su procedencia. La preparación también puede optimizar los datos mediante manipulaciones como la deduplicación e indexación. Esta actividad puede combinar datos de diferentes proveedores, utilizando metadatos para crear un conjunto de datos más completo.
- *Analítica*: incluye la codificación de la lógica empresarial de bajo nivel, es decir, implementa técnicas para extraer conocimiento de los datos según los requisitos específicos de la aplicación. Esto implica el uso de algoritmos de procesamiento de datos para generar nuevos conocimientos. La lógica analítica se implementa utilizando frameworks de procesamiento que pueden manejar grandes volúmenes de datos, ya sea en lotes o en tiempo real. Estos frameworks permiten que los módulos de análisis se comuniquen entre sí para ejecutar la lógica analítica de manera efectiva.
- *Visualización*: prepara los datos procesados y los resultados del análisis para presentarlos al consumidor de datos. El objetivo es formatear y presentar los datos de manera que transmitan claramente su significado y conocimiento. Esto puede incluir la creación de informes basados en texto o gráficos. La visualización puede ser estática (almacenada para acceso posterior) o interactiva, permitiendo a los consumidores de datos interactuar con los datos basados en parámetros específicos. Esta actividad puede usar bibliotecas de visualización o frameworks de procesamiento especializados para mostrar los datos.
- *Acceso*: se centra en la comunicación con el consumidor de datos. Puede ser un servicio genérico como un servidor Web configurado para manejar solicitudes específicas. Esta acti-

vidad interactúa con las actividades de visualización y análisis para responder a solicitudes del consumidor, utilizando los frameworks de procesamiento y plataformas para recuperar y entregar los datos solicitados. Además, se asegura de que los metadatos necesarios estén disponibles y se mantengan mientras los datos son transferidos al consumidor. La interacción puede ser sincrónica (en tiempo real) o asincrónica (en diferido), y puede usar métodos de extracción o inserción para la transferencia de datos.

2.6.2. Herramienta para la Gestión de la Variedad basada en Contexto (CoVaMaT)

La Figura 2.10 en el lado derecho en color verde muestra una serie de componentes denominados *activos de la base de conocimiento*. Dichos activos son administrados mediante una herramienta de soporte desarrollada previamente, con el nombre de CoVaMaT (Context-based Variety Management Tool) [15, 16].

CoVaMaT esta compuesta por tres funcionalidades fundamentales que abordan distintos aspectos relacionados con la documentación de variedades, la instanciación de casos y la consulta de activos de dominio. Previo a describir las funcionalidades es necesario dar definiciones sobre algunos conceptos clave definidos por CoVaMaT:

- *Activos de dominio*: son recursos tangibles e intangibles que se utilizan en el contexto de un dominio específico. Estos activos pueden incluir documentos, herramientas, modelos, patrones de diseño, componentes de software, conocimientos especializados, y/o cualquier otro elemento que sea valioso para entender, desarrollar o gestionar un dominio particular. Suelen ser compartidos y reutilizados dentro de una organización o comunidad para mejorar la eficiencia y la calidad en el trabajo relacionado con ese dominio específico.
- *Caso de dominio*: consiste en la descripción de un caso de dominio mediante la selección de las variantes o variedades. Por ejemplo, en el ámbito de los recursos hídricos, los cuerpos de agua pueden ser ríos, lagos, etc.; y el caso puede corresponder a uno de estos valores, por ejemplo, ríos. Además, para ese río en particular, pueden ser relevantes valores específicos de calidad del agua, como oxígeno disuelto, pH, etc. El conjunto de valores seleccionados para todas las variables relevantes en el dominio constituirá el caso instanciado.
- *Caso reusable*: se refiere a utilizar activos de dominio y casos ya instanciados para hacer uso de ese conocimiento ya documentado en una situación similar. En general se realiza en base a la variedad de contexto definida.

A continuación, describimos cada una de de las funcionalidades de CoVaMaT:

- *F-1: Funcionalidad para documentar variedades*: permite especificar la variedad de dominio de un caso como jerarquías de tipos de variedad, que pueden identificarse mediante alguno de los enfoques de identificación de variedad vistos (T-VIP o B-VIP). Por ejemplo, las diferentes posibilidades para cuerpos de agua, parámetros de calidad del agua, etc., son candidatos a ser variantes de dominio de sistemas de hidrología. Así, los tipos de variedad se detectan al desarrollar casos de dominio y se almacenan como activos de ese dominio. Son atendidos por un servicio (S-1: Servicio de documentación de variedad:), el cual es respaldado por un proceso (P-1: Documentación de la variedad de dominio) cuando surge un requisito de búsqueda (Evento E-1: Comenzar a buscar variantes).
- *F-2: Funcionalidad para instanciar casos*: permite instanciar un caso de dominio mediante la selección de variantes. Por ejemplo, podríamos seleccionar el caso de “río” para instanciar la variedad de cuerpos de agua; “oxígeno disuelto” para los parámetros de calidad, y así sucesivamente. Como las posibles instancias de variedad del dominio fueron creadas previamente por F-1, las instanciaciones de casos de dominio se crean y almacenan como casos

de dominio por un servicio (S-2: Servicio de instanciación de caso), el cual es respaldado por un proceso (P-2: Definición del caso de dominio) cuando se produce una invocación (Evento E-1: Requerir el uso de la instanciación de casos).

Las principales actividades de P-2, son recuperar las variantes documentadas en P-1 e instanciarlas para un caso de dominio específico. Es decir, las posibles variantes de un caso de dominio se seleccionan aquí para crear el caso específico que se va a implementar. Finalmente, el caso de dominio también se almacena como un activo de caso de dominio.

- *F-3: Funcionalidad para reutilización de casos*: permite reutilizar activos de variedad de dominio (creados en P-1) y/o activos de casos de dominio (creados en P-2). Por ejemplo, podemos reutilizar el caso de “río” para otro río en una ubicación diferente; “oxígeno disuelto” y “pH” como parámetros de calidad relevantes; y así sucesivamente. Reutilizar no implica una coincidencia exacta de los activos de dominio. Por lo tanto, los interesados pueden consultar activos de dominio almacenados previamente y compararlos con un contexto particular con el objetivo de detectar casos similares. Así, las consultas se basan en el contexto definido por los interesados, recuperando cualquier activo de dominio relacionado (activos de dominio y/o activos de casos de dominio). Los casos reutilizables se almacenan como activos de casos reutilizables mediante un servicio (S-3: Servicio de consulta de activos de dominio), que es apoyado por dos procesos (P-3 Definición de caso reutilizable y P4: Consulta de activos de casos de dominio similares) cuando los interesados requieren la reutilización de un caso (Evento E3: Requiere Reutilización).

A su vez, para la documentación de la variedad utilizando las tres funcionalidades previas, se incluye un artefacto de software llamado *datasheet*. El mismo fue introducido en trabajos anteriores [32, 33], y contiene un modelo de variabilidad usando una combinación de notación UML y OVM (Modelo de Variabilidad Ortogonal) [9]. Los datasheets son el eje con el que se modelan, e instancian los componentes reusables de un dominio. En el caso de CoVaMA se utiliza una versión simplificada de los datasheet utilizando solo la parte del modelo de variabilidad.

Para identificar y documentar la variabilidad en datasheets, es necesario definir los siguientes conceptos:

- *Sujeto de Variabilidad (Variability Subject)*: es un elemento variable del mundo real, o una propiedad variable de tal elemento. Ejemplo: el color de un auto.
- *Objeto de Variabilidad (Variability Object)*: es una instancia particular de un sujeto de variabilidad. Ejemplo: color rojo, verde, rosa, etc.
- *Punto de Variación (Variation Point)*: es una representación de un sujeto de variabilidad dentro de artefactos de dominio enriquecidos con información de contexto.
- *Variante (Variant)*: Una representación de un objeto de variabilidad.

Por ejemplo, en la Figura 2.11 se observa un modelo de variabilidad que se desprende de un caso de uso denominado *abrir puerta*. Este caso de uso tiene dos posibilidades que son: *abrir puerta con llave*, o *abrir puerta con tarjeta lectora*. A la derecha de la figura, en la parte superior puede verse la representación del punto de variación encontrado, que es la cerradura (VP: Variation Point), la cual puede ser de dos tipos, una cerradura con llave o con tarjeta lectora (V: Variants). Entonces, el caso de uso de abrir la puerta puede modelarse como se muestra en la parte inferior de la figura.




Figura 2.11: Ejemplo de modelos de variabilidad (extraída de [9])

2.7. Resumen del capítulo

En este capítulo definimos el concepto de big data junto con su ciclo de vida y brindamos ejemplos de algunas herramientas y técnicas que son utilizadas en las actividades incluidas. Luego describimos el dominio de agricultura de precisión en el cual se basa nuestro trabajo de tesis. Continuando, realizamos un análisis de varios trabajos en la literatura dentro de este dominio que proponen diferentes análisis sobre las cuencas y los niveles freáticos. Por último, describimos los trabajos previos dentro del proyecto de investigación donde se enmarca esta tesis y que serán utilizados en el capítulo siguiente. Específicamente explicamos el significado de la *variedad* y sus tipos, así como los dos enfoques que dan soporte a su identificación. Se describió la herramienta COVAMAT que permite definir, documentar y consultar la variedad de un dominio y que da soporte al desarrollo de casos de dominio promoviendo la reusabilidad.

En el próximo capítulo se describe la aplicación del enfoque T-VIP para el desarrollo de dos casos de dominio dentro de la región del Alto Valle de Río Negro y Neuquén.

Capítulo 3

Aplicación del Enfoque T-VIP en el Dominio de la Agricultura Precisión

En este capítulo describimos la aplicación del enfoque top-down (T-VIP) explicado en el capítulo anterior mediante un caso de estudio que incluye dos casos de dominio dentro de la región del Alto Valle de Río Negro y Neuquén. El caso de estudio se enmarca dentro del dominio de la agricultura de precisión.

3.1. Enfoque T-VIP para el Desarrollo de dos Casos de Dominio basados en Contextos

En la Figura 3.1 mostramos el enfoque T-VIP que involucra los 5 pasos descriptos en el capítulo anterior (Figura 2.10) ahora instanciada para contemplar dos casos de dominio diferentes. Estos casos describen una variedad de contexto, en la que los procesos y activos creados en el primer caso se documentan y son reutilizados en el segundo. Como se observa en la figura, la variedad de contexto es la que incluye la variación mientras que las otras tres se mantienen iguales.

En el *Caso de Dominio 1 - periodo SIN Riego*, se crean activos y casos del dominio en el periodo comprendido entre mayo y agosto. Estos meses, en la zona del Alto Valle, este periodo se corresponde con los meses en que el canal principal de riego permanece inactivo. Esto sucede porque las condiciones productivas (principalmente fruticultura) no demandan un riego constante ya que los cultivos no se encuentran en su periodo vegetativo. En consecuencia, el impacto de las aguas superficiales (provenientes principalmente del Río Negro) sobre el nivel freático resulta diferente en comparación con la época de mayor uso hídrico.

Una vez establecido el marco de análisis en el periodo sin riego, aplicamos nuevamente el enfoque para desarrollar el *Caso de Dominio 2 - periodo CON Riego*, que analiza los datos comprendidos entre septiembre y abril, coincidiendo con la etapa vegetativa de los frutales y la máxima demanda de agua por parte de los cultivos. Durante este lapso, la infraestructura de canales, entra en funcionamiento pleno. En particular, el canal principal de riego, una obra de ingeniería de unos 130 km de longitud, se convierte en la columna vertebral de la red hídrica de la región. Este canal principal, concebido inicialmente para transportar $45 \text{ m}^3/\text{s}$ (aunque actualmente soporta caudales de hasta $60 \text{ m}^3/\text{s}$), abastece a canales secundarios y terciarios. Su traza comienza en las inmediaciones del Dique Ingeniero Rodolfo E. Ballester —anteriormente Dique Contralmirante Cordero—, aprovechando la pendiente natural para distribuir el agua a lo largo del valle. A medida que avanza, bordea el límite nordeste entre el valle y la meseta, desviando el caudal hacia diversas chacras y establecimientos productivos dedicados, sobre todo, a la fruticultura. En su último tramo, el canal ingresa en el sector medio del valle cerca de Villa Regina y concluye en la zona de Chichinales. Podemos observar en la Figura 3.1, en color rojo del

caso de dominio 2, el canal principal que se activa en este periodo. Este segundo caso reutiliza activos del primero y añade nuevas perspectivas y análisis. En particular, se analiza el impacto de los canales de riego activos en este periodo en conjunto con el Río Negro sobre la fluctuación de las napas freáticas en la zona de Villa Regina.




Figura 3.1: Enfoque T-VIP aplicado a dos casos de dominio

A continuación describimos cada uno de los cinco pasos del enfoque T-VIP junto con las actividades que se realizan en cada uno para ambos casos de dominio.

3.1.1. Caso de Dominio 1: periodo sin Riego

Este caso de dominio fue el primero que realizamos por lo que generó la construcción de las hipótesis, su procesamiento y verificación, ya que no existían casos similares dentro del mismo dominio en CoVaMaT. Como el dominio de cobertura es la agricultura de precisión, creamos inicialmente el activo de dominio, al que llamamos *Activo de dominio de Agricultura de Precisión*. A su vez, como definimos una situación de variedad de contexto, creamos dicha variedad para que pueda ser reutilizada en casos futuros. Así, utilizamos la funcionalidad F-1 (*Funcionalidad para documentar variedades*) de CoVaMaT con su proceso P-1 (*Documentar variedad de dominio*), para documentar la variedad de contexto dentro del activo de dominio creado previamente. En la Figura 3.2 mostramos este proceso P-1 con sus cuatro actividades donde se identifica la variedad, se determina su tipo, se ingresa un datasheet y finalmente se almacena. Podemos observar el activo de dominio, en el cual se define una variedad de contexto, mediante un datasheet que posee un nuevo artefacto denominado *periodo sin riego Villa Regina*.




Figura 3.2: Proceso P-1 donde documentamos la variedad de contexto como un nuevo *Activo de dominio de Agricultura de Precisión* en CoVaMaT

Paso 1: Definición de Hipótesis

Para la definición de las hipótesis en este caso de dominio, nos hemos basado en el análisis realizado de los trabajos relacionados de la literatura (capítulo anterior) y la información y conocimiento brindada por los usuarios expertos. En primer lugar, los expertos nos plantearon el requerimiento de conocer si el nivel del Río Negro tiene influencia en la fluctuación de la napa freática, ya que consideran que debería existir una relación directa con la fluctuación de la misma. Por esta razón se planteó la siguiente hipótesis:

- **Hipótesis 1 (H1):** ¿El nivel del Río Negro tiene influencia en la recarga de la napa freática? ¿Qué impacto tiene la distancia entre el río y los freáticos en la variación del nivel de la napa?

Luego, se planteó una hipótesis enfocada en comprobar si es posible obtener un modelo que pueda predecir el nivel de la napa freática con la variable del nivel del Río Negro. De esta manera, la hipótesis propone:

- **Hipótesis 2 (H2):** ¿Se puede predecir en forma eficiente el nivel de la napa freática por cada freático utilizando la variable del nivel del Río Negro?

Al mismo tiempo, los expertos nos plantearon la necesidad de considerar las variables climáticas dentro del estudio. Es decir, analizar su influencia en la fluctuación del nivel de la napa y su relevancia en comparación con el nivel del Río Negro. Así, planteamos la tercera hipótesis:

- **Hipótesis 3 (H3):** ¿Cuales son las variables climáticas que tienen mayor-menor influencia que el nivel del Río Negro en la fluctuación del nivel freático?

Finalmente, se planteó la idea de poder crear un modelo para predecir la fluctuación de la napa con las variables climáticas más influyentes:

- **Hipótesis 4 (H4):** De acuerdo a los resultados obtenidos en las hipótesis anteriores ¿Se puede predecir el nivel de la napa freática por cada freático en la zona de estudio considerando únicamente las variables climáticas?

De esta forma en la Figura 3.1 podemos observar las 4 hipótesis generadas, las cuales deben ser procesadas en los pasos 2 y 3.

Pasos 2 y 3: Procesamiento de las Hipótesis

Aquí tomamos las cuatro hipótesis definidas (como analistas de datos) y llevamos a cabo todas las actividades involucradas (Figura 3.1). A continuación describimos cada una de ellas.

Proceso de Big Data: Actividad Colección

El conjunto de datos utilizado se obtuvo de tres fuentes diferentes: 1) la estación hidrométrica 1808 - Río Negro - Paso Córdova, 2) freatímetros ubicados en la zona de Villa Regina, y 3) la estación meteorológica Villa Regina.

Los datos del nivel del Río Negro (1) fueron proporcionados por la *estación hidrométrica 1808 - Río Negro - Paso Córdova* que se encuentra aproximadamente a 50 km río arriba de la zona de estudio. Según los expertos en el dominio, el río no tiene afluentes en este tramo, por lo tanto es válido utilizar las medidas obtenidas en la estación para realizar este estudio. La estación toma registros en forma diaria, y para este caso seleccionamos los valores desde el 01 de enero de 2010 al 31 de Diciembre del 2023; lo que equivale a un total de 5112 registros de datos semiestructurados con formato de texto. Este conjunto de datos posee 4 variables: *fecha*, *altura*, *cota IGN* y *cota IGN corregida*¹. En topografía, la cota es la distancia vertical entre un punto del terreno y un plano de referencia horizontal, generalmente el nivel del mar. La cota corregida se refiere a la cota ajustada teniendo en cuenta factores como errores de medición o cambios en el plano de referencia. La diferencia entre la cota y la cota corregida es que ésta última proporciona una medida más precisa y ajustada del terreno, eliminando posibles errores o desviaciones.

Luego, los datos proporcionados del nivel de la napa freática de Villa Regina (2) se obtienen de 77 freatímetros. Los freatímetros son registrados mensualmente por los colaboradores del INTA, y en este caso, tomamos los valores registrados en el periodo 2010 al 2023, lo que equivale a un total de 168 registros de datos por freatímetro. Estos datos son del tipo semi-estructurados y poseen 4 variables: un *identificador único* de freatímetro, *cota*, *mes* y *altura* de la napa en metros.

Por último, los datos de las variables climáticas (3) se obtienen de la estación meteorológica de Villa Regina, ubicada en la misma localidad. Este conjunto de datos cuenta con 33 variables climáticas. En total, el periodo de datos abarca desde 2010 hasta 2023, acumulando 520715 registros. Estos datos son del tipo semiestructurado y se presentan en formato de texto.

Finalmente y para concluir con esta actividad, utilizamos el proceso P-1 (*Documentar variedad de dominio*) de CoVaMaT para documentar la variedad de las fuentes dentro del *Activo de dominio de Agricultura de Precisión* creado previamente. En este caso, como podemos observar en la Figura 3.3, el proceso P-1 crea una nueva fuente de *datos semi-estructurados* proveniente de la *estación meteorológica de Villa Regina*, la *estación 1808 - Río Negro - Paso Córdova* y los datos de los *Freatímetros Villa Regina*.

Proceso de Big Data: Actividad Preparación

En esta actividad, considerando las hipótesis definidas, analizamos la información de las tres fuentes de información provistas. En primer lugar, abordamos la ubicación de los freatímetros en el área de estudio. A partir de la segunda fuente (registros del nivel de la napa), seleccionamos los freatímetros que se encuentran en la zona comprendida entre el Río Negro y un límite de 2 km de distancia desde su cauce (criterio que se adoptó por sugerencia de los expertos en el dominio). De esta manera, se seleccionaron 19 freatímetros que cumplieran con este criterio². Al mismo tiempo, en base a estos 19 freatímetros, establecimos un criterio de aceptación para los valores nulos. Si estos valores superaban un año de ausencia de datos, el freatímetro se descartaba del estudio. Como resultado, se eliminaron 4 freatímetros del conjunto inicial, quedando 15.

¹cota y la cota corregida miden la altura sobre el nivel medio del mar

²La selección se llevó a cabo con la ayuda del sistema Q-GIS (<https://www.qgis.org/>)




Figura 3.3: Proceso P-1 donde documentamos la variedad de las fuentes dentro del *Activo de dominio de Agricultura de Precisión* en CoVaMaT

Posteriormente, realizamos una tarea de estructuración y transformación de datos, dado que el conjunto original se encontraba en formato de texto y era necesario convertirlo a valores decimales. Además, el valor medido en metros de los freaímetros se convirtió en *msnm* con el objetivo de poder comparar gráficamente el nivel de la napa con el nivel del Río Negro. La Tabla 3.1 muestra las tres variables finales del conjunto de datos. En la misma podemos observar el *nombre*, la *descripción* y el *tipo* de las variables.

Nombre	Descripción	Tipo
freatímetro	Identificador unívoco	Numérico
nivelfreatímetro	Medido en <i>msnm</i>	Numérico
Fecha	Mensual	Fecha (Date)

Tabla 3.1: Descripción de las variables utilizadas en el conjunto de datos de los freaímetros.

Después de estas transformaciones y del primer filtrado de datos nulos, analizamos los valores faltantes dentro de los 15 freaímetros seleccionados. Se detectaron un total de 508 valores nulos. Para completar estos datos utilizamos la técnica *IterativeImputer* debido al comportamiento de fluctuación similar entre pozos a lo largo del tiempo, indicando que existe una correlación entre ellos. Como describimos en el capítulo anterior, esta técnica genera un modelo de regresión para predecir los valores faltantes de una columna objetivo en función de las demás columnas. Por ejemplo, las Tablas 3.2 y 3.3 muestran un extracto del conjunto de datos de los freaímetros antes y después de la imputación de los valores nulos, respectivamente. En ellas podemos observar que cada columna representa un *freatímetro* y cada fila el *nivelfreatímetro* registrado en cada fecha. Luego, en la Tabla 3.2 (antes de la imputación), se puede observar (en color amarillo) que en la fecha 2010-01-01 no se registraron valores para el *freatímetro* 60947, ya que figura como *Nulo*. Una vez aplicada la técnica, en la Tabla 3.3 podemos observar (en color verde) que el valor faltante fue completado con 198.91. Este número surge de la estimación que realiza *IterativeImputer* al ajustar un modelo de regresión entre la columna del *freatímetro* 60947 (como variable *Y*) y las demás columnas (otros freaímetros y fecha, como variables *X*). De esta manera, la técnica “aprende” cómo predecir la columna faltante a partir del comportamiento de las otras y rellena el valor nulo.

Este mismo procedimiento se realizó para todas las columnas donde inicialmente había valores

nulos, garantizando así la completitud del conjunto de datos.

Fecha	60040	60075	60160	60300	60440	60947
2010-01-01	191.43	192.02	194.18	195.25	197.18	Nulo
2010-02-01	191.52	191.99	194.07	195.13	197.48	Nulo
2010-03-01	191.71	192.56	Nulo	195.45	196.58	Nulo
2010-04-01	191.59	192.54	193.45	195.75	196.93	Nulo
2010-05-01	191.39	192.27	194.09	195.98	196.57	198.53
2010-06-01	191.34	191.78	193.47	194.74	196.04	Nulo
2010-07-01	191.16	191.87	192.91	194.65	195.95	Nulo

Tabla 3.2: Valores de los freátímetros antes de la imputación.

Fecha	60040	60075	60160	60300	60440	60947
2010-01-01	191.43	192.02	194.18	195.25	197.18	198.91
2010-02-01	191.52	191.99	194.07	195.13	197.48	198.74
2010-03-01	191.71	192.56	193.93	195.45	196.58	198.59
2010-04-01	191.59	192.54	193.45	195.75	196.93	198.88
2010-05-01	191.39	192.27	194.09	195.98	196.57	198.53
2010-06-01	191.34	191.78	193.47	194.74	196.04	198.46
2010-07-01	191.16	191.87	192.91	194.65	195.95	198.30

Tabla 3.3: Valores de los freátímetros después de la imputación.

Posteriormente, se validó el rendimiento predictivo de la imputación mediante validación cruzada con 5 folds. Como describimos en capítulo anterior esta técnica evalúa un modelo dividiendo los datos en varios subconjuntos de entrenamiento y prueba. Para evaluar la precisión de la técnica *IterativeImputer*, utilizamos el MAE y el coeficiente de determinación (R^2) como métricas principales. Los resultados obtenidos fueron:

- **MAE:** 1.6001 (msnm)
- **R^2 :** 0.8854 %

Estos valores indicaron que la imputación logró completar los datos faltantes con un margen de error aceptable, manteniendo la coherencia con el comportamiento general de los freátímetros. Por lo tanto, se consideró que el uso de *IterativeImputer* resultó adecuado y no introdujo distorsiones significativas en los datos originales.

Al finalizar el proceso, el conjunto de datos completó todos sus valores faltantes imputados. A este conjunto de datos lo denominamos *freatímetroCotaCompleto*.

Continuando, para la primera fuente de datos (nivel del río), realizamos también algunas actividades de preparación. Como describimos previamente, el nivel del río se mide diariamente, es decir, el conjunto de datos tiene un registro para cada día de cada año. Por tal motivo, se decidió cambiar la escala de días a meses en el conjunto de datos original, con el objetivo de poder unificar este conjunto de datos con el creado previamente.

Para realizar dicho cambio, calculamos el promedio del nivel del Río Negro por cada mes a lo largo de los años del periodo seleccionado para este estudio (2010-2023). Como se puede observar en la Tabla 3.4, obtuvimos un nuevo conjunto de datos al que llamamos *nivelRíoPromedio*. Para unificar este nuevo conjunto con el conjunto *freatímetroCotaCompleto* utilizamos como conector la variable *Fecha*.

Para la tercera fuente de datos partimos del conjunto inicial de 33 variables climáticas registradas por la estación meteorológica ubicada en Villa Regina. Para poder trabajar mejor el

Fecha	Año	Mes	nivelRio
2010-01-01	2010	1	236.547742
2010-02-01	2010	2	236.556429
2010-03-01	2010	3	236.584839
2010-04-01	2010	4	236.864667
2010-05-01	2010	5	236.280645
...	...	...	...
2023-08-01	2023	8	237.838065
2023-09-01	2023	9	237.681000
2023-10-01	2023	10	237.171935
2023-11-01	2023	11	237.076657
2023-12-01	2023	12	236.856452

Tabla 3.4: Promedios mensuales de altura de General Roca a lo largo de los años (Conjunto de Datos *nivelRíoPromedio*).

análisis del nivel freático, decidimos reducir ese conjunto y quedarnos solo con las variables más importantes. Esta selección se hizo combinando criterios metodológicos, la revisión de trabajos anteriores y el asesoramiento de los expertos en el dominio.

En primer lugar, se descartaron aquellas variables que no aportaban información útil para el estudio. Por ejemplo, las variables *Dirección del viento (Wind Dir)* y *Dirección de ráfagas máximas (Hi Dir)* fueron eliminadas debido a que, según los especialistas consultados, no se espera una relación directa entre la dirección del viento y las fluctuaciones del nivel de la napa freática. Asimismo, la variable *Hora (Time)*, que indica el horario específico de cada medición, no aporta valor adicional al análisis temporal, ya que el estudio se basa en valores agregados mensuales donde la variable *Fecha (Date)* es suficiente. También se excluyó la variable *Intervalo de archivado (Arc. Int.)*, que señala cada cuánto tiempo se almacenan los datos. Esta variable no representa un fenómeno físico que afecte directamente el nivel freático y, por lo tanto, no contribuye de forma significativa al análisis.

De esta forma, tras aplicar estos criterios, se seleccionaron 14 variables que fueron consideradas para los objetivos del estudio. Estas variables se pueden observar en la Tabla 3.5. El conjunto final representa un resumen de los factores climáticos más relevantes para analizar la relación con el nivel freático. Cabe destacar que este conjunto de datos definitivo fue completado con sus valores faltantes utilizando la técnica *KNNImputer*, con un valor de $k = 1$.

Una vez completados los datos, calculamos el promedio mensual de cada variable, agrupando por año y mes como se puede observar en la Tabla 3.6. Cabe aclarar que en la tabla se muestran solo algunas de las 14 variables seleccionadas, a modo de ejemplo para ilustrar el resultado del cálculo de los promedios mensuales. Este paso permite integrar este conjunto con los conjuntos previos bajo el mismo formato de registro. A este nuevo conjunto de datos lo denominamos *promedio_mensual_clima*.

De esta forma, en la actividad de preparación de los datos hemos generado tres conjuntos de datos: *freatímetroCotaCompleto*, *nivelRíoPromedio*, y *promedio_mensual_clima*.

Por último, volvimos a utilizar CoVaMaT pero ahora para registrar la *variedad de contenido* y la *variedad de proceso*. Como podemos observar en la Figura 3.4, el proceso P-1 permite documentar dichas variedades y almacenarlas, como parte del *Activo de dominio de Agricultura de Precisión*. Las tres primeras datasheets registran las 14 variables climáticas, las 3 variables de los freáticos y las 4 variables del caudal del río. A su vez, en el activo de *variedad de proceso* documentamos las técnicas y procedimientos utilizados para identificar y tratar valores atípicos, nulos y sobreajuste.

Variable (Inglés)	Traducción (Español)	Tipo
Date	Fecha	Date
Temp Out	Temperatura Exterior	Numérica
Hi Temp	Temperatura Máxima	Numérica
Low Temp	Temperatura Mínima	Numérica
Out Hum	Humedad	Numérica
Dew Pt.	Punto de Rocío	Numérica
Wind Speed	Velocidad del Viento	Numérica
Hi Speed	Velocidad Máxima del Viento	Numérica
Rain	Precipitación Acumulada	Numérica
Rain Rate	Tasa de precipitación	Numérica
Solar Rad.	Radiación Solar	Numérica
Solar Energy	Energía Solar Acumulada	Numérica
ET	Evapotranspiración	Numérica
Wind Chill	Sensación Térmica	Numérica

Tabla 3.5: Variables climáticas seleccionadas para el análisis del nivel freático.

Date	Temp Out	Hi Temp	Low Temp	Out Hum	Dew Pt.
2010-01	15.53	15.71	15.36	51.05	3.83
2010-02	13.98	14.16	13.80	54.52	3.50
2010-03	16.24	16.41	16.06	55.32	6.07
2010-04	12.80	12.94	12.65	58.89	3.78
2010-05	9.54	9.69	9.38	67.05	2.76
2010-06	10.75	10.90	10.61	61.89	2.69
2010-07	7.85	8.02	7.69	54.16	-1.76

Tabla 3.6: Promedio mensual de variables climáticas (Conjunto de Datos *promedio_mensual_clima*).




Figura 3.4: Proceso P-1 donde documentamos la variedad de contenido como activo de dominio de Agricultura de Precisión en CoVaMaT

Proceso de Big Data: Actividad Analítica

En esta actividad y a través de una serie de análisis, exploramos los conjuntos de datos con el objetivo de validar las hipótesis. Considerando la primera hipótesis ($H1$), la cual postulaba:

- **Hipótesis 1 ($H1$): ¿El nivel del Río Negro tiene influencia en la recarga de la napa freática? ¿Qué impacto tiene la distancia entre el río y los freatímetros en la variación del nivel de la napa?**

Para analizar si el nivel del Río Negro influye en la recarga de la napa freática, empleamos los conjuntos de datos: *freatímetroCotaCompleto* y *nivelRíoPromedio*.

Comenzamos con un análisis visual preliminar para comparar el comportamiento del Río Negro y la napa freática, utilizando gráficos que muestran sus fluctuaciones en el periodo sin riego. En la Figura 3.5 graficamos la fluctuación de los 15 freatímetros con respecto a la napa en dicho periodo. En cada gráfico, el eje horizontal (x) se toma el periodo sin riego compuesto por los meses de mayo, junio, julio y agosto desde el año 2010 a 2023³, mientras que el eje vertical (y) muestra los valores registrados para cada variable ($msnm$). Cada serie de cada gráfico representa, en azul, la variación del nivel del río, y en verde el nivel de la napa. En los gráficos a simple vista se puede observar un comportamiento similar en algunos casos entre los diferentes freatímetros. Por ejemplo, se pueden observar los freatímetros 62053 (fila 5, columna 3) y 60610 (fila 3, columna 1) un comportamiento similar entre ambos niveles. Este comportamiento indicaría que las fluctuaciones del río tienen un impacto en la dinámica de la napa. Por otro lado, en los freatímetros 61271 (fila 5, columna 1) y 60040 (fila 1, columna 1), no se observa relación entre los niveles.

Como segundo paso y para profundizar lo observado, realizamos un nuevo análisis para evaluar la asociación entre las variables involucradas. Como se observa en la Figura 3.6 hemos utilizado las técnicas de correlación Spearman, Kendall y Pearson. La figura muestra un mapa de calor donde cada fila corresponde a un freatímetro y cada columna a la técnica de correlación utilizada. Luego, el color en cada celda refleja cuán estrechamente están relacionados las dos variables. Los tonos más intensos (por ejemplo, azules más oscuros) representan correlaciones más fuertes (cerca de 1 o -1), mientras que colores más claros indican correlaciones más débiles (cerca de 0). Por ejemplo, podemos observar en los resultados de la correlación de Pearson que el freatímetro 62053 (fila 1) tiene la correlación más alta (0.61), lo que sugiere una relación lineal moderada positiva entre el nivel del río y este freatímetro. Los siguientes freatímetros, como 60610 y 60460 muestran una relación positiva moderada con valores de 0.41 y 0.37 respectivamente (Pearson). Por otro lado, los freatímetros 60300 y 61383 tienen correlaciones muy próximas a 0, lo que sugiere una débil o incluso nula relación lineal.

Por otro lado, podemos observar que la técnica de Spearman muestra resultados bastante cercanos a Pearson lo que indica que la relación entre el nivel del río y los freatímetros es tanto lineal como monotónica. Con la técnica de Kendall la correlación sigue siendo positiva para el freatímetro 62053 (0.43), pero la magnitud es menor que en las técnicas anteriores. Podemos observar que en general, los valores de Kendall son generalmente más bajos en comparación con Pearson y Spearman, lo que podría sugerir una relación más débil o menos uniforme en el orden de los datos. Esto quiere decir que a veces, cuando el nivel del río sube, el valor del freatímetro no sigue el mismo patrón de aumento, y viceversa. De la comparación de las 3 técnicas, los freatímetros 62053, 60610, y 60460 son los más fuertemente correlacionados con el nivel del río, sugiriendo una dependencia del nivel freático en estas ubicaciones con respecto al comportamiento del río. En los últimos freatímetros de la Figura 3.6 (60300, 61383 y 60040), la correlación es prácticamente nula o negativa, lo que indica que el nivel del río no tiene una influencia significativa sobre ellos.

³Serían 156 meses en 13 años




Figura 3.5: Comparación del nivel del Río Negro y las mediciones en distintos freatímetros.

En conclusión, la consistencia entre los resultados de Pearson y Spearman refuerza que la relación es tanto lineal como monótonica para la mayoría de los freatímetros más correlacionados. Sin embargo, los valores más bajos en Kendall pueden sugerir que, en algunos casos, la relación no es tan estrictamente ordenada o sigue patrones más complejos.



Figura 3.6: Resultados del análisis de correlación para el Conjunto de Datos *freatímetroCota-Completo* y *nivelRíoPromedio* utilizando los técnicas de Pearson, Spearman y Kendall

Luego para comprender mejor los valores obtenidos previamente, analizamos el impacto de la correlación con respecto a la distancia de los freatímetros con el río. El mapa de la Figura 3.7 presenta una muestra de la distribución espacial de los freatímetros, los cuales hemos categorizado en tres grupos de acuerdo con su nivel de correlación. Los colores utilizados significan: verde (correlación fuerte) mayor a $|0.5|$, amarillo (correlación moderada) entre $|0.5|$ y $|0.2|$ y rojo (correlación baja) entre $|0.2|$ y 0. Además, consideramos la distancia de cada freatímetro al río como un factor importante en la interacción entre el acuífero y el río. De esta forma, se puede identificar una tendencia donde los puntos con correlación fuerte (verde) y moderada (amarillo) son los mas cercanos al río entre (0-250 m) y (250-900 m), mientras que los más alejados (900-2000 m) suelen tener correlaciones más bajas (rojo). Esto sugiere que la influencia del río sobre el nivel freático disminuye a medida que aumenta la distancia.

Para un análisis más detallado, creamos la Tabla 3.7, que contiene tres columnas: identificador numérico de los freatímetros, valor de la correlación de Pearson obtenida entre el nivel del río y la napa, y distancia entre el cauce del Río Negro y cada freatímetro. La tabla está ordenada según la distancia, desde la más cercana hasta la más lejana, entre el río y cada freatímetro.

Podemos observar que el freatímetro 62053 ubicado a una distancia aproximada de 250 metros del río (resaltado en verde), posee la correlación más alta y positiva (0.61). Este resultado sugiere




Figura 3.7: Representación de los freátímetros con un código de colores según su distancia al río: verde = correlación fuerte, amarillo = correlación intermedia y rojo = correlación débil o nula.

Freatímetro	Correlación	Distancia (m)
62053	0.6100	250
60075	0.2300	350
60610	0.4100	400
61250	0.3300	600
61383	-0.0300	600
60460	0.3700	700
60933	0.2000	900
60947	0.1500	1200
60040	-0.0940	1350
60440	0.1400	1550
60300	-0.0068	1600
60955	0.2700	1900
60771	0.1900	1900
60160	0.3200	2000
61271	0.0480	2000

Tabla 3.7: Correlación entre el nivel del río y la napa freática según la distancia al río, con colores indicativos de rangos de correlación: verde (fuerte), amarillo (moderada), y rojo (débil).

una conexión directa entre el nivel del río y la napa en áreas cercanas, donde las fluctuaciones del nivel del río tienen un impacto inmediato en el nivel freático. Luego, observamos que a medida que la distancia aumenta, las correlaciones comienzan a disminuir. En el rango intermedio entre 250 y 900 metros, la mayoría de las correlaciones aún son moderadas valores entre $|0.5|$ y $|0.2|$ (amarillo). Por ejemplo, el freátmetro 60460, a 700 metros, muestra una correlación de 0.37, y el 60933, a 900 metros, mantiene una correlación de 0.2. Luego, la influencia del río parece diluirse progresivamente con la distancia.

Sin embargo, se detectaron excepciones que rompen con la tendencia esperada en esta franja. El freátmetro 61383, ubicado a 600 m, presenta una correlación negativa (-0.0300), lo que sugiere que en este punto no hay una relación directa entre el nivel del río y el nivel freático.

En distancias superiores a 900 metros (resaltado en rojo en su mayoría), la correlación se debilita significativamente. Por ejemplo, el freátmetro 60040, a 1350 metros, muestra una correlación de -0.0940, lo que indica una relación prácticamente nula. De manera similar, en distancias de 2000 metros, como en el caso del freátmetro 61271, la correlación es débil, con un valor de 0.0480 respectivamente. Esto refleja que, a mayores distancias, la influencia directa del río en el nivel freático es menor, posiblemente debido a factores como la topografía, características del acuífero, o barreras hidráulicas naturales.

En la franja de 900 a 2000 m, se identificaron dos excepciones notables que presentan correlaciones moderadas, a pesar de la distancia al río. El freátmetro 60955 (1900 m) muestra una correlación de 0.2700, lo que indica que aún mantiene una cierta conexión con el río. Por su parte, el freátmetro 60160 (2000 m) presenta una correlación de 0.3200, superior a lo esperado para esta distancia.

En conclusión, los datos sugieren que la proximidad al río es un factor importante en la intensidad de la correlación entre los niveles del río y la napa freática pero no el único. Las zonas cercanas presentan conexiones más fuertes y directas, mientras que las áreas más alejadas experimentan una relación más débil o casi inexistente. Este análisis destaca la importancia de la distancia entre el río y los freátmetros para comprender la interacción entre aguas superficiales y subterráneas. De esta forma, aunque se evidenció una relación entre el nivel del río y el nivel freático, esta no fue uniforme en toda la región. Por ello, en los siguientes pasos evaluaremos si el nivel del Río Negro, considerado como única variable, es capaz de predecir de manera eficiente el comportamiento de cada freátmetro.

Considerando la segunda hipótesis ($H2$), la cual postulaba:

- **Hipótesis 2 ($H2$): ¿Se puede predecir en forma eficiente el nivel de la napa freática por cada freátmetro utilizando la variable del nivel del Río Negro?**

Para abordar esta hipótesis, utilizamos los dos mismos conjuntos de datos que en la primera hipótesis: *freatmetroCotaCompleto* y *nivelRioPromedio*. Luego, seleccionamos los meses correspondientes al periodo sin riego (mayo, junio, julio y agosto) desde 2010 hasta 2022. Finalmente, los datos de 2023 fueron reservados para validar las predicciones del modelo con valores reales, con el objetivo de evaluar su capacidad de generalización y precisión en la estimación del nivel freático. Dado que este nivel es una variable que fluctúa en el tiempo, implementamos un modelo de red neuronal LSTM. Como vimos en el capítulo anterior, este modelo es capaz de capturar patrones a largo plazo en los datos y son una buena opción para resolver problemas de predicción de secuencias de series de tiempo.

Para construir el modelo LSTM, utilizamos únicamente el nivel del Río Negro como variable de entrada, junto con el identificador de cada freátmetro como variable categórica, lo que permite que el modelo diferencie entre los distintos puntos de medición. La variable de salida fue el nivel de la napa freática, permitiendo al modelo aprender la relación entre ambos niveles a lo largo del tiempo. A su vez, como LSTM requiere datos secuenciales, organizamos las observaciones en ventanas de tiempo de 4 meses, utilizando los meses de mayo, junio, julio y agosto de cada

Hiperparámetros	Valor
Tamaño del lote	16
Número de épocas	200
Tasa de aprendizaje	0.001
Función de activación (LSTM)	tanh
Tasa de abandono (LSTM)	0.3
Optimizador	Adam

Tabla 3.8: Hiperparámetros utilizados en el modelo LSTM.

año. Con esta estructura, el modelo aprende a predecir el nivel freático en función de los 4 meses anteriores.

Para evaluar su desempeño, se dividieron los datos en 80 % entrenamiento y 20 % prueba, dejando el año 2023 exclusivamente para validación con valores reales no utilizados en el entrenamiento. Para analizar y crear los modelos, configuramos la red neuronal de tres formas diferentes. A continuación describimos cada una de ellas⁴.

Primera configuración de la red neuronal LSTM. En esta primera configuración usamos una arquitectura de dos capas LSTM. La primera capa LSTM tiene 128 neuronas (o nodos) y mantiene la secuencia de salida para la siguiente capa LSTM, que cuenta con 64 neuronas (o nodos). Ambas utilizan la función de activación tanh con una tasa de abandono del 30 % para reducir el riesgo de sobreajuste.

Para mejorar la estabilidad del modelo, empleamos el optimizador Adam con una tasa de aprendizaje de 0.001. Además, utilizamos detención temprana, configurado para detener el entrenamiento si la pérdida de validación no mejora en 15 épocas consecutivas, restaurando los mejores pesos obtenidos hasta ese momento. El entrenamiento lo realizamos con un tamaño de lote de 16 y un máximo de 200 épocas. En la Tabla 3.8 se presenta un resumen de los principales hiperparámetros utilizados en este modelo.

Para evaluar el desempeño del modelo, utilizamos las siguientes cuatro métricas que nos devolvieron los resultados:

- MSE: 0.0465
- MAE: 0.1540
- R²: 0.9561
- RMSE: 0.8279

Los mismos muestran que el modelo tiene una buena capacidad predictiva, dado que el coeficiente R² es de 0.9561, lo que sugiere que el modelo explica el 95.61 % de la variabilidad en los datos. Asimismo, los valores de MSE, MAE y RMSE son bajos, lo que indica que las predicciones se acercan bastante a los valores reales. La Tabla 3.9 presenta una comparación entre los valores predichos (tercera columna) y los valores reales (cuarta columna) observados en mayo de 2023 para los 15 freatímetros analizados. Cabe recordar que los datos del año 2023 no fueron utilizados en el entrenamiento del modelo, sino que se reservaron con el propósito de realizar una validación real de la capacidad predictiva. Como podemos observar, los valores predichos por el modelo LSTM presentan una alta coincidencia con los valores reales, con diferencias mínimas en la mayoría de los freatímetros. Por ejemplo, en los freatímetros 60040, 60075 y 60440, la predicción es muy cercana a los valores reales, con un margen de error muy bajo. Para otros freatímetros,

⁴Se utilizaron las librerías *TensorFlow* <https://www.tensorflow.org/?hl=es-419> y *Keras* <https://keras.io/> para implementar el modelo LSTM

Freatímetro_ID	Fecha	Nivel Freático Predicho (<i>msnm</i>)	Nivel Freático Real (<i>msnm</i>)
60040	2023-05	191.23	191.33
60075	2023-05	192.22	191.64
60160	2023-05	193.45	192.87
60300	2023-05	194.88	194.75
60440	2023-05	196.23	196.21
60460	2023-05	197.24	197.10
60610	2023-05	198.07	196.67
60771	2023-05	199.09	199.51
60933	2023-05	199.04	200.30
60947	2023-05	200.12	199.14
60955	2023-05	201.52	202.12
61250	2023-05	202.19	202.08
61271	2023-05	202.77	203.38
61383	2023-05	203.25	203.94
62053	2023-05	190.53	190.05

Tabla 3.9: Comparación entre valores predichos y valores reales no utilizados en el entrenamiento de la LSTM, mayo de 2023.

como 60933 y 61271, hay una diferencia entre el valor real y la predicción, aunque sigue siendo pequeña en términos absolutos. En general, la precisión de las predicciones es aceptable para esta primera configuración, lo que confirma la efectividad del modelo LSTM en la tarea de pronosticar el nivel freático a partir del nivel del Río Negro.

En la Figura 3.8 observamos la comparación entre los valores predichos y los valores reales del nivel freático (en *msnm*) a lo largo de las muestras. La línea azul continua representa los valores reales del nivel freático y la línea naranja punteada muestra las predicciones generadas por el modelo LSTM. Como podemos observar, el modelo ha logrado realizar una buena predicción del nivel freático, reflejando tendencias y variaciones con un error relativamente bajo. Sin embargo, en eventos de cambios abruptos, las predicciones pueden mostrar un ligero desfase o no captar la magnitud exacta de las fluctuaciones.

Este análisis sugiere que el modelo es aceptable, aunque podría beneficiarse de ajustes en los hiperparámetros o la inclusión de más variables para mejorar la captura de eventos específicos. En búsqueda de esta mejora planteamos la segunda configuración de la LSTM.

Segunda Configuración de la red neuronal LSTM. En esta segunda configuración (Tabla 3.10), realizamos ajustes en algunos hiperparámetros, con el objetivo de mejorar su capacidad predictiva. En particular, optimizamos la tasa de aprendizaje, el número de unidades en las capas LSTM (256 en la primera capa y 128 en la segunda) y el tamaño del lote, manteniendo otros parámetros como la función de activación y el optimizador sin cambios.

Hiperparámetros	Valor
Tamaño del lote	32
Número de épocas	200
Tasa de aprendizaje	0.0005
Función de activación (LSTM)	tanh
Tasa de abandono (LSTM)	0.3
Optimizador	Adam

Tabla 3.10: Hiperparámetros utilizados en la segunda configuración del modelo LSTM.

Tras entrenar el modelo con estos ajustes, obtuvimos los siguientes resultados:

- MSE: 0.0387




Figura 3.8: Comparación entre valores reales (azul) y predicciones del modelo LSTM (naranja) para el nivel freático.

- MAE: 0.1421
- R^2 : 0.9634
- RMSE: 0.8250

Estos valores reflejan una mejora respecto a la configuración anterior, reduciendo el MSE de 0.0465 a 0.0387 y el MAE de 0.1540 a 0.1421. Esto indica que el modelo ha logrado aumentar su precisión en la estimación del nivel freático, lo que sugiere que los ajustes contribuyeron a la mejora del rendimiento.

Para validar el modelo, comparamos los valores predichos y los valores reales correspondientes al mes de mayo de 2023 para cada freatímetro (Tabla 3.11). Se destaca que el modelo logra capturar la tendencia del nivel freático con un margen de error relativamente bajo. La mayoría de las predicciones presentan diferencias menores a un metro con respecto a los valores reales, lo que indica un buen desempeño general del modelo.

Como se observa en la Figura 3.9, la segunda configuración permitió mejorar la captura de las relaciones entre el nivel del río y el nivel freático. Se aprecia que la curva de predicción (línea punteada naranja) se ajusta más estrechamente a los valores reales, lo que indica una mejor capacidad del modelo para generalizar sobre los datos de prueba y realizar predicciones más precisas.

A pesar de que los resultados obtenidos con esta configuración mostraron mejoras en la precisión del modelo, aún existen pequeñas diferencias entre los valores predichos y los valores reales, lo que sugiere que podrían implementarse nuevas optimizaciones. Así generamos una tercera configuración del modelo.

Tercera Configuración de la red neuronal LSTM. En esta configuración (Tabla 3.12), agregamos una capa adicional de LSTM con 64 unidades, manteniendo las dos capas previas con 256 y 128 unidades respectivamente y modificamos la tasa de aprendizaje. El objetivo de esta modificación fue capturar mejor las dependencias temporales en los datos e intentar mejorar la capacidad predictiva del modelo. Se conservó el tamaño del lote.

Freatímetro_ID	Nivel Freático Predicho (<i>msnm</i>)	Nivel Freático Real (<i>msnm</i>)
60040	191.2200	191.332
60075	192.3200	191.635
60160	193.6300	192.870
60300	194.9600	194.752
60440	196.3909	196.210
60460	197.1000	197.098
60610	197.9000	196.670
60771	198.8800	199.510
60933	199.6900	200.300
60947	200.4799	199.145
60955	201.2599	202.117
61250	201.9799	202.0755
61271	202.6100	203.3576
61383	203.1799	203.9349
62053	190.4499	190.005

Tabla 3.11: Comparación entre los valores predichos y los valores reales del nivel freático en mayo de 2023.




Figura 3.9: Comparación entre valores reales (azul) y predicciones del modelo LSTM (naranja) para el nivel freático en la segunda configuración.

Hiperparámetros	Valor
Tamaño del lote	32
Número de épocas	200
Tasa de aprendizaje	0.001
Función de activación (LSTM)	tanh
Tasa de abandono (LSTM)	0.3
Optimizador	Adam

Tabla 3.12: Hiperparámetros utilizados en la tercera configuración del modelo LSTM.

Tras entrenar el modelo con estos ajustes, obtuvimos los siguientes resultados:

- MSE: 0.0440
- MAE: 0.1531
- R^2 : 0.9585
- RMSE: 0.8793

Comparando estos resultados con la segunda configuración, observamos que el MSE y el MAE han aumentado ligeramente, lo que indica un leve deterioro en la precisión del modelo. El coeficiente de determinación (R^2) también ha disminuido, lo que sugiere que el modelo no ha logrado una mejora significativa con la capa adicional de LSTM.

Nuevamente, para validar el desempeño, comparamos las predicciones del modelo con los valores reales del nivel freático en mayo de 2023 para cada freatímetro. A pesar de que el modelo siguió proporcionando predicciones aceptables, la tercera configuración no logró una mejora significativa en comparación con la segunda. De hecho, en algunos freatímetros se observan aumentos en la diferencia entre los valores predichos y los valores reales, lo que sugiere que la adición de una capa extra de LSTM podría haber introducido una mayor complejidad sin una ganancia clara en precisión. Por ejemplo, como se observa en la Tabla 3.13 en el freatímetro 60610, la diferencia entre el valor real y la predicción aumentó de 1.23 msnm en la segunda configuración (197.90 predicho vs. 196.67 real) a 1.55 msnm en la tercera configuración (198.22 predicho vs. 196.67 real). Del mismo modo, en el freatímetro 60947, el error pasó de 1.33 msnm (200.48 predicho vs. 199.145 real en la segunda configuración) a 1.43 msnm en la tercera (200.58 predicho vs. 199.145 real).

Como se observa en la Figura 3.10, con los tres gráficos juntos de cada configuración, vemos que en la (c) la adición de una tercera capa LSTM no produjo una mejora significativa en la capacidad del modelo para ajustarse a los datos reales. De hecho, los valores predichos presentan un error mayor en comparación con la segunda configuración (b), lo que indica que agregar más capas LSTM no siempre mejora el rendimiento, y podría haber introducido un sobreajuste en los datos de entrenamiento.

Aunque la tercera configuración incorporó una mayor profundidad en la arquitectura del modelo, los resultados indican que no mejoró el desempeño en comparación con la segunda configuración. Esto sugiere que el modelo puede haber alcanzado un punto de saturación en la cantidad de capas necesarias para capturar la relación entre el nivel del río y el nivel freático.

Al mismo tiempo, en la Tabla 3.14 mostramos los resultados de las evaluaciones de las tres configuraciones diferentes del modelo LSTM. Podemos observar que la segunda configuración se perfila como la mejor opción para predecir el nivel freático. Presenta el menor error en todas las métricas, lo que sugiere que su estructura de dos capas LSTM (256 y 128 unidades) con una tasa de aprendizaje de 0.0005 logra el mejor equilibrio entre complejidad y generalización.

Los resultados muestran que es posible lograr un modelo predictivo eficiente utilizando únicamente el nivel del Río Negro como variable de entrada. Sin embargo, las diferencias entre las

Freatímetro_ID	Nivel Freático Predicho (msnm)	Nivel Freático Real (msnm)
60040	191.4700	191.332
60075	192.5899	191.635
60160	193.8399	192.870
60300	195.3299	194.752
60440	196.5500	196.210
60460	197.3999	197.098
60610	198.2200	196.670
60771	199.0000	199.510
60933	199.8000	200.300
60947	200.5800	199.145
60955	201.3300	202.117
61250	202.0000	202.0755
61271	202.6000	203.3576
61383	203.1199	203.9349
62053	190.5000	190.005

Tabla 3.13: Comparación entre los valores predichos y los valores reales del nivel freático en mayo de 2023 para la tercera configuración.

Configuración	MSE	MAE	R ²	RMSE
Configuración 1	0.0465	0.1540	0.9561	0.8279
Configuración 2	0.0387	0.1421	0.9634	0.8250
Configuración 3	0.0440	0.1531	0.9585	0.8793

Tabla 3.14: Comparación de las tres configuraciones del modelo LSTM según sus métricas de desempeño.

pruebas destacan la importancia de optimizar los parámetros y la arquitectura del modelo para maximizar su rendimiento. Aunque el modelo alcanza un buen desempeño con esta variable, también es evidente que la incorporación de factores adicionales, como variables climáticas, podría mejorar aún más su precisión y robustez. Este análisis refuerza la validez de la hipótesis, aunque con la consideración de que un enfoque más completo podría ser beneficioso en aplicaciones prácticas.

De esta forma surgió la tercera hipótesis que planteaba:

- **Hipótesis 3 (H3): ¿Cuáles son las variables climáticas que tienen mayor-menor influencia que el nivel del Río Negro en la fluctuación del nivel freático?**

Para analizar esta hipótesis, utilizamos los conjuntos de datos: *freatímetroCotaCompleto* y *promedio_mensual_clima*. Primero realizamos un análisis de correlación entre el nivel freático y diversas variables climáticas, incluyendo la *Humedad (Out Hum)*, *Punto de rocío (Dew Pt.)*, y *Tasa de precipitación (Rain Rate)*. Aunque se analizaron otras variables como la *evapotranspiración (ET)* y la *temperatura exterior (Temp Out)*, este trabajo se enfoca únicamente en aquellas que presentaron correlaciones significativas, descartando las que mostraron valores absolutos inferiores a 0.2.

Los resultados se presentan en la Figura 3.11, y muestran un mapa de calor correspondiente a las correlaciones de Pearson entre el nivel freático y las variables climáticas seleccionadas (*Humedad (Out Hum)*, *Punto de rocío (Dew Pt.)*, y *Tasa de precipitación (Rain Rate)*). Los tonos más oscuros indican correlaciones más fuertes, mientras que los tonos claros reflejan relaciones débiles o nulas. Podemos observar, que la variable climática *Punto de rocío* muestra una relación con el nivel freático, con diferencias notables entre los distintos freatímetros. En algunos puntos




Figura 3.10: Comparación entre los valores reales (azul) y las predicciones (naranja) para las tres configuraciones del modelo LSTM.

específicos, como 61271, 60300 y 60771, se observa una correlación moderada positiva de 0.33, 0.44 y 0.41 respectivamente. Esto sugiere que, en estos casos, un mayor *punto de rocío* podría estar relacionado con un aumento en el nivel freático, posiblemente por reducción de la evaporación o mayor condensación. Sin embargo, en otros freatímetros, como 60610, 61250 y 61383, la correlación es cercana a cero o negativa, lo que sugiere que este efecto no es uniforme en toda la región.

Por su parte, la variable *Humedad* también mostró relaciones moderadas en 60300 (0.32), 60771 (0.33), 60955 (0.21) y 61271 (0.35), lo que respalda la hipótesis de que una mayor humedad favorece la estabilidad o ascenso de la napa freática.

La variable *Tasa de precipitación* presentó correlaciones más bajas en general, siendo los mayores valores observados en 60040 (0.27), 60300 (0.15), 60440 (0.20) y 60955 (0.18). Esto indicaría que la precipitación tiene un efecto limitado sobre la recarga de la napa en este contexto. En general esto se explica ya que en la zona de estudio el clima es seco, casi sin precipitaciones.

Luego de analizar las correlaciones, se seleccionó la variable climática *Punto de rocío* ya que presentó los mejores valores de correlación. Esta fue utilizada para comparar su influencia con la del nivel del río según la distancia de los freatímetros al cauce.

En la Tabla 3.15 se muestran los valores de correlación entre el nivel freático y ambas variables (punto de rocío y nivel del río), junto con una codificación por colores que facilita su interpretación: verde para correlaciones fuertes (mayores a $|0.5|$), amarillo para correlaciones moderadas (entre $|0.5|$ y $|0.2|$), y rojo para correlaciones bajas (menores a $|0.2|$).

Como se puede observar, en 5 de los 15 freatímetros, la correlación entre el nivel freático y el punto de rocío es mayor que la correlación con el nivel del río. Este patrón se observa principalmente en freatímetros más alejados del río, como los casos de 60300, 60955, 61271, 60771 y 60440. Por ejemplo, en el freatímetro 60771, que se encuentra a 1900 metros del río, la correlación con el punto de rocío alcanza un valor de 0.41(amarillo), mientras que con el nivel del río es de apenas 0.19(rojo). Del mismo modo, en el freatímetro 61271, a 2000 metros de distancia, el punto de rocío presenta una correlación de 0.33(amarillo), muy superior a la del río, que es




Figura 3.11: Resultados de las correlaciones entre el nivel freático y las variables climáticas utilizando Pearson.

apenas 0.048(baja). Estos casos sugieren que, en zonas donde la correlación del nivel del río es baja o nula, el punto de rocío adquiere un rol más importante como factor asociado a la variación del nivel freático.

En contraste, en algunos freatímetros ubicados más cerca del río, como 62053 (250 m), 60610 (400 m) y 60460 (700 m), el nivel del río mantiene una correlación más alta que el punto de rocío. Esto refuerza la idea de que la variable del nivel del río tiende a tener mayor impacto en las zonas próximas al cauce, mientras que, a medida que aumenta la distancia, otras variables climáticas comienzan a tener mayor influencia sobre el comportamiento de la napa.

Este análisis refuerza la idea de que, si bien el nivel del río es una variable relevante, no es la única ni siempre la más determinante. Variables como el punto de rocío podrían ser más efectivas para predecir el comportamiento de la napa en ciertos sectores.

Considerando esto, se planteó la siguiente hipótesis:

- **Hipótesis 4 (H4):** De acuerdo a los resultados obtenidos en las hipótesis anteriores ¿Se puede predecir el nivel de la napa freática por cada freatímetro en la zona de estudio considerando únicamente las variables climáticas?

Para abordar esta hipótesis, partimos de los resultados obtenidos en los análisis de correlación anteriores, donde identificamos cuáles variables climáticas mostraban una mayor influencia sobre la variación del nivel freático en la Villa Regina. En particular, seleccionamos aquellas variables que presentaron correlaciones moderadas o mayores en la mayoría de los freatímetros. Las variables seleccionadas fueron *Humedad (Out Hum)*, *Punto de rocío (Dew Pt.)* y *Tasa de precipitación (Rain Rate)*. Optamos por la implementación de una red neuronal LSTM como en la H2.

En este caso, el modelo fue entrenado utilizando únicamente las variables climáticas previamente seleccionadas como entradas, descartando el nivel del río para evaluar si es posible predecir el nivel de la napa freática exclusivamente a partir de información climática. Asimismo, el identificador de cada freatímetro será considerado como variable categórica, permitiendo que el modelo distinga entre las diferentes ubicaciones.

Freatímetro	Distancia (m)	Correlación Río	Correlación punto de rocío
62053	250	0.6100	0.06
60075	350	0.2300	-0.09
60610	400	0.4100	-0.04
61250	600	0.3300	0.00
61383	600	-0.0300	-0.03
60460	700	0.3700	0.03
60933	900	0.2000	0.19
60947	1200	0.1500	0.12
60040	1350	-0.0940	0.10
60440	1550	0.1400	0.28
60300	1600	-0.0068	0.44
60955	1900	0.2700	0.28
60771	1900	0.1900	0.41
60160	2000	0.3200	0.03
61271	2000	0.0480	0.33

Tabla 3.15: Comparación de la correlación de Pearson del nivel del río y *Punto de rocío*, según la distancia al río.

Primera configuración de la red neuronal LSTM. El modelo se entrenó con un tamaño de lote de 16 y un máximo de 200 épocas. Los hiperparámetros utilizados son los mismos que en *H2*, resumidos en la Tabla 3.8.

Los resultados de la evaluación del modelos con las métricas fueron:

- MSE: 0.0333
- MAE: 0.1276
- R^2 : 0.9683
- RMSE: 0.7628

Los mismos demuestran que el modelo tiene una alta capacidad predictiva, alcanzando un R^2 de 0.9683, lo que indica que el modelo explica aproximadamente el 96.83 % de la variabilidad en los datos del nivel freático. Asimismo, los valores de MSE, MAE y RMSE son bajos, reflejando predicciones precisas y cercanas a los valores observados. En la Tabla 3.16 se presenta una comparación entre los valores predichos por el modelo LSTM y los valores reales observados en mayo de 2023 para los 15 freatímetros analizados. Los datos del año 2023 fueron reservados exclusivamente para la validación del modelo, sin ser utilizados durante el entrenamiento.

Se observa que los valores predichos se aproximan bastante a los valores reales. Por ejemplo, en los freatímetros 60040, 60075 y 60440, la diferencia entre el nivel freático predicho y el real es mínima. En algunos freatímetros, como 60610 y 60947, si bien la diferencia es algo mayor, sigue siendo aceptable considerando la complejidad de las variables climáticas involucradas.

En términos generales, el modelo ha logrado capturar adecuadamente la tendencia y magnitud del nivel freático utilizando únicamente las variables climáticas seleccionadas *Humedad (Out Hum)*, *Punto de rocío (Dew Pt.)* y *Tasa de precipitación (Rain Rate)*, reafirmando la capacidad predictiva de las mismas.

En la Figura 3.12, se presenta la comparación entre los valores reales (azul) y los valores predichos (naranja) por el modelo LSTM utilizando las variables climáticas seleccionadas como entradas.

Freatímetro_ID	Fecha	Nivel Freático Predicho (<i>msnm</i>)	Nivel Freático Real (<i>msnm</i>)
60040	2023-05	191.26	191.27
60075	2023-05	192.39	192.09
60160	2023-05	193.68	194.09
60300	2023-05	195.15	194.75
60440	2023-05	196.46	196.14
60460	2023-05	197.24	196.20
60610	2023-05	198.21	196.65
60771	2023-05	199.12	199.22
60933	2023-05	199.99	200.10
60947	2023-05	200.81	198.34
60955	2023-05	201.55	202.04
61250	2023-05	202.20	201.69
61271	2023-05	202.77	202.86
61383	2023-05	203.25	203.89
62053	2023-05	190.25	189.93

Tabla 3.16: Comparación entre valores predichos y valores reales no utilizados en el entrenamiento de la LSTM (variables climáticas), mayo de 2023.




Figura 3.12: Comparación entre valores reales (azul) y predicciones (naranja) del modelo LSTM para el nivel freático utilizando variables climáticas.

Como se puede observar, el modelo logra seguir adecuadamente la tendencia general de los datos, manteniendo un buen ajuste en la mayoría de los casos. Estos resultados sugieren que las variables climáticas seleccionadas poseen una buena capacidad explicativa en la variación del nivel freático, permitiendo obtener predicciones confiables sin considerar directamente el nivel del río.

Segunda Configuración de la red neuronal LSTM. En esta segunda configuración, usamos los mismos hiperparámetros utilizados para la segunda configuración de la *H2* definidos en la Tabla 3.10 con un número de unidades en las capas LSTM de 256 en la primera y 128 en la segunda.

Tras entrenar el modelo con esta configuración, obtuvimos los siguientes resultados para las métricas:

- MSE: 0.0385
- MAE: 0.1319
- R^2 : 0.9633
- RMSE: 0.8208

A pesar de los cambios realizados, los resultados muestran una leve disminución en el desempeño comparado con la configuración anterior. Aunque el modelo mantiene una capacidad predictiva aceptable, reflejada en un R^2 de 0.9633, se observa que la precisión disminuyó en comparación con la primera configuración.

Para validar el modelo, comparamos los valores predichos y los valores reales utilizando el mismo criterio que en la primera configuración como se muestra en la Tabla 3.17. La comparación muestra que, aunque el modelo logra capturar la tendencia general, presenta diferencias más grandes en algunos freáticos.

Freático_ID	Fecha	Nivel Freático Predicho (<i>msnm</i>)	Nivel Freático Real (<i>msnm</i>)
60040	2023-05	191.13	191.27
60075	2023-05	192.22	192.09
60160	2023-05	193.50	194.09
60300	2023-05	194.98	194.75
60440	2023-05	196.52	196.14
60460	2023-05	197.53	196.20
60610	2023-05	198.42	196.65
60771	2023-05	199.36	199.22
60933	2023-05	200.24	200.10
60947	2023-05	201.03	198.34
60955	2023-05	201.69	202.04
61250	2023-05	202.24	201.69
61271	2023-05	202.68	202.86
61383	2023-05	203.03	203.90
62053	2023-05	190.24	189.93

Tabla 3.17: Comparación entre valores predichos y valores reales no utilizados en el entrenamiento de la segunda configuración del modelo LSTM (variables climáticas), mayo de 2023.

La Figura 3.13 muestra la comparación entre los valores predichos (naranja) y los valores reales (azul) de ambas configuraciones.

A partir de los resultados obtenidos en las dos configuraciones evaluadas, se elaboró una tabla comparativa 3.18 que resume los principales hiperparámetros utilizados y las métricas de





Figura 3.13: Comparación entre los valores reales y las predicciones para las dos configuraciones del modelo LSTM.

Hiperparámetros		
	Modelo 1	Modelo 2
Capas LSTM	128 / 64	256 / 128
Tasa de aprendizaje	0.001	0.0005
Batch size	16	32
Métricas de evaluación		
	Modelo 1	Modelo 2
Error cuadrático medio (MSE)	0.0333	0.0385
Error absoluto medio (MAE)	0.1276	0.1319
Coefficiente de determinación (R^2)	0.9683	0.9633
Raíz del error cuadrático medio (RMSE)	0.7628	0.8208
Mejor en métricas	Modelo 1 (más preciso)	

Tabla 3.18: Comparación entre dos configuraciones del modelo LSTM para la predicción del nivel freático utilizando variables climáticas.

evaluación obtenidas por cada modelo. El objetivo de esta comparación es identificar cuál de las configuraciones presenta un mejor desempeño general en la predicción del nivel freático.

Estos resultados sugieren que la complejidad adicional introducida en la segunda configuración no fue beneficiosa para el conjunto de datos disponible, posiblemente debido al tamaño de los datos. La primera configuración del modelo demuestra que es posible predecir el nivel freático utilizando únicamente variables climáticas, alcanzando un desempeño aceptable en la mayoría de los freáticos analizados. Además, estos resultados refuerzan la hipótesis de que las variables climáticas seleccionadas tienen un impacto significativo y suficiente para modelar la dinámica del nivel freático, sin necesidad de incluir el nivel del río como variable explicativa.

Nuevamente, una vez terminadas de analizar las cuatro hipótesis, documentamos la *variedad de proceso* implementada en CoVaMaT. Como podemos observar en la Figura 3.14, estas variedades, que son parte del *Activo de dominio de Agricultura de Precisión* registran las técnicas de correlación utilizadas, el tipo de procesamiento, el tipo de clasificación y las técnicas de preparación de datos.

Proceso de Big Data: Actividades de Visualización y Acceso

En esta actividad diseñamos e implementamos un formulario interactivo utilizando la herramienta *ipywidgets*⁵, con el objetivo de predecir el nivel freático de cada freático de la zona de estudio. Esta interfaz permite acceder de manera sencilla a las capacidades del modelo LSTM previamente entrenado, correspondiente a la primera configuración validada en la Hipótesis 4 del caso 1, cuyo desempeño fue el más satisfactorio.

El formulario permite al usuario ingresar manualmente los valores correspondientes de tres variables climáticas: *Humedad*, *Punto de rocío* y *Tasa de precipitación*, junto con el identificador del freático y la fecha del mes para el cual se dispone de datos climáticos. A partir de estos datos, el sistema recupera automáticamente los registros históricos de los tres meses anteriores para el freático seleccionado, formando así la secuencia temporal requerida por el modelo.

Este formulario está limitado al periodo sin riego, por lo que sólo permite seleccionar los meses que van de Mayo a Agosto. Además, el modelo está configurado para realizar predicciones con un horizonte de un mes hacia adelante. Por ejemplo:

⁵<https://pypi.org/project/ipywidgets/>




Figura 3.14: Proceso P-1 donde documentamos la variedad de procesos como *activo de dominio de Agricultura de Precisión* en CoVaMaT

- Si se ingresan los datos climáticos correspondientes a julio de un determinado año, la predicción será para agosto del mismo año.
- Si se ingresan los datos de agosto, el sistema generará la predicción para mayo del año siguiente.

En la Figura 3.15, se observa una predicción para el freatímetro identificado como 60040, correspondiente al mes de agosto de 2021. Los valores climáticos ingresados manualmente por el usuario fueron: *Tasa de precipitación* igual a 0,064 mm, *Humedad* de aproximadamente 55,59 % y *Punto de rocío* de -0,249°C. Luego de presionar el botón *Prededir Nivel Freático*, el sistema muestra como resultado una predicción de nivel freático para ese freatímetro y mes específico, con un valor de 191.22 msnm.

Figura 3.15: Ejemplo de entrada de datos en el formulario interactivo para la predicción del nivel freático.

A continuación, en la Tabla 3.19, se presenta el resultado obtenido junto con el valor real medido para el freatímetro 60040.

Freatímetro ID	Predicción (msnm)	Valor Real (msnm)	Diferencia (msnm)
60040	191.22	191.27	0.05

Tabla 3.19: Comparación entre el valor predicho por el formulario y el valor real medido

Se observa que el modelo logra predecir el nivel freático con un margen de error relativamente bajo, capturando adecuadamente la tendencia para el freatímetro.

Este formulario podría adaptarse al modelo de la *H2* utilizando la misma lógica.

Paso 4: Verificación de las Hipótesis

Tomando en cuenta la primera hipótesis que formulaba:

Hipótesis 1: ¿Tiene influencia el nivel del Río Negro en la recarga de la napa freática? ¿Que impacto tiene la distancia entre el río y los freatímetros en la variación del nivel de la napa?

Los resultados indicaron que la correlación entre el nivel del río y el nivel freático es positiva en la mayoría de los freatímetros, aunque su intensidad varía según la ubicación y la distancia al cauce. Los freatímetros más cercanos al río, como el 62053 (250 m) y el 60610 (400 m), presentaron correlaciones más altas (0.61 y 0.41 respectivamente), sugiriendo una mayor influencia del mismo en estas zonas. A medida que aumenta la distancia, la correlación disminuye, e incluso se vuelve baja o cercana a cero en algunos casos, como en el freatímetro 60300 (-0.0068 a 1600 m).

Aunque la correlación entre el nivel del río y el nivel freático es moderada y varía entre los diferentes freatímetros, el análisis muestra una clara tendencia: *la influencia del río es más evidente en los puntos más cercanos al cauce, disminuyendo a medida que aumenta la distancia*. Esto refuerza la idea de que el Río Negro contribuye a la recarga de la napa, aunque la relación no es igual en todos los freatímetros.

Tomando en cuenta la segunda hipótesis la cual planteaba:

Hipótesis 2: ¿Se puede predecir en forma eficiente el nivel de la napa freática por cada freatímetro utilizando la variable del nivel del Río Negro?

Pudimos ver que los resultados obtenidos con las distintas configuraciones del modelo LSTM fueron muy buenos, destacándose especialmente la segunda configuración, que mostró el mejor rendimiento. Los resultados validaron la hipótesis, mostrando que *es posible construir un modelo predictivo eficiente basado en el nivel del Río Negro*.

Luego para la tercera hipótesis, que postulaba:

Hipótesis 3: ¿cuales son las variables climáticas que tienen mayor-menor influencia que el nivel del Río Negro en la fluctuación del nivel freático?

Los resultados mostraron que variables como *Humedad (Out Hum)*, *Punto de rocío (Dew Pt.)* y *Tasa de precipitación (Rain Rate)* presentaron correlaciones relevantes con el nivel freático, aunque la intensidad de estas relaciones varía según la ubicación del freatímetro. Este análisis confirmó que las variables climáticas influyen en el nivel de la napa freática, aunque su impacto no es uniforme en todos los puntos de medición, ya que cercano al río, la misma disminuye.

Por lo tanto, se considera verificada la hipótesis, ya que *algunas variables climáticas demostraron tener una influencia comparable o incluso mayor que la del nivel del río aquellos freatímetros mas alejados al cauce*.

Por último, para la cuarta hipótesis, que postulaba:

Hipótesis 4: De acuerdo a los resultados obtenidos en las hipótesis anteriores ¿Se puede predecir el nivel de la napa freática por cada freatímetro en la zona de estudio considerando unicamente las variables climáticas?

Pudimos comprobar que el modelo basado exclusivamente en variables climáticas también logró buenos resultados. En particular, la primera configuración fue la que respondió mas favorablemente.

Los resultados permitieron validar la hipótesis, ya que se demostró que *es posible construir un modelo para estimar el nivel freático usando las variables climáticas punto de rocío, humedad y lluvia*.

Paso 5: Reformulación o Terminación

Se decidió finalizar este caso de dominio debido a que se arribó a la verificación de las hipótesis formuladas. Como resultado del mismo se generaron todos los activos pertenecientes al dominio de Agricultura de Precisión que mostramos en las Figuras 3.2, 3.3, 3.4 y 3.14. Un resumen completo de todos los activos creados puede verse en la Figura 3.16. Luego, para la documentación del caso de dominio sin riego, utilizamos la funcionalidad F-2 (*Funcionalidad para instanciar casos*) para instanciar los activos de dominio creados previamente. De esta forma, llamamos al proceso P-2 (*Definir caso*) el cual recupera los activos de dominio, selecciona e instancia las variedades, y desarrolla y almacena el caso. En la Figura 3.17 podemos observar que desde el *Activo de dominio de Agricultura de Precisión* instanciamos todos los puntos de variabilidad creados para los activos de este dominio resultando en la selección de las variedades aplicadas al caso. Por último, el caso se documentó como *Caso de dominio sin riego VR*.

3.1.2. Caso de Dominio 2: periodo con Riego

A continuación realizamos un segundo caso de dominio el cual requirió realizar las mismas cinco actividades del enfoque T-VIP (Figura 3.1) pero ahora sobre un periodo diferente. Nos abocamos al periodo con riego, desde el mes de septiembre al mes de abril. Como podemos observar en la Figura 3.18 el canal de riego (línea roja) esta activo, es decir posee agua y la distribuye entre los canales secundarios para regar las chacras.

La realización de este caso tiene la particularidad de que existe en el repositorio de CoVaMaT un activo del dominio de agricultura de precisión, con varios activos para cada una de las variedades definidas en cada actividad del proceso de big data. Entonces, utilizamos la funcionalidad F-3 (*Funcionalidad para reutilización de casos*) y los procesos P-3 (*Definir caso de reuso*) y P-4 (*Consultar activos de dominio en casos similares*) para consultar y recuperar los activos del dominio y/o casos de dominio existentes y similares. En la Figura 3.19 podemos observar los pasos para la búsqueda y recuperación de los activos creados para el caso anterior y que fueron reusados para este caso. Lo primero que realizamos (número 1 de la figura) fue la búsqueda de los activos en donde se encontró y recuperó el *Activo de dominio de Agricultura de Precisión*. Luego de que lo analizamos y seleccionamos, determinamos que era necesario crear una nueva variedad de contexto que ahora incluya el *periodo con riego Villa Regina* (número 2, en naranja en la figura). Como vemos, esta variedad posee ahora los dos periodos, con y sin riego. Luego, se utilizó el proceso P-4 para buscar casos del dominio similares, donde se recuperó el *Caso de dominio sin riego VR* (número 3 en la figura) con todos sus activos asociados (Figura 3.17). Con el caso ya recuperado, instanciamos la variedad de contexto al *Periodo con riego Villa Regina* (número 4 en la figura) y creamos un nuevo activo denominado *Caso reusable con riego VR* (número 5 en la figura). Luego continuamos con las siguientes actividades del proceso de big data, analizando si hay similitudes en las siguientes variedades.

Paso 1: Definición de Hipótesis

Las hipótesis planteadas en este caso se corresponden con *H1* y *H3* del caso de dominio anterior. A su vez, agregamos una nueva hipótesis aquí que involucra la comparación de los resultados de este caso con el caso previo en el periodo sin riego. La nueva hipótesis postulaba:




Figura 3.16: Proceso P-1 donde documentamos la variedad de contexto como un nuevo activo de dominio de Agricultura de Precisión en CoVaMaT




Figura 3.17: Caso de dominio sin riego VR creado a partir de las instancias del Activo de dominio de Agricultura de Precisión




Figura 3.18: Caso de dominio 2 donde vemos el canal de riego activo




Figura 3.19: Creación de una nueva variedad de contexto y del *Caso reusable periodo con riego*

- **Hipótesis 5 (H5):** ¿Los factores analizados en el periodo sin riego, poseen la misma influencia en el periodo con riego en la zona de estudio?

Pasos 2 y 3: Procesamiento de las Hipótesis

En los pasos 2 y 3 tomamos las tres hipótesis definidas (como analistas de datos) y llevamos a cabo todas las actividades involucradas (Figura 3.1).

Proceso de Big Data: Actividad Colección

La actividad de colección de datos es similar al *Caso de dominio sin riego VR* ya que poseen los mismos formatos. Sin embargo, los datos son diferentes ya que se corresponden a dos periodos distintos.

Proceso de Big Data: Actividad Preparación

Dentro de esta actividad se llevaron a cabo las mismas técnicas de preparación de los datos aplicadas en el *Caso de Dominio sin riego VR*, con la diferencia que el periodo tomado para este caso contiene a los meses de septiembre a abril. La similitud en la preparación se debe a que ambos conjuntos de datos poseían las mismas variables, la misma frecuencia de medición y el mismo formato. Al igual que con el caso de periodo sin riego, se prepararon 3 conjuntos de datos:

- *freatímetroCotaCompleto_C2*: reúne mediciones históricas de la cota de diversos freatímetros en la zona de estudio en el periodo planteado en este caso.
- *nivelRíoPromedio_C2*: posee información del nivel del río promedio por mes.
- *promedio_mensual_clima_C2*: contiene los datos de variables climáticas promediadas mensualmente.

Para la creación y documentación en CoVaMaT, no tuvimos que crear nuevas variedades ya que son las mismas que poseíamos en el *Activo de dominio de Agricultura de Precisión* para la variedad de contenido. Por lo tanto lo único que realizamos fue asociarlas al *Caso reusable periodo con riego* (Figura 3.20).




Figura 3.20: Instanciación de las variables asociadas con el *Activo de dominio de Agricultura de Precisión* al *Caso reusable periodo con riego VR*

Proceso de Big Data: Actividad Analítica

En esta actividad, examinamos los diferentes conjuntos de datos para evaluar nuestras hipótesis. De acuerdo a la primera hipótesis ($H1$), que planteaba:

- **Hipótesis 1 ($H1$): ¿El nivel del Río Negro tiene influencia en la recarga de la napa freática? ¿Qué impacto tiene la distancia entre el río y los freatímetros en la variación del nivel de la napa?**

Para analizar si el nivel del Río Negro influye en la recarga de la napa freática, empleamos los conjuntos de datos: *freatímetroCotaCompleto_C2* y *nivelRíoPromedio_C2*.

Comenzamos con un análisis visual preliminar, como podemos observar en la Figura 3.21. En la misma graficamos la fluctuación de los 15 freatímetros con respecto a la napa en el periodo con riego. En cada gráfico, el eje horizontal (x) toma el periodo con riego compuesto por los meses de septiembre, octubre, noviembre, diciembre, enero, febrero, marzo y abril desde el año 2010 a 2023⁶, mientras que el eje vertical (y) muestra los valores registrados para cada variable (*msnm*). Cada serie de cada gráfico representa, en azul, la variación del nivel del río, y en verde el nivel de la napa. En los gráficos a simple vista se puede observar un comportamiento similar en algunos casos entre los diferentes freatímetros, como en los freatímetros 62053 (fila 5, columna 3), 60610 (fila 3, columna 1) y 60955 (fila 4, columna 2). Allí, se pueden observar picos del nivel freático que coinciden con los picos en el nivel del río. Por otro lado, en los freatímetros 61383 (fila 5, columna 2) y 60933 (fila 3, columna 3), no se observa relación entre los niveles.

Para profundizar lo observado, realizamos análisis de correlación para evaluar la asociación entre las variables del nivel del río y nivel de la napa en el periodo con riego. Como se observa en la Figura 3.23, las técnicas de correlación utilizados fueron Spearman Kendall y Pearson, obteniendo valores en general bajos. Tanto las correlaciones positivas como las negativas rondan magnitudes que apenas superan $|0.2|$. Por ejemplo, para Pearson, el freatímetro 60610 muestra la correlación más alta (0.23), lo cual indica que, aún en el mejor de los casos, la relación con el nivel del río sigue siendo débil. En el otro extremo, existen freatímetros con correlaciones ligeramente negativas (como 61250 con -0.093 o 60040 con -0.06), sugiriendo una posible relación inversa muy leve y probablemente poco significativa en la práctica.

La Figura 3.23 muestra la distribución espacial de los freatímetros en relación al cauce del Río Negro, representados con colores que reflejan la fuerza de la correlación de Pearson entre el nivel del río y el nivel freático durante el periodo con riego.

Por otro lado, la Tabla 3.20 complementa esta información, mostrando para cada freatímetro su distancia al cauce del río y el valor exacto de la correlación de Pearson. Cabe destacar que la tabla está ordenada de menor a mayor distancia al río, lo cual permite observar con mayor claridad si existe algún patrón espacial entre la proximidad al cauce y el grado de correlación.

Los resultados obtenidos permiten concluir que, en el periodo con riego analizado, el nivel del río tiene una influencia baja o prácticamente nula en la mayoría de los freatímetros. La distancia al río no parece ser un factor determinante por sí solo.

Debido a que la mayoría de las correlaciones obtenidas son menores a 0.20, y sólo tres freatímetros superan ese umbral, no es posible construir un modelo predictivo confiable del nivel freático basado exclusivamente en el nivel del río para este periodo. La asociación débil implica que el nivel del río no explica suficientemente la variabilidad del nivel de la napa en la zona de estudio durante los meses con riego, lo cual sugiere que otras variables climáticas o de gestión hídrica (el uso de canales de riego) podrían tener un mayor peso en la fluctuación de la napa.

A partir de estos resultados, planteamos la siguiente hipótesis, con el objetivo de analizar si algunas variables climáticas influyen en el comportamiento del nivel freático.

- **Hipótesis 3 ($H3$): ¿Cuáles son las variables climáticas que tienen mayor-menor influencia que el nivel del Río Negro en la fluctuación del nivel freático?**

⁶Serían 112 meses en 14 años




Figura 3.21: Comparación del nivel del Río Negro y las mediciones en distintos freáticos




Figura 3.22: Resultados del análisis de correlación para el Conjunto de Datos freatímetroCota-Completo_C2 y nivelRíoPromedio_C2 con las técnicas de Pearson, Spearman y Kendall




Figura 3.23: Representación de los freátímetros con un código de colores según su distancia al río: amarillo = correlación intermedia y rojo = correlación débil o nula.

Freatímetro	Distancia (m)	Correlación
62053	250	0.20
60075	350	0.13
60610	400	0.23
61383	600	-0.08
61250	600	-0.093
60460	700	0.20
60933	900	-0.038
60947	1200	0.074
60040	1350	-0.060
60440	1550	0.14
60300	1600	0.095
60955	1900	0.099
60771	1900	0.047
61271	2000	-0.019
60160	2000	-0.049

Tabla 3.20: Distancia al río y correlación de Pearson por freatímetro, ordenados por distancia. Se destacan en amarillo los casos con correlaciones moderadas (entre $|0.5|$ y $|0.2|$)

Para verificar esta hipótesis, utilizamos nuevamente Pearson considerando las interacciones entre las variables climáticas y el nivel freático en Villa Regina. En este caso utilizamos los conjuntos de datos *freatímetroCotaCompleto_C2* y *promedio_mensual_clima_C2*.

Del análisis de correlación pudimos observar que aunque los resultados observados fueron en general débiles, algunas variables mostraron un desempeño relativamente superior respecto al resto. En particular, las variables *humedad (Out Hum)*, *punto de rocío (Dew Pt.)* y *tasa de precipitación (Rain Rate)* fueron las que obtuvieron mejores resultados (Figura 3.24). En particular, el *punto de rocío (Dew Pt.)* fue la variable que mostró los valores de correlación más elevados, alcanzando un máximo de 0.24 en el freatímetro 60440 y valores cercanos a 0.20 en otros puntos como 60460 y 61271. Aunque estos valores son moderados/bajos, sugieren que el punto de rocío podría estar relacionado con la dinámica del nivel freático en determinados sectores.

La *humedad (Out Hum)* presentó varios coeficientes negativos, siendo los más notorios los de los freatímetros 60955 con -0.25 y 61250 con -0.27. Esto podría indicar una relación inversa en ciertos sitios, donde mayores niveles de humedad se asocian con una disminución del nivel freático, aunque esta relación no es fuerte ni generalizada.

La *tasa de precipitación (Rain Rate)*, en cambio, mostró los valores más bajos de correlación en casi todos los casos. Esto sugiere que las precipitaciones no tienen una influencia directa o inmediata sobre el nivel freático en estos puntos.




Figura 3.24: Resultados de las correlaciones entre el nivel freático y las variables climáticas utilizando Pearson.

La Tabla 3.21 presenta los coeficientes de correlación de Pearson entre el nivel freático y dos variables: el *nivel del Río Negro* y el *Punto de rocío (Dew Pt.)*, junto con la distancia de cada freatímetro al cauce del mismo. El objetivo de esta tabla fue analizar qué variable presenta mayor influencia sobre las fluctuaciones del nivel freático en diferentes ubicaciones dentro de la zona de estudio. Para facilitar la interpretación, las celdas fueron coloreadas de acuerdo con la magnitud de la correlación: rojo para correlaciones débiles y amarillo para correlaciones moderadas.

Como podemos observar los resultados son muy dispares y en todos los casos bajos, tanto positiva como negativamente. Al igual que el nivel del río, las variables climáticas no ejercen influencia en la napa durante el periodo analizado.

De esta forma, pasamos a la última hipótesis para analizar la variedad contextual existente, es decir, si los comportamientos son similares en ambos periodos.

Freatímetro	Distancia (m)	Correlación Nivel Río	Correlación Punto de rocío
62053	250	0.200	-0.190
60075	350	0.130	-0.040
60610	400	0.230	0.010
61383	600	-0.080	0.110
61250	600	-0.093	0.100
60460	700	0.200	0.210
60933	900	-0.038	0.050
60947	1200	0.074	0.080
60040	1350	-0.060	0.010
60440	1550	0.140	0.240
60300	1600	0.095	0.200
60955	1900	0.099	0.150
60771	1900	0.047	0.040
61271	2000	-0.019	0.220
60160	2000	-0.049	0.090

Tabla 3.21: Distancia y coeficientes de correlación (Nivel del río y Dew Pt.) por freatímetro

- **Hipótesis 5 (H5):** ¿Los factores analizados en el periodo sin riego, poseen la misma influencia en el periodo con riego en la zona de estudio?

Para verificar la hipótesis incorporamos la variante *porcentaje de cambio* [34] que busca responder si las variables analizadas durante el periodo sin riego (mayo–agosto) conservan la misma influencia en el periodo con riego (septiembre–abril).

$$\% \text{ Cambio} = \frac{B - A}{A} \times 100$$

donde A representa el valor del periodo sin riego y B el valor del periodo con riego.

En la Tabla 3.22 se muestran los valores de correlación de Pearson entre el nivel freático y las variables del nivel del Río Negro. La misma esta ordenada de acuerdo a la distancia de cada freatímetro al cauce del río. La ultima columna muestra porcentaje de cambio en la correlación. Podemos observar en esta ultima columna que los porcentajes de cambios son en su mayoría negativos.

Luego, en la Tabla 3.23 se muestran los valores de correlación de Pearson entre el *nivel freático* y la variable climática *Punto de rocío*. La tabla está ordenada según la distancia de los freatímetros al cauce del río. La ultima columna muestra el porcentaje de cambio.

Los resultados de ambas tablas mostraron una tendencia clara donde la mayoría de los freatímetros mostró una disminución marcada en la correlación durante el periodo con riego. Esto sugiere que las variables antes influyentes, como el nivel del río y las climáticas, pierden protagonismo cuando existe una fuente de agua externa, como lo es el riego.

Para mayor claridad de los cambios, en la Figura 3.25 podemos observar la comparación de cada freatímetro con respecto al *nivel del río-nivel freático* (en rojo), *punto de rocío-nivel freático* (en azul), considerando los periodos sin y con riego. Un valor negativo indica que la correlación disminuye durante el periodo de riego, mientras que un valor positivo refleja que la relación aumenta. Los freatímetros están ordenados según su distancia al cauce, de menor a mayor, para facilitar la interpretación espacial del fenómeno. Podemos observar por ejemplo, que el freatímetro 62053, el cual es el mas cercano al río, posee un porcentaje de cambio de -67.21 (en colo rojo), es decir que el nivel del río tiene un 67 % menos de influencia cuando se riega la zona que cuando no se riega. Este mismo comportamiento se repite en casi todos los freatímetros, con caídas marcadas, como en el freatímetro 60300 (-1497 %) o en el 61250 (-128.18 %), lo que

evidencia una disminución generalizada en la relación entre el río y la napa freática durante el periodo de riego. La única excepción es el freatómetro 61383, que muestra un cambio positivo pero que no modifica la tendencia.

A su vez, los valores de correlación con el punto de rocío (Dew Pt.) (en azul en la figura) muestran un comportamiento más variado. Por ejemplo, el freatómetro 60460 (a 700 metros del río) presenta un incremento de 600 %, lo que indica un aumento importante en la influencia del punto de rocío durante el periodo con riego. Algo similar ocurre en el freatómetro 60160 (2000 m), que posee un cambio de 200 %. Es importante interpretar estos porcentajes con cautela. En muchos casos, los valores reales de las correlaciones son muy bajos, por lo que, aunque los cambios porcentuales sean altos, el impacto en términos absolutos sigue siendo limitado. Por ejemplo, en el freatómetro 60460 la correlación del punto de rocío (color azul) pasó de 0.03 a 0.21, es decir, un aumento del 600 %; pero que sigue dentro de un rango de correlación baja. Lo mismo aplica a 61383, cuya variación positiva en el nivel del río (color rojo) es poco significativa en valores reales, por lo que puede considerarse que su influencia se mantuvo prácticamente constante.

En contraste, hay freatómetros donde la influencia del punto de rocío disminuye. Es el caso de 62053 y 61383, donde las correlaciones bajan drásticamente, con porcentajes de cambio de -417 % y -467 %, respectivamente.

Freatómetro	Distancia (m)	nivel Rio Sin Riego	nivel Rio Con Riego	% Cambio
62053	250	0.61	0.20	-67.21
60075	350	0.23	0.13	-43.48
60610	400	0.41	0.23	-43.90
61250	600	0.33	-0.09	-128.18
61383	600	-0.03	-0.08	166.67
60460	700	0.37	0.20	-45.95
60933	900	0.20	-0.04	-119.00
60947	1200	0.15	0.07	-50.67
60040	1350	-0.09	-0.06	-36.17
60440	1550	0.14	0.14	0.00
60300	1600	-0.01	0.10	-1497.06
60955	1900	0.27	0.10	-63.33
60771	1900	0.19	0.05	-75.26
60160	2000	0.32	-0.05	-115.31
61271	2000	0.05	-0.02	-139.58

Tabla 3.22: Correlación de Pearson entre el nivel del río y el nivel freático, comparando periodos con y sin riego, ordenado por distancia al cauce.

Los resultados obtenidos indican que, durante el periodo con riego, la influencia de las variables analizadas (tanto el nivel del río como las variables climáticas) se reduce de forma considerable. En la mayoría de los freatómetros, las correlaciones descienden a valores cercanos o inferiores a 0.2, lo cual representa una relación muy débil o prácticamente nula. Esto sugiere que, durante el periodo con riego, influyen otros factores que no fueron considerados (por ejemplo, el canal de riego principal).

Para dejar registrado lo realizado en esta última hipótesis creamos dos nuevos activos en CoVaMaT. Por un lado, como no existía un método que compare resultados de dos análisis en dos contextos diferentes, lo agregamos como parte del *Activo de dominio de Agricultura de Precisión*, en la variedad de procesos. Como podemos observar en la Figura 3.26, llamamos al proceso P-1 para agregar este nuevo punto variante al que llamamos comparación con la variante de la función elegida llamada porcentaje de cambio (en naranja).

Proceso de Big Data: Actividades de Visualización y Acceso

Las actividades de visualización y acceso quedan pendientes de su terminación ya que sólo se realizaron en forma informal mostrando a los usuarios expertos los resultados obtenidos en los

Freatímetro	Distancia (m)	Dew Pt. Sin Riego	Dew Pt. Con Riego	% Cambio
62053	250	0.06	-0.19	-416.67
60075	350	-0.09	-0.04	-55.56
60610	400	-0.04	0.01	-125.00
61250	600	0.00	0.10	-
61383	600	-0.03	0.11	-466.67
60460	700	0.03	0.21	600.00
60933	900	0.19	0.05	-73.68
60947	1200	0.12	0.08	-33.33
60040	1350	0.10	0.01	-90.00
60440	1550	0.28	0.24	-14.29
60300	1600	0.44	0.20	-54.55
60771	1900	0.41	0.04	-90.24
60955	1900	0.28	0.15	-46.43
61271	2000	0.33	0.22	-33.33
60160	2000	0.03	0.09	200.00

Tabla 3.23: Correlación de Pearson para Dew Pt. en los casos 1 y 2, con porcentaje de cambio, ordenada por distancia al río.




Figura 3.25: Comparación del porcentaje de cambio en la correlación de Pearson entre los periodos sin riego y con riego para cada freatímetro




Figura 3.26: Proceso P-1 donde documentamos la nueva variedad de procesos para la comparación como *activo de dominio de Agricultura de Precisión* en CoVaMaT

gráficos previos.

Paso 4: Verificación de las Hipótesis

Tomando en cuenta la primera hipótesis que formulaba:

Hipótesis 1: ¿Tiene influencia el nivel del Río Negro en la recarga de la napa freática? ¿Qué impacto tiene la distancia entre el río y los freatímetros en la variación del nivel de la napa?

Los resultados mostraron que el nivel del Río Negro no presenta una influencia significativa sobre el comportamiento del nivel freático en la zona de estudio durante el periodo con riego. Si bien algunos freatímetros cercanos al cauce, como el 60610 y el 62053, registraron valores de correlación levemente mayores que otros, ninguno superó los 0.2, lo que representa una asociación muy débil. Además, no se observó un patrón claro entre la distancia al río y la intensidad de la correlación. *Por lo tanto, esta hipótesis no se valida: los datos analizados no muestran una relación clara entre el nivel del río y el nivel freático como para sostener que exista una influencia significativa para el periodo con riego.*

Luego para la tercera hipótesis, que postulaba:

Hipótesis 3: ¿Cuáles son las variables climáticas que tienen mayor o menor influencia que el nivel del Río Negro en la fluctuación del nivel freático?

El análisis de los resultados mostró que las variables climáticas tampoco presentan una influencia clara o significativa sobre el comportamiento del nivel freático. Si bien el *Punto de rocío* fue la variable que alcanzó los valores más altos de correlación en comparación con otras variables del clima, estos valores fueron en general muy bajos y no superaron el umbral de 0.2 en la mayoría de los casos.

Esto indica que, si bien puede haber una cierta relación puntual en algunos sectores, las variables climáticas no explican la variación del nivel freático en el área de estudio.

Por lo tanto, esta hipótesis no se valida: los resultados no muestran una relación clara entre las variables climáticas y el comportamiento del nivel freático en la zona de estudio para el periodo con riego.

Por último, para la quinta hipótesis, que postulaba:

Hipótesis 5: ¿Los factores analizados en el periodo sin riego poseen la misma influencia en el periodo con riego?

En términos generales, se observa que durante el periodo con riego las variables que mostraban cierta relación con el nivel freático dejan de ser relevantes. Esto sugiere que, cuando se activa el sistema de riego, el comportamiento de la napa comienza a depender de otros factores no contemplados en este análisis, como el ingreso de agua proveniente de las prácticas de riego en las chacras. Esta intervención externa cambia el comportamiento natural de la napa, haciendo que se pierdan las relaciones que antes se veían con el nivel del río y las variables climáticas. *Por lo tanto, esta hipótesis no se valida: la influencia de las variables analizadas cambia entre los periodos con y sin riego.*

Paso 5: Reformulación o Terminación




Figura 3.27: *Caso reusable con riego VR* creado a partir de las instanciaciones del *Activo de dominio de Agricultura de Precisión* y del *Caso de dominio sin riego VR*

Luego, para finalizar la documentación del *Caso reusable con riego VR*, instanciamos las variedades que faltan, por ejemplo la definida en H5. En la Figura 3.27 podemos observar que desde el *Activo de dominio de Agricultura de Precisión* instanciamos todas las variantes creadas para los activos de este dominio resultando en las aplicadas al caso.

3.2. Resumen del Capítulo

En este capítulo describimos los pasos realizados del enfoque T-VIP para el desarrollo de dos casos dentro del dominio de Agricultura de Precisión, basados en una variación contextual por periodos de tiempo. Se analizaron hipótesis aplicables a la zona de Villa Regina. Además, en cada actividad se describió la forma en que se creó el *Activo de dominio de Agricultura de Precisión*, y su instanciación en ambos casos. Primero, en el *Caso de dominio sin riego VR* y luego en *Caso reusable sin riego VR*. Todo esto fue almacenado en la base de conocimiento CoVaMaT.

Capítulo 4

Conclusiones y trabajo futuro

En este capítulo se describen las conclusiones y contribuciones más importantes de este trabajo de tesis. En primer lugar, se resumen los puntos principales de estudio a través de los objetivos presentados en el primer capítulo y de las tareas que se llevaron a cabo para alcanzar los mismos. Luego, se describen las conclusiones especificando las contribuciones teóricas y prácticas desarrolladas en este trabajo. Por último, se discuten las limitaciones y los trabajos futuros.

4.1. Resumen del Trabajo

En este trabajo hemos realizado el desarrollo de casos de dominio como aplicaciones de sistemas de big data en el campo de la agricultura de precisión, centrándonos en la predicción de la fluctuación del nivel de napa freática en la zona de Villa Regina. Para el desarrollo de los casos hemos aplicado un enfoque top-down que se basa en la detección de variedades para la creación de aplicaciones flexibles y adaptables.

En el Capítulo 2 analizamos los conceptos fundamentales de los sistemas de big data y exploramos el ciclo de vida típico desde la evaluación del caso de negocio hasta la visualización y utilización de los datos resultantes. Luego, introducimos el dominio de agricultura de precisión, explicando su importancia en la gestión eficiente del agua y el rol clave que cumple el nivel freático en la productividad agrícola. Se describieron los freatómetros como instrumentos de medición de dicho nivel. A continuación, analizamos una serie de trabajos previos que aplican técnicas de aprendizaje automático para predecir el nivel del agua subterránea en distintas regiones del mundo. Se compararon enfoques y variables empleadas, destacando el uso recurrente de datos climáticos y niveles del río como predictores. Por último, realizamos un resumen de los trabajos previos del grupo de investigación donde se enmarca esta tesis, enfocándonos en el concepto de variedad, los enfoques Top-Down (T-VIP) y Bottom-Up (B-VIP) para identificarla, y la herramienta CoVaMaT que permite la documentación de activos para fomentar el reuso.

En el Capítulo 3 describimos el desarrollo de dos casos dentro del dominio de la agricultura de precisión, mediante la aplicación del enfoque T-VIP. El contexto estuvo definido específicamente por los periodos con y sin riego en la zona de Villa Regina. Así, en el primer caso de dominio (periodo sin riego) planteamos cuatro hipótesis orientadas a explorar la relación entre distintas variables y la fluctuación del nivel freático, con el objetivo de desarrollar un modelo capaz de predecir su variación. Durante este primer caso, se crearon varios activos de dominio en CoVaMaT que luego fueron utilizados por el segundo caso de dominio (periodo con riego). En este último, los activos documentados fueron reusados para la ejecución de dos hipótesis, reusando los activos de Villa Regina. Se agregó una tercera hipótesis, para comparar los resultados de acuerdo a la variedad de contexto planteada.

A continuación, describimos, para cada objetivo específico definido en el Capítulo 1, el trabajo realizado para lograrlo:

- Para la realización del primer objetivo, el cual planteaba *modelar el contexto para el análisis y definir hipótesis*, en el Capítulo 2 (secciones 2.1, 2.2 y 2.4) profundizamos en las nociones básicas y específicas en la construcción de sistemas de big data en general y los trabajos relacionados en el dominio de la agricultura de precisión. Esto incluyó el análisis y clasificación de modelos de análisis empleados, junto con las variables utilizadas, las zonas investigadas y los resultados que obtuvieron. Esta información nos proporcionó un panorama de las técnicas más usadas para comprender las diferentes variables y los diferentes métodos utilizados para la predicción del nivel freático. Al mismo tiempo, nos guió en la creación del activo de dominio de agricultura de precisión para el cual definimos dos variedades de contexto en la zona de Villa Regina, uno para el periodo sin riego (sección 3.1.1 del Capítulo 3) y el otro para el periodo con riego (sección 3.1.2 del Capítulo 3). A partir de allí, planteamos cuatro hipótesis para el caso de dominio del periodo sin riego y tres para el caso del periodo con riego. Estas hipótesis fueron definidas acorde a los trabajos en la literatura y los requerimientos de los usuarios expertos del INTA. También documentamos las variedades de contexto definidas que se almacenaron empleando la herramienta CoVaMaT.
- Para la realización del segundo objetivo, el cual planteaba *instanciar el modelo de contexto*, en el Capítulo 3 describimos detalladamente la aplicación del enfoque T-VIP desarrollado en trabajos previos del grupo de investigación. Para ello, realizamos las actividades incluidas en el proceso de big data donde primero recolectamos datos de variables climáticas de Villa Regina, el nivel del río y datos del nivel de la napa tomados de los distintos freáticos de la zona de estudio. Luego, mediante la actividad de preparación se transformaron dichas fuentes para que estén aptas para el análisis que llevaríamos a cabo. Esto incluyó tareas como la eliminación de registros, eliminación de variables, imputar datos faltantes, agregar variables nuevas, entre otras (secciones 3.1.1 y 3.1.2 del Capítulo 3). Además, identificamos y almacenamos la variedad hallada que, en este caso, fue la variedad de las fuentes y contenido, haciendo uso de la herramienta CoVaMaT.
- Con respecto al tercer objetivo, el cual planteaba *verificar las hipótesis*, continuamos la aplicación del resto de las actividades del proceso de big data. Empleamos varias técnicas de análisis de datos (secciones 3.1.1 y 3.1.2 del Capítulo 3), estudiamos las estadísticas básicas de las diferentes variables utilizadas en los diferentes periodos en la zona de Villa Regina, analizamos la relación entre las variables a través de diferentes coeficientes de correlación en varios análisis, entre otras tareas. Durante el periodo sin riego, se confirmó que el nivel del río influye en el nivel freático, especialmente en freáticos cercanos al cauce (*H1*). Además, se demostró que es posible predecir con buena precisión el nivel de la napa utilizando solo el nivel del río mediante un modelo LSTM (*H2*). También se validó que ciertas variables climáticas, como el *Punto de rocío (Dew Pt.)*, tienen influencia en el nivel freático, aunque varía según la ubicación (*H3*). A partir de esto, se construyó un modelo LSTM usando solo variables climáticas, logrando buenas predicciones (*H4*). Durante el periodo con riego planteado en el segundo caso, se analizaron tres hipótesis sobre los factores que influyen en el nivel freático.

Se observó que el Río Negro no tiene una relación clara con el nivel freático, por lo que la (*H1*) planteada en este caso no se validó. Por otro lado, las variables climáticas mostraron una influencia moderada, por lo tanto no muestran una relación clara entre las variables climáticas y el comportamiento del nivel freático por este motivo no se validó la (*H3*) en el periodo con riego. En cambio, se comprobó que los factores que influyen en el nivel freático cambian entre los periodos con y sin riego, por lo que la (*H5*) no se validó.

En conclusión, este trabajo destacó la utilidad del enfoque T-VIP para desarrollar soluciones basadas en big data aplicadas a la agricultura de precisión, enfocadas en la predicción del nivel

freático en el Alto Valle de Río Negro y Neuquén. Identificamos variables importantes y verificamos hipótesis claves mediante el análisis de los datos. La herramienta CoVaMaT fue clave para organizar y reutilizar la información de manera eficiente. Creemos que estos avances pueden mejorar la gestión del agua en la región y servir como base para futuros estudios.

4.2. Limitaciones y Trabajos Futuros

Podemos identificar ciertas limitaciones que han impactado en la extensión del trabajo desarrollado. A su vez, podemos identificar áreas prometedoras para futuras tareas que permitan ampliar y enriquecer los resultados presentados. A continuación, detallamos las limitaciones encontradas y proponemos direcciones para investigaciones futuras

1. *Análisis del canal de riego*: Debido a la extensión de esta tesis, se decidió no incluir el análisis de los datos del nivel del canal de riego principal en la zona de estudio. Las hipótesis relacionadas con esta variable quedaron pendientes para trabajos futuros. Comprender su impacto podría aportar información valiosa sobre la fluctuación de la napa durante el periodo con riego y, en consecuencia, permitir la construcción de un modelo predictivo más robusto.
2. *Visualización de datos*: Esta actividad se abordó de forma limitada en esta tesis, enfocándonos en los casos de estudio y en una representación básica de los resultados. Consideramos que una visualización más completa podría contribuir a una mejor interpretación de los patrones observados y facilitar la comunicación de los hallazgos. Incluir esta fase en futuros trabajos permitiría profundizar en el análisis y apoyar con mayor claridad los procesos de toma de decisiones.
3. *Recursos computacionales*: El entrenamiento de redes neuronales implica una alta demanda de recursos, especialmente cuando se trabaja con grandes volúmenes de datos o configuraciones complejas, como múltiples unidades ocultas o validación cruzada con varios pliegues. Además, los procesos de imputación y validación de datos también requieren un uso intensivo de memoria y procesamiento, lo que puede limitar el alcance de los análisis. Para futuros trabajos, sería valioso contar con una infraestructura adecuada o explorar estrategias más eficientes para optimizar estos procedimientos y así aprovechar al máximo las capacidades de modelado.

Bibliografía

- [1] S. Lallahem, J. Mania, A. Hani, and Y. Najjar. On the use of neural networks to evaluate groundwater levels in fractured media. *Journal of Hydrology*, 307(1):92–111, 2005.
- [2] Nevenka Djurovic, Milka Domazet, Ruzica Stricevic, Vesna Pocuca, Velibor Spalevic, Radmila Pivic, Enika Gregoric, and Uros Domazet. Comparison of groundwater level models based on artificial neural networks and anfis. *The Scientific World Journal*, 2015(742138):13, 2015.
- [3] Mohd khairul nizar Shamsuddin, Faradiella Mohd Kusin, Wan Sulaiman, M. Ramli, Mohamad Faizal Tajul Baharuddin, and Mohd Shalahuddin Adnan. Forecasting of groundwater level using artificial neural network by incorporating river recharge and river bank infiltration. *MATEC Web of Conferences*, 103:04007, 01 2017.
- [4] Kangning Sun, Litang Hu, Jianli Guo, Zhengqiu Yang, Yuanzheng Zhai, and Shouquan Zhang. Enhancing the understanding of hydrological responses induced by ecological water replenishment using improved machine learning models: A case study in yongding river. *Science of The Total Environment*, 768:145489, 2021.
- [5] Ali El Bilali, Abdeslam Taleb, and Youssef Brouziyne. Comparing four machine learning model performances in forecasting the alluvial aquifer level in a semi-arid region. *Journal of African Earth Sciences*, 181:104244, 2021.
- [6] Qi Liu, Dongwei Gui, Lei Zhang, Jie Niu, Heng Dai, Guanghui Wei, and Bill X. Hu. Simulation of regional groundwater levels in arid regions using interpretable machine learning models. *Science of The Total Environment*, 831:154902, 2022.
- [7] Thomas Erl, Wajid Khattak, and Paul Buhler. *Big Data Fundamentals: Concepts, Drivers & Techniques*. Prentice Hall Press, USA, 1st edition, 2016.
- [8] M. Campetella and A. Cechich. Caracterización de contexto en sistemas big data: Caso de estudio de las fluctuaciones del nivel freático en función de variables meteorológicas. 2023.
- [9] Klaus Pohl, Günter Böckle, and Frank J. van der Linden. *Software Product Line Engineering: Foundations, Principles and Techniques*. Springer-Verlag New York, Inc., Secaucus, NJ, USA, 2005.
- [10] Arshdeep Bahga and Vijay Madisetti. *Big Data Science Analytics: A Hands-On Approach. 1st Edition*. VPT, 2016.
- [11] Thomas Erl, Wajid Khattak, and Paul Buhler. *Big Data Fundamentals: Concepts, Drivers Techniques*. Prentice Hall Press, 1st edition, 2016.
- [12] Francis J. Pierce and Peter Nowak. Aspects of precision agriculture. volume 67 of *Advances in Agronomy*, pages 1–85. Academic Press, 1999.

- [13] Esteban Jobbagy and Marcelo Nosetto. Como hacer de las napas un aliado pautas y criterios para el monitoreo de niveles freáticos en sistemas de producción agrícola en la región pampeana. *Revista CREA*, 328:32–38, 01 2008.
- [14] J. Han, M. Kamber, and J. Pei. *Data Mining: Concepts and Techniques*. The Morgan Kaufmann Series in Data Management Systems. Elsevier Science, 3 edition, 2012.
- [15] L. Osycka, A. Cechich, A. Buccella, A. Montenegro, and A. Muñoz. Covamat: Functionality for variety reuse through a supporting tool. In *XI Conference on Cloud Computing, Big Data & Emerging Topics (JCC-BD&ET)*, 2023.
- [16] Lam Osycka, Agustina Buccella, and Alejandra Cechich. Data variety modeling: A case of contextual diversity identification from a bottom-up perspective. In Patricia Pesado and Gustavo Gil, editors, *Computer Science - CACIC 2021*, pages 124–138, Cham, 2022. Springer International Publishing.
- [17] A. Cechich, A. Buccella, A. Montenegro C. Villegas, and A. Munoz. A Rodriguez. A model of reusable variation in big data system development. In *XI Conference on Cloud Computing, Big Data & Emerging Topics (JCC-BD&ET)*, 2023.
- [18] A. Buccella, J. Luzuriaga, A. Cechich, L. Osycka, F. Paterno, M. Pol’la, M. Cruz, R. Martnez, R. Mazalu, and M. Moyano. Reusabilidad en el contexto de desarrollo de sistemas para big data. In *Actas del XXIII Workshop de Investigadores en Ciencias de la Computacion (WICC21)*, Chilecito, La Rioja, pages 525–529, 2021.
- [19] Agustina Buccella, Lam Osycka Alejandra Cechich, Juan Luzuriaga, Carolina Villegas, Marcos Cruz, Franco Corgatelli, Rodolfo Martnez, and Rafaela Mazalu. Covamat: Modelo conceptual de una herramienta para el soporte a la gestion de variedad en sistemas big data. In *Actas del XXV Workshop de Investigadores en Ciencias de la Computacion (WICC23)*, Junn, Bs As, 2023.
- [20] Big Data Fundamentals Concepts, Drivers Techniques, author = Thomas Erl, year = 2016.
- [21] Cort J. Willmott and Kenji Matsuura. Advantages of the mean absolute error (mae) over the root mean square error (rmse) in assessing average model performance. *Climate Research*, 30:79–82, 2005. Published December 19.
- [22] Boyle D. P. Krause, P. and F. Base. Comparison of different efficiency criteria for hydrological model assessment. 2005.
- [23] Arshdeep Bahga and Vijay Madisetti. *Big Data Science & Analytics: A Hands-On Approach*. 1st edition, 2016.
- [24] Essam El-Hashash and Raga Hassan. A comparison of the pearson, spearman rank and kendall tau correlation coefficients using quantitative variables. *Asian Journal of Probability and Statistics*, 20:36–48, 10 2022.
- [25] Pramita Sree Muhuri, Prosenjit Chatterjee, Xiaohong Yuan, Kaushik Roy, and Albert Esterline. Using a long short-term memory recurrent neural network (lstm-rnn) to classify network attacks. *Information*, 11(5):243, 2020. Submission received: 26 March 2020 / Revised: 23 April 2020 / Accepted: 28 April 2020 / Published: 1 May 2020.
- [26] Tianfeng Chai and R.R. Draxler. Root mean square error (rmse) or mean absolute error (mae)?– arguments against avoiding rmse in the literature. *Geoscientific Model Development*, 7:1247–1250, 06 2014.

- [27] Sylvain Arlot and Alain Celisse. A survey of cross-validation procedures for model selection. *Statistics Surveys*, 4(none):40 – 79, 2010.
- [28] Rodolfo G. Bongiovanni, Evandro C. Montovani, Stanley Best, and Alvaro Roel. *Agricultura de precisión: integrando conocimientos para una agricultura moderna y sustentable*. 2006. [en línea]. Montevideo, Uruguay: PROCISUR/IICA. (Consultado: 30 junio 2024).
- [29] Jyh-Shing R Jang. Anfis: Adaptive-network-based fuzzy inference system. 1993.
- [30] VICENTE VEGA ANGIE CAROLINA. Ensayo del método muskingum-cunge. 2020.
- [31] Liam Osycka. Modelado bottom-up de variedad de dominio en sistemas big data, 2022.
- [32] A. Buccella, A. Cechich, M. Pol'la, M. Arias, S. Doldan, and E. Morsan. Marine ecology service reuse through taxonomy-oriented SPL development. *Computers & Geosciences*, 73(0):108 – 121, 2014.
- [33] Agustina Buccella, Alejandra Cechich, Juan Porfiri, and Domenica Diniz Dos Santos. Taxonomy-oriented domain analysis of gis: A case study for paleontological software systems. *ISPRS International Journal of Geo-Information*, 8(6), 2019.
- [34] J. Olivier. *Business Math: A Step-by-step Handbook*. Open Textbooks, 2021. [Online]. Available: <https://mds.marshall.edu/oa-textbooks/552>.